



Análise

As emoções são importantes: uma revisão sistemática e meta-análise da detecção e classificação das emoções dos alunos em STEM durante a aprendizagem online

Aamir Anwar e ¹ , Ikram Ur Rehman ^{1,*} , Moustafa M. Nasralla ¹ 

¹ , Sohaib Bin Altaf Khattak ² 

Nasrullah Khilji

¹ Escola de Computação e Engenharia, Universidade de West London, Londres W5 5RF, Reino Unido; 21452391@student.uwl.ac.uk (AA); nasrullah.khilji@uwl.ac.uk (NK)

² Laboratório de Engenharia de Sistemas Inteligentes, Departamento de Engenharia de Comunicações e Redes, Prince Sultan University, Riyadh 66833, Arábia Saudita; mnasralla@psu.edu.sa (MMN); skhattak@psu.edu.sa (SBAK)

* Correspondência: ikram.rehman@uwl.ac.uk

Resumo: Nos últimos anos, o rápido crescimento da aprendizagem online destacou a necessidade de métodos eficazes para monitorar e melhorar as experiências dos alunos. As emoções desempenham um papel crucial na formação do envolvimento, motivação e satisfação dos alunos em ambientes de aprendizagem online, especialmente em disciplinas STEM complexas. Neste contexto, a análise de sentimento emergiu como uma ferramenta promissora para detectar e classificar emoções expressas em formas textuais e visuais. Este estudo oferece uma extensa revisão da literatura usando a técnica de itens de relatório preferidos para revisões sistemáticas e meta-análises (PRISMA) sobre o papel da análise de sentimento na satisfação do aluno e na aprendizagem on-line em disciplinas STEM. A revisão analisa a aplicabilidade, os desafios e as limitações das técnicas de análise de sentimentos baseadas em textos e expressões faciais em ambientes educacionais, revisando 57 artigos de pesquisa revisados por pares de 236 artigos, publicados entre 2015 e 2023, inicialmente identificados por meio de uma estratégia de pesquisa abrangente. Através de um extenso processo de busca e escrutínio, esses artigos foram selecionados com base em sua relevância e contribuição para o tema. As conclusões da revisão indicam que a análise de sentimento tem um potencial significativo para melhorar as experiências dos alunos, encorajando a aprendizagem personalizada e promovendo a satisfação no ambiente de aprendizagem online. Educadores e administradores podem obter informações valiosas sobre as emoções e percepções dos alunos, empregando técnicas computacionais para analisar e interpretar emoções expressas em textos. No entanto, a revisão também identifica vários desafios e limitações associados à análise de sentimentos em ambientes educacionais. Esses desafios incluem a necessidade de detecção e interpretação precisa de emoções, abordagem de variações culturais e linguísticas, garantia de privacidade e ética dos dados e dependência de fontes de dados de alta qualidade. Apesar destes desafios, a revisão destaca o imenso potencial da análise de sentimento na transformação de experiências de aprendizagem online em disciplinas STEM e recomenda mais investigação e desenvolvimento nesta área.

Palavras-chave: educação inclusiva; análise de sentimentos; satisfação dos alunos; inteligência artificial; reconhecimento e classificação de emoções; tecnologias emergentes; análise de sentimento facial; PRISMA



Citação: Anwar, A.; Rehman, U.; Nasralla, MM; Khattak, SBA; Khilji, N. Emotions Matter: Uma revisão sistemática e meta-análise da detecção e classificação das emoções dos alunos em STEM durante o aprendizado on-line. Educ. Ciência. **2023**, *13*, 914. <https://doi.org/10.3390/educsci13090914>

Editor Acadêmico: Anastasia Sofroniou

Recebido: 19 de julho de 2023

Revisado: 1º de setembro de 2023

Aceito: 4 de setembro de 2023

Publicado: 8 de setembro de 2023



Direitos autorais: © 2023 dos autores. Licenciado MDPI, Basileia, Suíça.

Este artigo é um artigo de acesso aberto distribuído nos termos e condições do Creative Commons

Licença de atribuição (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

1. Introdução

Espera-se que o mercado global de aprendizagem on-line ultrapasse US\$ 848,12 bilhões até 2030 [1]. Tornou-se popular, especialmente em resposta à pandemia de COVID-19. Como resultado, os educadores tiveram que adaptar os seus métodos de ensino para acomodar as necessidades dos alunos online. Um dos problemas mais desafiadores para os instrutores é manter os alunos envolvidos no processo de aprendizagem. O envolvimento do usuário é um atributo da experiência do usuário que avalia o investimento cognitivo, afetivo e comportamental de uma pessoa ao interagir com um ambiente dig

sistema [2]. Em contraste, o envolvimento do aluno refere-se ao nível de atenção, interesse, otimismo e paixão dos alunos quando aprendem ou são ensinados [3]. O envolvimento é fundamental para aprendizagem porque aumenta a probabilidade dos alunos reterem informações e completarem o curso [4,5]. Manter os alunos motivados em um ambiente de aprendizagem on-line pode ser desafiador devido a muitas distrações, como barulho de familiares ou animais de estimação, questões tecnológicas e outras demandas, como autodisciplina e gerenciamento de tempo. Para garantir sucesso dos alunos, os educadores devem desenvolver formas inovadoras de mantê-los envolvidos e motivados. As tecnologias interativas são uma das técnicas para aumentar o envolvimento do aluno na aprendizagem on-line. Ao fornecer um ambiente de aprendizagem mais imersivo e dinâmico, a tecnologia interativa ajuda a manter os alunos interessados [6]. Por exemplo, discussão on-line fóruns e salas de bate-papo podem ser utilizados para aumentar a colaboração dos alunos e promover atividades ativas aprendizado. Os questionários e jogos online, por outro lado, podem tornar o estudo mais interessante e envolvente, ao mesmo tempo que proporcionam aos alunos feedback instantâneo sobre o seu progresso [7]. A realidade virtual (VR) e a realidade aumentada (AR) também podem ser usadas para criar ambientes mais envolventes e experiências de aprendizagem imersivas. Os educadores podem ajudar os alunos a permanecerem envolvidos e motivados em seus estudos ao introduzir essas tecnologias em seus cursos on-line.

A análise de sentimento (SA) está se tornando cada vez mais significativa em muitas áreas, incluindo marketing, saúde e educação, uma vez que permite a captura e avaliação de emoções expressas por meio de diversas modalidades, como texto, gestos faciais, sinais de eletroencefalograma (EEG) e vozes [8]. Como outras modalidades, os sinais EEG também são importantes para capturar emoções, pois medem diretamente a atividade cerebral associada a estados emocionais [9]. Eles podem fornecer insights sobre os sentimentos, atitudes e opiniões das pessoas, analisando o sentimento, o que pode informar a tomada de decisões e melhorar a qualidade de serviços e bens. Por exemplo, a análise do sentimento do feedback do cliente pode ajudar empresas na melhoria de seus produtos ou serviços, enquanto a análise de sentimento dos pacientes o feedback pode ajudar os profissionais de saúde a melhorar o atendimento ao paciente. Além disso, a análise de sentimento pode ser usada para monitorar conversas on-line em busca de ameaças potenciais, como cyberbullying ou discurso de ódio e em sala de aula para analisar as expressões faciais dos alunos e inferir os seus estados emocionais ou sentimentos durante as atividades de aprendizagem. Como sentimento análise continua a se desenvolver e se expandir, ela pode revolucionar a forma como entendemos e interagir uns com os outros, tanto online como offline.

Com base na análise de sentimento, é evidente que educadores e alunos consistentemente enfatizar e valorizar a importância do envolvimento dos alunos na aprendizagem online [10]. A análise de sentimento que examina conversas online e atividades nas redes sociais pode divulgar os pontos de vista e opiniões dos alunos sobre a aprendizagem on-line e a eficiência de várias táticas de engajamento, como multimídia interativa, gamificação e aprendizagem personalizada. Em geral, a análise de sentimento revelou que os estudantes têm maior probabilidade de se interessar e motivado em ambientes de aprendizagem on-line interativos, colaborativos e imersivos [11]. Os educadores podem contribuir para a criação de uma experiência de aprendizagem online mais útil e eficaz para todos os alunos, avaliando os seus sentimentos em relação à aprendizagem online e utilizando esse conhecimento para orientar suas práticas docentes. Além disso, a análise de sentimento também demonstraram que o envolvimento do aluno se correlaciona positivamente com o desempenho acadêmico [11]. Quando os alunos se envolvem ativamente na aprendizagem, é mais provável que retenham informações, aplique-as a situações do mundo real e obtenha notas mais altas. Em contraste, alunos desinteressados são mais propensos a ter dificuldades com a motivação e podem ter níveis mais baixos de desempenho acadêmico [12]. Isto realça a importância de implementar medidas eficazes estratégias de envolvimento na aprendizagem online, especialmente durante a pandemia de COVID-19, o que forçou muitos alunos a aprender remotamente. Ao aproveitar a análise de sentimento para identificar as estratégias mais eficazes para promover o envolvimento, os educadores podem ajudar a garantir seus alunos são bem-sucedidos e preparados para futuras atividades acadêmicas e profissionais. A Figura 1 mostra uma ilustração da análise de sentimento facial e baseada em texto na aprendizagem online.

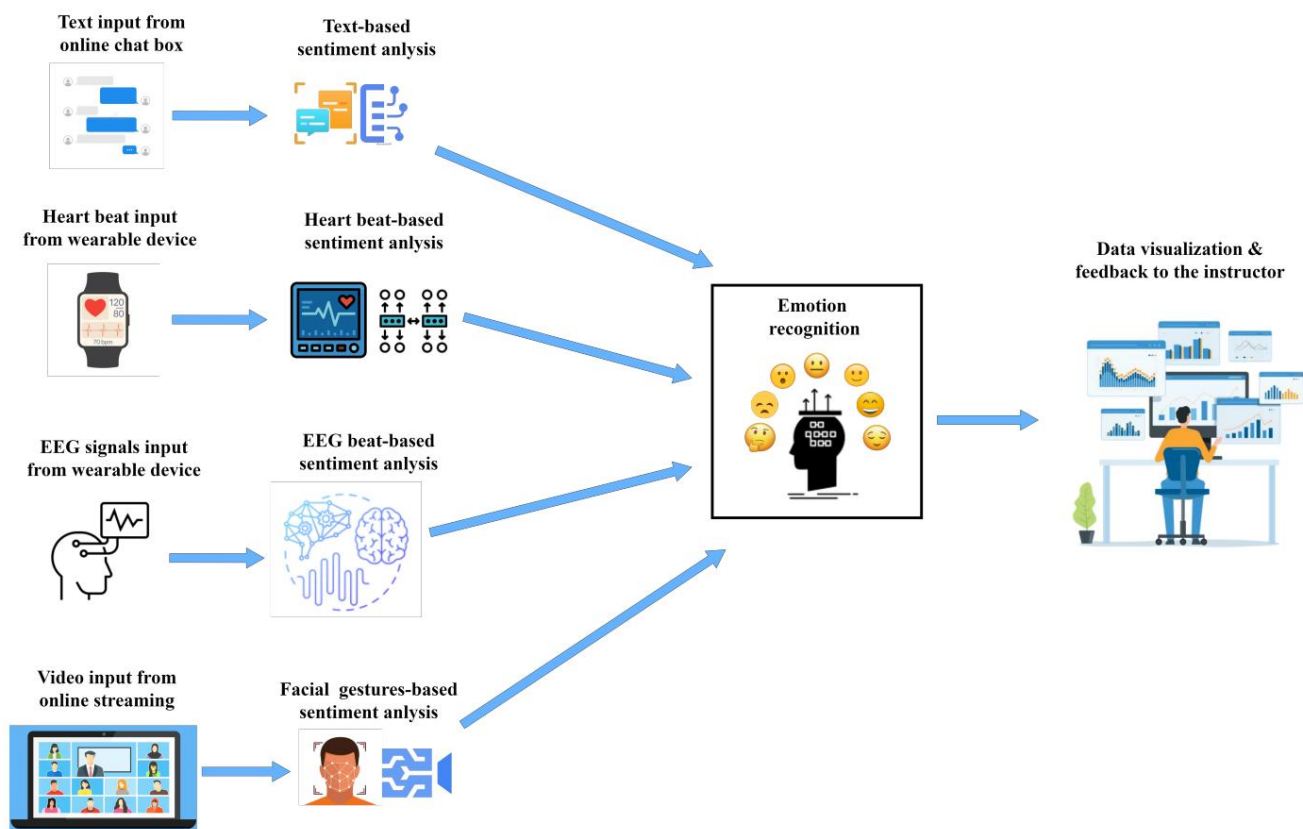


Figura 1. Análise de sentimentos e classificação de emoções na aprendizagem online.

Embora a popularidade da análise de sentimento tenha crescido nos últimos anos para avaliar as atitudes e opiniões das pessoas sobre vários tópicos, incluindo aprendizagem on-line, vários problemas estão associados ao uso da análise de sentimento para analisar bate-papos, gestos faciais e vídeos. Um dos problemas mais desafiadores é que diferentes modos de comunicação podem ser complicados e multifacetados, dificultando a captura e compreensão eficaz do sentimento. Os indivíduos, por exemplo, podem usar sarcasmo ou ironia em discussões escritas ou verbais, algo que os algoritmos de análise de sentimento podem achar difícil de distinguir [14]. Da mesma forma, as expressões faciais e a linguagem corporal podem transmitir uma ampla gama de emoções e atitudes, que podem ser difíceis de categorizar usando abordagens automatizadas de análise de sentimentos [15]. Outros desafios da análise de sentimento são a possibilidade de viés de dados, barreiras linguísticas, variações culturais e estilos de escrita individuais, que podem impactar os dados do chat.

À luz das questões associadas à análise de sentimentos baseada em chat e gestos faciais no contexto do online e do e-learning, há uma clara necessidade de mais pesquisas para melhorar a precisão e a confiabilidade dessas modalidades. O desenvolvimento de técnicas mais avançadas pode enfrentar os desafios da interpretação precisa de expressões faciais e baseadas em texto e melhorar a precisão geral da análise de sentimentos. Além disso, é necessário um estudo de revisão sistemática para analisar os conjuntos de dados, técnicas e desempenho atuais da análise de sentimento baseada em texto e gestos faciais para fazer recomendações para melhorar a análise de sentimento na aprendizagem online.

Além disso, este artigo apresenta quatro questões de pesquisa, que são apresentadas na Tabela 1. É importante notar que estas questões de investigação são respondidas na secção Resultados e Análise (ou seja, Secção 5), com base na revisão e avaliação realizadas no nosso estudo.

Tabela 1. Questões de pesquisa.

Pergunta nº. Pergunta de pesquisa	
RQ1	Como a análise de sentimento baseada em texto tem sido usada no domínio educacional para facilitar os alunos?
RQ2	Quais são os desafios/limitações da análise de sentimento baseada em texto em ambientes online? aprendido?
RQ3	Como a análise de sentimento facial tem sido usada no domínio educacional para facilitar os alunos?
RQ4	Quais são os desafios/limitações da análise de sentimento facial on-line? aprendido?

A análise de sentimentos é uma técnica amplamente aplicada em vários domínios, incluindo a educação, onde tem atraído considerável atenção dos investigadores. No entanto, são escassas revisões abrangentes e sistemáticas da literatura sobre análise de sentimentos na educação e limitado. Por exemplo, Oghu et al. [16] conduziram uma revisão sistemática da literatura sobre as técnicas, recursos e benefícios da análise de sentimentos na educação; no entanto, eles incluíram um número limitado de artigos em seu estudo. Da mesma forma, Dolianiti et al. [17] revisaram o estado atual da análise de sentimento na educação, mas não examinaram os processos experimentais e métodos de análise de sentimento na educação, nem considere as categorias de sentimento, os objetivos da pesquisa e as principais conclusões dos estudos. Outro estudo, de Jin Zhou et al. [18], tentaram preencher esta lacuna conduzindo uma revisão sistemática da literatura sobre análise de sentimento na educação de 2010 a 2020, com foco em os propósitos da pesquisa, categorias de sentimento, fontes de dados, métodos e descobertas dos estudos. No entanto, este estudo também teve algumas limitações, como a exclusão de alguns artigos que não correspondiam aos termos de pesquisa, apenas revisando publicações de periódicos, e não realizando uma meta-análise dos estudos incluídos. Além disso, a maioria das revisões de literatura existentes sobre análise de sentimento na educação concentra-se em dados baseados em texto, enquanto outras formas de dados, como sinais de EEG, áudio e vídeo, ainda precisam ser abordadas. Por exemplo, Kastrati et al. [19] revisaram as abordagens/técnicas e soluções para sistemas de análise de sentimento baseados em texto, bem como as métricas de avaliação e conjuntos de dados usados para avaliar seu desempenho. Eles discutiram o uso do processamento de linguagem natural (PNL), como abordagens baseadas em léxico e dicionário, para SA baseada em texto. No entanto, não abordaram os desafios e oportunidades da aplicação da análise de sentimentos a outros tipos de dados que estão cada vez mais disponíveis em ambientes educativos. Wankhade e outros. [20] realizaram uma revisão abrangente e sistemática da literatura sobre os métodos e avaliação de tarefas de análise de sentimento e suas aplicações em diversos domínios. Eles avaliaram os pontos fortes e as limitações dos métodos e identificaram o futuro desafios de pesquisa da análise de sentimento em relação aos métodos e aos tipos de dados. No entanto, esta pesquisa não discute a análise de sentimento nos setores educacional e online. domínios de aprendizagem.

Portanto, há necessidade de uma revisão bibliográfica mais abrangente e atualizada sobre análise de sentimento na educação que abrange fontes de dados baseadas em texto e faciais juntamente com diferentes métodos e aplicações em vários contextos educacionais. Este papel fornece uma visão holística do estado atual da arte e das direções futuras do sentimento análise em educação.

Além disso, nosso estudo enfatiza o vasto potencial da análise de sentimento na remodelação de experiências de aprendizagem on-line em disciplinas STEM. Além disso, exige medidas adicionais pesquisas e avanços neste domínio para desbloquear ainda mais potencial.

2. Fundamentação Teórica

Esta seção fornece uma base essencial para a compreensão dos conceitos-chave e técnicas relacionadas à análise de sentimento. Abrange duas subseções principais, ou seja, análise de sentimento baseada em texto e análise de sentimento facial. O primeiro está dividido

em quatro níveis e este último é dividido em dois níveis amplos, conforme mostrado na Figura 2. Exploramos ainda mais esses níveis de análise de sentimento e investigamos as técnicas empregadas na análise de sentimento de texto e facial. Esta seção tem como objetivo estabelecer uma base para as investigações e descobertas apresentadas neste artigo, abordando de forma abrangente a análise de sentimento baseada em texto e facial.

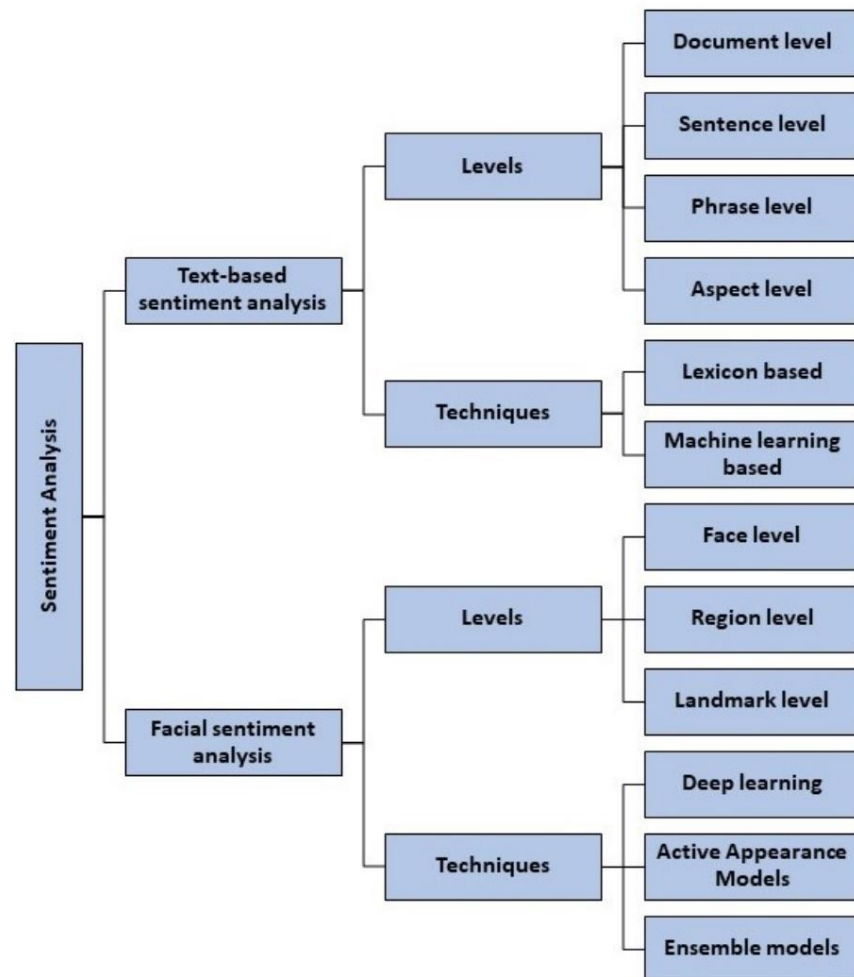


Figura 2. Taxonomia da análise de sentimento.

2.1. Análise de sentimento baseada em texto

A análise de sentimento baseada em texto usa técnicas de PNL para extrair informações úteis de um texto e classificar essas informações em certas classes de sentimento, como felicidade, tristeza, estresse, raiva e outras emoções [21]. A análise de sentimento baseada em texto visa extrair as informações necessárias e insights significativos do texto, permitindo que os educadores tomem decisões informadas. A análise de sentimento baseada em texto pode ser usada em determinadas áreas, como detecção de emoções em postagens no Twitter, detecção de emoções dos alunos sobre métodos e conteúdo de ensino usando respostas ou pesquisas dos alunos e detecção de emoções dos consumidores ao utilizar um produto ou serviço. Por exemplo, os autores em [22] usaram análise de sentimento em dados do Twitter para coletar comentários sobre filmes antes de serem lançados. Este estudo previu receitas de bilheteria para os próximos filmes e descobriu uma associação significativa entre a quantidade de atenção que um próximo filme tem no Twitter e Outro estudo usou análise de sentimento nas análises de aplicativos móveis para selecionar aplicativos altamente avaliados para transtorno do espectro do autismo (TEA) [23]. Da mesma forma, os autores em [24] utilizaram a análise de sentimento no domínio educacional, utilizando dados de bate-papo dos alunos durante sessões de aprendizagem online. Este estudo explorou a eficácia de diferentes estratégias de tutoria e conteúdos de ensino, classificando as respostas dos alunos em emoções positivas e negativas.

Depois de construir nossa compreensão básica da análise de sentimento baseada em texto, avançamos explorá-lo investigando dois aspectos principais: os níveis de análise e a gama de técnicas utilizado neste campo.

2.1.1. Níveis de análise de sentimento baseados em texto

A análise de sentimento baseada em texto pode ser aplicada em quatro níveis de granularidade, ou seja, (1) análise em nível de documento, (2) análise em nível de frase, (3) análise em nível de frase e (4) análise em nível de aspecto. Os diferentes níveis de análise de sentimento baseada em texto são ainda mais discutido abaixo:

- (a) **Análise de sentimento em nível de documento:** A abordagem do sentimento em nível de documento análise envolve analisar um documento inteiro e atribuir uma única polaridade a o documento como um todo [20]. Embora esta abordagem não seja frequentemente utilizada, pode ser útil para categorizar capítulos ou páginas de um livro como positivos, negativos ou neutros sentimentos. Suponha que um artigo sobre “uso da tecnologia no domínio educacional para melhorar a aprendizagem do aluno” pode ser revisado usando o sentimento em nível de documento análise para determinar o sentimento geral expresso no artigo em relação ao impacto da integração tecnológica nos resultados de aprendizagem dos alunos. Ambos supervisionados e métodos de aprendizagem não supervisionados podem classificar o documento [25]. Um dos os desafios mais significativos na análise de sentimento em nível de documento são entre domínios e análise de sentimento entre idiomas [25]. Por exemplo, a análise de sentimento específica do domínio alcançou alta precisão, mantendo a sensibilidade do domínio. Essas tarefas exigem que um conjunto de palavras específicas e limitadas do domínio seja usado como vetor de recursos.
- (b) **Análise de sentimento em nível de frase:** a análise de sentimento em nível de frase avalia as emoções de frases individuais dentro de um texto. Por exemplo, “O professor explicou muito bem este tema”. Neste caso, a análise de sentimento em nível de frase técnica analisaria e classificaria a sentença como positiva. Enquanto comparado com análise de sentimento em nível de documento, esta abordagem fornece uma análise de sentimento mais granular. Para análise de sentimento em nível de frase, métodos de aprendizado de máquina como Bayes ingênuo (NB), máquina de vetores de suporte (SVM) e modelos de aprendizado profundo, por exemplo, redes neurais recorrentes (RNNs) e redes neurais convolucionais (CNNs), podem ser utilizados [26]. Lidar com negação, sarcasmo e ironia, e lidar com linguagem e jargão específicos do domínio são desafios típicos do nível de frase análise de sentimentos. Apesar desses desafios, a análise de sentimento em nível de frase tem aplicações em vários domínios, incluindo análise de feedback de clientes, redes sociais monitoramento de mídia e análise de revisão de produtos. Esta abordagem proporciona uma abordagem mais compreensão completa do sentimento expresso em um texto, analisando o sentimento de frases individuais, que pode ser usado para melhorar a tomada de decisão e satisfação do consumidor.
- (c) **Análise de sentimento em nível de frase:** O sentimento de frases ou expressões individuais dentro de uma frase ou texto é analisado em nível de frase. Por exemplo, “O estilo de ensino e o conteúdo do tema me ajudaram a compreender essa informação complexa”. Neste exemplo, a frase “me ajudou a entender isso informação complexa” indica um sentimento positivo, pois sugere que o ensino o estilo e o conteúdo facilitaram efetivamente a compreensão de informações complexas. Em comparação com a análise de sentimento em nível de frase, esta abordagem fornece uma análise uniforme análise mais granular. Para análise de sentimento em nível de frase, algoritmos de aprendizado de máquina como SVM, árvores de decisão, redes neurais e técnicas baseadas em regras são necessários. frequentemente utilizado [27]. Lidar com frases dependentes do contexto, expressões idiomáticas do dia-a-dia e palavras pouco claras são os desafios mais comuns da análise de sentimento em nível de frase. No entanto, a análise de sentimentos em nível de frase tem muitas aplicações, incluindo análise de avaliações de clientes, monitoramento de mídias sociais, mineração de opinião, etc. fornece uma compreensão mais sofisticada do sentimento representado em um texto

analisando o sentimento de frases individuais, o que pode auxiliar no fortalecimento da tomada de decisão e na satisfação do consumidor.

- (d) **Análise de sentimento em nível de aspecto:** O sentimento de aspectos ou características específicas de um produto ou serviço descrito em um texto é analisado usando análise de sentimento em nível de aspecto. Este método é benéfico para as empresas, pois revela quais componentes de seus produtos ou serviços os clientes mais apreciam ou não gostam. Algoritmos de aprendizado de máquina como SVM, RNN e CNN são comumente usados para análise de sentimento em nível de aspecto [28]. Em uma revisão massiva de um curso on-line aberto (MOOC), por exemplo, a análise de sentimento em nível de aspecto analisaria o sentimento de fatores específicos, como material de aprendizagem, qualidade do ensino e experiência do instrutor, em vez de apenas fornecer uma classificação geral positiva ou negativa.

2.1.2. Técnicas de análise de sentimento baseadas em texto

A análise de sentimento baseada em texto é uma forma proeminente e amplamente utilizada de análise de sentimento, portanto, várias técnicas foram desenvolvidas para realizar a análise de sentimento. Métodos baseados em léxico, aprendizado de máquina e híbridos são algumas das técnicas mais comumente usadas na análise de sentimento baseada em texto. A Figura 3 fornece uma visão geral de diferentes técnicas de análise de sentimentos para detecção e classificação de emoções. Esta seção se concentra em duas abordagens proeminentes: as abordagens baseadas em léxico e de aprendizado de máquina. Fornecerá a compreensão necessária das metodologias empregadas para extrair informações de sentimento de dados textuais, destacando suas metodologias distintas e aplicações práticas.

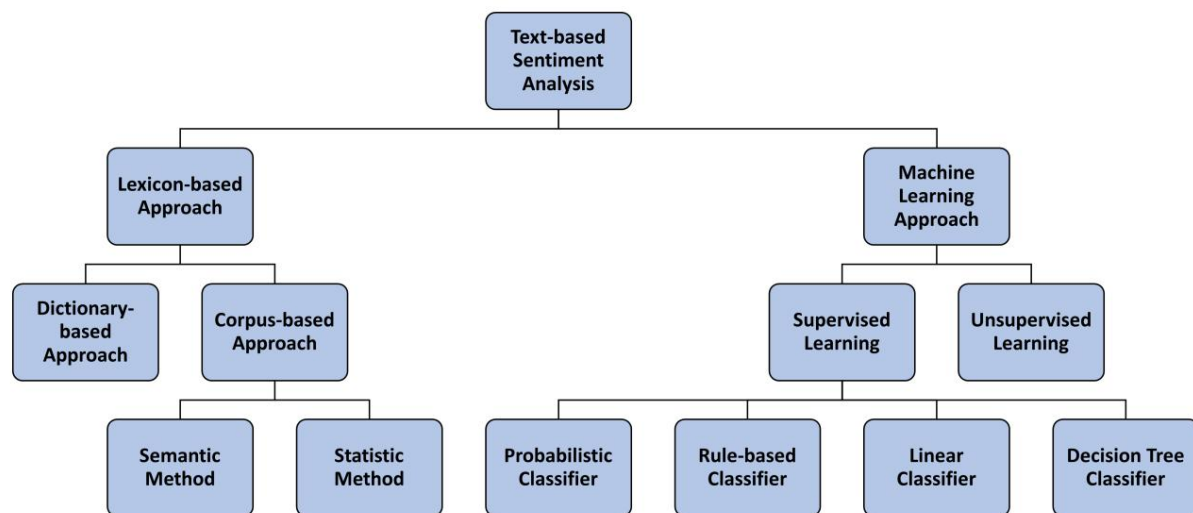


Figura 3. Técnicas de análise de sentimento baseadas em texto [29].

- (a) **Abordagem baseada no léxico:** A análise de sentimento baseada no léxico é um método estabelecido que determina o sentimento de um texto usando dicionários de termos predefinidos e suas pontuações de sentimento associadas. Cada palavra no texto é pontuada com base em sua polaridade, ou seja, positiva, negativa ou neutra. A soma ou média das pontuações das palavras no texto é então usada para calcular o sentimento geral do texto [30]. As técnicas baseadas em léxico têm a vantagem de serem razoavelmente simples de implementar e exigem um mínimo de dados anotados para treinamento. No entanto, a cobertura e a qualidade dos léxicos utilizados podem limitar a sua precisão [31]. Para resolver esta limitação, os pesquisadores desenvolveram vários léxicos específicos para domínios ou idiomas específicos [32]. Além disso, abordagens baseadas em léxico podem ser combinadas com outras técnicas, como marcação de classes gramaticais e análise sintática, para melhorar a precisão da análise de sentimento [33]. Alguns dos proeminentes

as técnicas de análise de sentimento baseada em léxico utilizadas na literatura são apresentadas na Tabela 2.

Tabela 2. Técnicas de análise de sentimento baseadas em léxico.

Técnica	Descrição Um	Referências)
SentiWordNet	recurso léxico disponível publicamente para mineração de opinião que atribui a cada synset do WordNet três pontuações de sentimento: positividade, negatividade e objetividade.	[34–36]
VADER	Uma ferramenta de análise de sentimento baseada em regras que utiliza um léxico de palavras e suas pontuações de intensidade, bem como regras gramaticais, para determinar a polaridade de um determinado texto.	[37,38],
SenticNet	Uma estrutura de análise de sentimento em nível de conceito que atribui pontuações de sentimento a conceitos com base em sua orientação semântica, polaridade conceitual e relação semântica com outros conceitos.	[39,40]
AFINN	Uma lista de palavras em inglês classificadas em valência com um número inteiro entre menos cinco (negativo) e mais cinco (positivo).	[41,42]
Léxico de Emoções NRC	Uma lista de palavras em inglês e suas associações com oito emoções básicas (raiva, medo, antecipação, confiança, surpresa, tristeza, alegria e nojo) e dois sentimentos (negativo e positivo).	[43,44]
Padrão	Um pacote Python que inclui um módulo de análise de sentimento baseado em um léxico de palavras de sentimento e um classificador baseado em regras. Ele pode lidar com negações, expressões idiomáticas e gírias, e também pode ser treinado em dados personalizados.	[45,46]
TextBlob	Uma biblioteca Python que inclui um módulo de análise de sentimento baseado no analisador de padrões. Ele também inclui um classificador Bayes ingênuo que pode ser treinado em dados personalizados.	[47,48]

(b) **Abordagem de aprendizado de máquina:** abordagens baseadas em aprendizado de máquina têm sido amplamente utilizadas na análise de sentimento devido à sua capacidade de aprender automaticamente padrões e relacionamentos complexos em dados. Uma estratégia proeminente é usar algoritmos de aprendizagem supervisionada, como SVM, NB e árvores de decisão, para classificar o texto como positivo, negativo ou neutro com base em dados de treinamento rotulados [49]. A aprendizagem não supervisionada é outra estratégia, que envolve agrupar documentos semelhantes com base em seu sentimento, usando técnicas como agrupamento k-means ou alocação latente de Dirichlet (LDA) [50]. Abordagens de aprendizagem profunda, como RNN e CNN, também têm sido utilizadas com sucesso em tarefas de análise de sentimento [51]. Esses algoritmos requerem enormes dados de treinamento e recursos computacionais, mas podem alcançar excelente precisão e generalização entre domínios e idiomas. No geral, as técnicas baseadas em aprendizado de máquina para análise de sentimentos em dados de texto fornecem um método robusto e adaptável. Uma lista das técnicas de aprendizado de máquina mais comumente usadas para análise de sentimentos é fornecida na Tabela 3.

Tabela 3. Técnicas de análise de sentimento de aprendizado de máquina.

Técnica	Descrição Um	Referências)
Baías ingênuas	algoritmo probabilístico que usa o teorema de Bayes para classificar o texto como positivo, negativo ou neutro.	[52,53]
Vetor de suporte Máquina (SVM)	Um algoritmo de aprendizagem supervisionada que separa dados em diferentes classes usando um hiperplano.	[54,55]
Floresta Aleatória	Um algoritmo de aprendizagem conjunto que constrói múltiplas árvores de decisão para classificar dados.	[56,57]
Convolutacional Rede neural (CNN)	Um tipo de rede neural que usa convolução camadas para aprender automaticamente recursos a partir dos dados de entrada.	[58,59]
Longo Curto Prazo Memória (LSTM)	Um tipo de rede neural recorrente que é capaz de capturar dependências de longo prazo nos dados de entrada.	[60,61]
Neurais Artificiais Redes (RNAs)	Um conjunto de algoritmos que tentam reconhecer relacionamentos subjacentes em um conjunto de dados por meio de um processo que imita como o cérebro humano funciona. Um modelo de linguagem pré-treinado que usa redes neurais profundas redes para gerar palavras contextualizadas	[62,63]
BERTO	incorporações. O BERT demonstrou alcançar resultados de última geração em uma ampla gama de ingredientes naturais tarefas de processamento de linguagem, incluindo sentimento análise.	[64,65]

2.2. Análise de sentimento facial

A análise de sentimento facial (FSA) é um campo emergente que ganhou muita atenção recentemente devido às suas aplicações potenciais em vários domínios, incluindo cuidados de saúde, educação, marketing e entretenimento. FSA envolve técnicas de visão computacional reconhecer expressões faciais e extrair automaticamente os estados emocionais dos indivíduos.

O principal objetivo da FSA é compreender as emoções e o comportamento humano através da análise facial características como sobrancelhas, olhos, nariz e boca. A FSA tem sido utilizada em muitas aplicações, como reconhecimento de emoções, detecção de estresse e detecção de engano.

O reconhecimento de expressões faciais para avaliar as respostas emocionais dos alunos oferece benefícios claros em relação à dependência exclusiva de dados auto-relatados. Autorrelatos podem ser influenciados pela subjetividade e desonestidade, pois os alunos podem não transmitir com precisão os seus verdadeiros sentimentos. As expressões faciais, por outro lado, fornecem um indicador objetivo e mensurável de emoções que não é afetados por preconceitos conscientes. A natureza automática do reconhecimento facial também leva a mais reações naturais e instintivas dos alunos, em vez de reações filtradas por deliberação.

Prevemos que o feedback em tempo real promove a geração de soluções inovadoras, a colaboração e o envolvimento dos alunos, que têm um forte impacto pedagógico na aprendizagem.

e metodologias de ensino. Algoritmos de aprendizagem profunda melhoraram significativamente a FSA desempenho nos últimos anos, permitindo análises mais precisas e confiáveis.

Vários estudos exploraram o potencial da FSA em vários domínios. Por exemplo, a FSA tem sido usada na área da saúde para reconhecer emoções em pacientes com depressão, ansiedade e transtorno bipolar. Um estudo [66] desenvolveu um FSA baseado em aprendizagem profunda

modelo para identificar depressão em pacientes analisando suas expressões faciais. O modelo alcançou uma precisão de 93,3%, demonstrando o potencial da FSA na detecção de transtornos mentais.

No domínio da educação, a FSA tem sido utilizada para monitorar o envolvimento e os níveis de atenção dos alunos durante a aprendizagem on-line [67]. Esta seção explorará os diferentes níveis em quais expressões faciais são analisadas para determinar estados emocionais e investigar vários metodologias empregadas para detectar e interpretar emoções a partir de expressões faciais.

2.2.1. Níveis de análise de sentimento facial

A FSA pode ser realizada em diferentes níveis, dependendo do nível de granularidade necessário para extrair informações emocionais de expressões faciais. Os três níveis primários de FSA são (1) análise em nível de rosto, (2) análise em nível de região e (3) análise em nível de referência, que são discutidos mais detalhadamente abaixo:

- (a) **Análise no nível do rosto:** No nível do rosto, a FSA envolve o reconhecimento de emoções demonstradas pelos indivíduos por meio de expressões faciais. Este tipo de análise é fundamental em áreas como a psicologia, o marketing e a interação humano-computador, onde a compreensão das emoções e dos seus efeitos é vital. Várias abordagens para realizar análises de sentimentos em nível facial foram propostas, incluindo métodos baseados em regras, baseados em recursos e baseados em aprendizagem profunda. Um estudo recente propôs uma abordagem baseada em aprendizagem profunda para análise de sentimento facial que superou os métodos tradicionais [68]. O modelo proposto utilizou uma CNN para extração de características e uma rede de memória de longo e curto prazo (LSTM) para modelagem de sequência. Outro estudo propôs um método para análise de sentimento facial que utilizava um conjunto de recursos artesanais, incluindo unidades de ação facial e suas combinações, para treinar um classificador SVM [69]. O método proposto alcançou uma alta precisão de 89,5% no conjunto de dados AffectNet [70]. Esses estudos destacam a eficácia de abordagens baseadas em aprendizagem profunda e em recursos para análise de sentimento no nível facial.
- (b) **Análise em nível de região:** A análise de sentimento facial em nível de região envolve a análise das expressões emocionais de regiões específicas do rosto, como olhos, boca ou sobrancelhas. Esta abordagem permite uma análise mais refinada da expressão emocional e pode fornecer insights sobre as emoções transmitidas. Várias técnicas de análise de sentimento facial em nível de região foram propostas, incluindo métodos baseados em aprendizagem profunda, como CNN e RNN [71]. Foi demonstrado que essas técnicas alcançam alta precisão na detecção de emoções em regiões específicas do rosto, como olhos ou boca. Outras abordagens incluem o uso de recursos geométricos e recursos artesanais, como padrões binários locais (LBPs) e histograma de gradientes orientados (HOGs), que também demonstraram ser eficazes na análise de sentimento em nível de região [72]. No entanto, a análise em nível de região ainda é um desafio devido à oclusão e às variações na intensidade da expressão, que podem afetar a precisão do reconhecimento de emoções [73]. No geral, a análise de sentimentos faciais em nível regional mostrou-se promissora na melhoria da precisão e granularidade no reconhecimento das emoções das expressões faciais. Mais pesquisas são necessárias para enfrentar os desafios restantes, como o reconhecimento de emoções sutis, a subjetividade e a variação individual e a compreensão contextual.
- (c) **Análise em nível de ponto de referência:** A detecção de pontos de referência faciais é outra abordagem usada para FSA. Essa abordagem baseia-se na extração de marcos faciais, definidos como pontos críticos da face, como cantos da boca, nariz e olhos. Esses pontos de referência são então usados para extrair recursos para reconhecimento de emoções. Esta técnica tem sido utilizada em estudos recentes para FSA. Por exemplo, em um estudo, os autores usaram pontos de referência faciais para reconhecer emoções de vídeos do YouTube para desenvolver um algoritmo de seleção de recursos eficaz para determinar os recursos ideais para melhorar ainda mais o desempenho da análise de sentimento multimodal [74]. Outro estudo utilizou marcos faciais para reconhecimento de emoções no contexto da robótica social [75]. A abordagem no nível do ponto de referência é considerada mais precisa do que as abordagens no nível do rosto ou da região, pois captura mudanças mais sutis nas expressões faciais que podem ser perdidas nos níveis mais elevados. No entanto, requer mais recursos computacionais e pode não ser adequado para aplicações em tempo real, como sistemas de monitoramento de motoristas e reconhecimento de emoções em videoconferências.

2.2.2. Técnicas de análise de sentimento facial

Algoritmos de visão computacional e aprendizado de máquina são normalmente empregados em abordagens FSA para analisar expressões faciais e extrair informações emocionais de rostos humanos. Várias metodologias são aplicadas nessas técnicas, como identificação de marcos faciais para identificar características faciais significativas, reconhecimento de expressões faciais para classificar emoções e estimativa de intensidade para quantificar a força das emoções exibidas. Modelos de aprendizagem profunda, como CNNs, RNNs ou arquiteturas híbridas, são comumente usados nessas metodologias. Esses algoritmos são treinados em enormes conjuntos de dados de expressões faciais rotuladas.

expressões para compreender padrões e gerar previsões confiáveis. Além disso, algumas técnicas analisam outras características faciais, como movimentos dos olhos, pose da cabeça ou microexpressões, para melhorar a precisão da análise de sentimentos. Com os avanços na visão computacional e no aprendizado de máquina, as técnicas de FSA estão evoluindo, permitindo aplicações em domínios tão diversos como pesquisa de mercado, atendimento ao cliente, educação e interação humano-computador. Várias técnicas podem ser aplicadas em cada nível de FSA. Algumas das técnicas comumente usadas são fornecidas abaixo na Tabela 4.

Tabela 4. Técnicas de análise de sentimento facial utilizadas em diferentes níveis.

Técnica	Descrição	Nível	Referências)
Viola-Jones Algoritmo	Detecta rostos usando recursos semelhantes aos do Haar	Nível do rosto	[76–78]
Autofaces	Projeta imagens faciais em um espaço de dimensão inferior e usa Análise do componente principal (PCA) para classificar emoções	Nível do rosto	[79,80]
Padrões Binários Locais (LBPs)	Descritor de textura que extrai informações sobre padrões locais de intensidades de pixels	Nível do rosto	[81–83]
Caras de Pescador	Projeta imagens faciais em um espaço de dimensão inferior e usa Análise discriminante de Fisher (FDA) para classificar emoções	Nível do rosto	[84]
Convolutacional Redes neurais (CNNs)	Redes neurais multicamadas que podem aprender automaticamente recursos para classificar emoções	Nível do rosto	[85,86]
Modelos de formas ativas (ASM)	Modelos estatísticos da forma e aparência de objetos, usados para detectar características faciais	Nível de referência	[87,88]
Aparência Ativa Modelos (AAMs)	Extensão de ASMs que também modela informações de textura para rastrear alterações de expressão facial	Nível de referência	[89,90]
Local restrito Modelos (CLMs)	Combina um ASM com um modelo de textura para rastrear expressões faciais e melhorar a precisão	Nível de referência	[91]
Codificação de ação facial Sistema (FACS)	Sistema para analisar e descrever expressões faciais com base na ativação de músculos individuais	Nível de referência	[92,93]
Histogramas de Gradientes Orientados (HOGs)	Descritor que extrai informações sobre a distribuição das direções do gradiente em uma imagem	Nível de região	[94]
Escala Invariante Transformação de recurso (SIFT)	Descritor que extrai recursos invariantes ao dimensionamento, rotação e translação	Nível de região	[95,96]
Acelerado e Robusto Recursos (SURF)	Descritor semelhante ao SIFT, mas mais rápido e robusto para mudanças na escala e orientação da imagem	Nível de região	[97,98]

2.3. Outras Modalidades

Embora nosso trabalho se concentre principalmente na análise de sentimento facial e baseada em texto, é realmente importante reconhecer que outras modalidades fisiológicas, como EEG e monitoramento da frequência cardíaca, também foram utilizadas para avaliar os estados cognitivos e emocionais dos alunos [99,100]. Essas modalidades também podem fornecer indicadores diretos e objetivos dos processos emocionais e mentais dos alunos e complementar as informações obtidas a partir de expressões faciais e textos. Portanto, é importante considerar os benefícios potenciais do uso de múltiplas modalidades fisiológicas para análise de sentimentos e detecção de engajamento na educação.

Os métodos baseados em EEG e monitoramento da frequência cardíaca ajudam a medir as emoções e o envolvimento dos alunos porque podem capturar as mudanças na atividade cerebral e na excitação fisiológica associadas a diferentes estados emocionais e níveis de carga cognitiva.

O EEG contém uma gama mais ampla de informações sobre o estado mental de um sujeito em relação a outros bio-sinais [9,101]. Mede vários parâmetros que refletem o envolvimento cognitivo e emocional dos alunos. Da mesma forma, o monitoramento da frequência cardíaca pode medir as variações nos batimentos cardíacos dos alunos que indicam estresse, excitação, tédio ou frustração. Quando combinados com expressões faciais e texto, estes métodos podem oferecer uma boa quantidade de dados, que podem ser influenciados pelo preconceito de autorrelato dos alunos, pela desejabilidade social ou pelas diferenças culturais. Além disso, estes métodos podem oferecer aos professores e aos alunos um feedback mais contínuo e em tempo real, o que pode ajudá-los a ajustar as suas estratégias de ensino e aprendizagem em conformidade. Portanto, métodos baseados em EEG e monitoramento de frequência cardíaca podem beneficiar a análise de sentimentos e a detecção de envolvimento na educação.

Nosso trabalho complementa a literatura existente, fornecendo uma visão abrangente da análise de sentimento na aprendizagem STEM online. Ao nos concentrarmos na análise de sentimentos textuais e faciais, reconhecemos o valor da integração de medidas fisiológicas.

Pesquisas futuras poderiam combinar a análise de sentimentos com dados de EEG para compreender melhor os processos de envolvimento emocional e cognitivo. Ao encorajar a exploração interdisciplinar, estas abordagens prometem insights mais ricos sobre as experiências dos alunos, melhorando os ambientes de aprendizagem online e enriquecendo as discussões sobre como melhorar o envolvimento em STEM.

3. Método

Realizamos uma revisão sistemática da literatura usando a técnica de itens de relatório preferidos para revisões sistemáticas e meta-análises (PRISMA) [102]. PRISMA é uma diretriz amplamente reconhecida e reconhecida para relatórios abrangentes de revisões sistemáticas e meta-análises. Seguindo as diretrizes do PRISMA, a revisão sistemática da literatura consiste em duas etapas principais: (i) a etapa de planejamento, que inclui estratégias de busca e inclusão/exclusão de artigos de pesquisa; e (ii) extração e análise de dados. Estas abordagens proporcionam uma visão holística do panorama da investigação através de diferentes perspectivas e formam relações entre as diversas camadas de questões de investigação multifacetadas apresentadas na Secção 1.

3.1. Estratégia de

busca Foi realizada uma busca utilizando os termos “Sentiment Analysis”, “Text-Based Sentiment Analysis”, “Facial Sentiment Analysis” e “Sentiment Analysis in Online Learning/Education” para recuperar diferentes estudos sobre o uso de análise de sentimento na aprendizagem on-line. Foi realizada uma busca minuciosa, recuperando dados de diversas bases de dados como ACM, ScienceDirect, IEEE Xplore, Medline, Scopus e Google Scholar, resultando em fontes relevantes no tempo de 2015 a 2023. Os operadores lógicos “OR” e “AND” foram usado para identificar duplicatas. A busca foi baseada nos metadados (por exemplo, título, resumo e palavras-chave). Também tentamos alguns sinônimos para cobrir todo o conteúdo possível.

3.2. Critérios de inclusão/exclusão

Os autores examinaram minuciosamente os artigos devolvidos e excluíram pesquisas, artigos curtos sem explicação adequada, artigos não revisados por pares, pré-prints e artigos não escritos em inglês. As palavras-chave listadas acima resultaram em artigos e relatórios técnicos publicados em diversas bases de dados de publicações. As buscas nas bases de dados geraram um total de 236 artigos. Após o escrutínio inicial com base na relevância dos artigos e nas metodologias de ponta utilizadas, 57 artigos foram selecionados e categorizados em três categorias, ou seja, análise de sentimento baseada em frases, análise de sentimento baseada em aspectos na aprendizagem/educação online, e análise de sentimento facial na aprendizagem online. A Figura 4 apresenta os critérios de inclusão/exclusão baseados na técnica PRISMA.

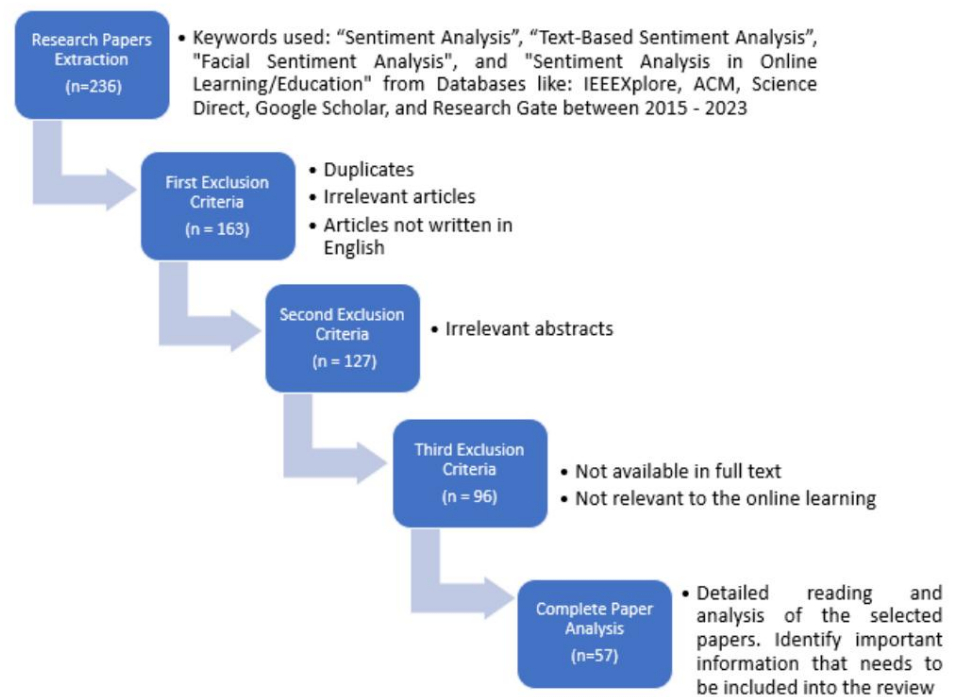


Figura 4. Critérios de seleção de artigos baseados na técnica PRISMA.

4. Resultados e Análise

Esta seção explora, analisa e fornece as respostas às questões de pesquisa do estudo descritas na Seção 1, Tabela 1. As soluções fornecidas são baseadas nos dados disponíveis nos estudos atuais e na análise dos autores de cada um. questão de pesquisa. Os estudos incluídos na investigação utilizaram diversos conjuntos de dados coletados de diversas fontes, como postagens em mídias sociais, fóruns on-line e sistemas de gerenciamento de aprendizagem (LMS). Esses conjuntos de dados abrangem uma variedade de disciplinas educacionais e níveis de escolaridade. No entanto, os estudos ainda não examinaram especificamente a generalização dos algoritmos de análise de sentimento para diferentes domínios acadêmicos e níveis de escolaridade. A maioria das pesquisas concentrou-se no desempenho em uma determinada área temática ou série. A capacidade dos modelos de análise de sentimento manterem a precisão quando aplicados a novas disciplinas e grupos de séries permanece uma questão em aberto que poderia ser explorada em trabalhos futuros. A seção está estruturada em quatro subseções distintas, abordando cada questão de pesquisa. Começamos focando na análise de sentimento baseada em texto, apresentando estudos de análise de sentimento baseados em frases e aspectos , destacando os conjuntos de dados, técnicas empregadas e descobertas resultantes. Além disso, na segunda subseção, são abordados os desafios e limitações encontrados na captação das emoções dos alunos através da análise de sentimentos baseada em texto, e é fornecido um resumo em forma de tabela. Posteriormente, a utilização da FSA no domínio educacional é abordada na terceira subseção, e é fornecida uma visão geral dos estudos relevantes, apresentando a metodologia, classes de emoções extraídas e resultados resultantes.

Finalmente, a quarta subseção discute os desafios e limitações associados à captura das emoções dos alunos utilizando a FSA. Diferentes aspectos, incluindo diferenças culturais nas expressões faciais e dependência da iluminação e qualidade da câmera, também são explorados.

No geral, esta seção fornecerá aos leitores insights dos autores sobre SA e FSA baseados em texto no domínio educacional.

4.1. RQ1: Uso de análise de sentimento baseada em texto no domínio educacional

As técnicas de análise de sentimentos baseadas em texto têm desempenhado um papel significativo nos ambientes de aprendizagem online, fornecendo informações valiosas sobre as emoções e sentimentos dos alunos expressos através do texto. Algoritmos de PNL e aprendizado de máquina são usados nessas técnicas

analisar e categorizar documentos de texto com base em seu sentimento, que pode ser positivo, negativo ou neutro. Para extrair informações de sentimento de materiais de aprendizagem on-line, fóruns de discussão, plataformas de mídia social e feedback dos alunos, foram usadas abordagens como saco de palavras, léxicos de sentimento e modelos de aprendizado de máquina, como NB, SVM e RNN.

Os autores analisaram a literatura atual para classificação de emoções baseada em texto das respostas dos alunos a esta questão de pesquisa. Além disso, identificamos os conjuntos de dados e técnicas utilizadas para análise de sentimento baseada em texto no domínio educacional. Entre 2015 e 2023, foram publicados 37 artigos sobre análise de sentimento de texto. Destes, 25 artigos concentraram-se na análise do sentimento ao nível da frase, enquanto os 12 restantes concentraram-se na análise do sentimento ao nível do aspecto. A Tabela 5 ilustra os estudos sobre análise de sentimento baseada em frases, incluindo os conjuntos de dados utilizados, técnicas empregadas, classes de emoções extraídas e as descobertas resultantes.

A Tabela 6 mostra os estudos de análise de sentimento baseados em aspectos publicados usando ferramentas educacionais conjuntos de dados ao usar diferentes técnicas.

Tabela 5. Estudos de análise de sentimentos baseados em frases no domínio educacional.

S.Nenhum título do artigo		Publicados Ano	Artigo Tipo	Conjunto de dados/tamanho da amostra	Metodologia de Estudo	Aulas de Emoção	Resultados/descobertas
1	Variantes de Longo Curto Prazo Memória para Sentimento Análise sobre vietnamita Feedback dos alunos Corpus [103]	2018	Conf.	16.175 frases do feedback dos alunos	LSTM, Dependência Árvore-LSTM (DT-LSTM), L-SVM, D-SVM e LD-SVM, NB	Positivo, negativo, neutro	LD-SVM: Negativo — 92,52, Neutro — 43,37, Positivo — 93,06, Precisão — 90,20, Pontuação F1 — 90,74
2	Mineração de opinião e reconhecimento de emoções aplicados a ambientes de aprendizagem [104]	2020	Diário -		EvoMSA, Multinomial NB, KNN, BERT, SVC, SVC linear	sentitEXT: (positivo e negativo), eduSERE (engajado, animado, entediado e frustrado)	Precisão: 93% sentiTEXT e 84% eduSERE
3	O que prevê a satisfação dos alunos com os MOOCs: A árvores de aumento de gradiente supervisionadas por aprendizado de máquina e abordagem de análise de sentimento [105]	2020	Diário	249 amostrados aleatoriamente MOOCs e percepções de 6.393 alunos sobre esses MOOCs	Impulsionando o modelo de árvore com TextBlob3	Positivo, negativo, neutro	Pontuação F1: estrutura (0,7780), vídeo (0,8832), instrutor (0,8570), conteúdo e recursos (0,7625), interação e suporte (0,8375), tarefa e avaliação (0,8138)
4	Análise de sentimento em avaliações massivas de cursos online abertos: uma abordagem de mineração de texto e aprendizagem profunda [106] Rede Social e	2020	Diário	66.000 avaliações MOOC	Aprendizado de máquina, métodos de aprendizado em conjunto e métodos de aprendizado profundo com Incorporação Word2Vec	Positivo negativo	Precisão de 95,80 por cento
5	Análise de sentimentos: Investigação de Alunos Perspectivas da Palestra Gravação [107]	2020	Diário	1.435 alunos reagiram a Pergunta do Facebook via emojis, 220 curtidas e 65 comentários foram gerados de 150 alunos únicos 8.281	Google Natural API de linguagem	Positivo, negativo, neutro	Pontuação de sentimento: positivo (39,4 por cento), negativo (33,3 por cento), neutro (27,3 por cento)
6	Investigando a Aprendizagem Experiência de MOOCs Alunos usando o tópico Modelagem e Sentimento Análise [108]	2021	Conf.	avaliações extraídas de cinco cursos na área de ciência de dados são analisadas no Coursera	Modelagem de tópicos (LDA) com VADER para análise de sentimento	Positivo, negativo, neutro	Pontuação de sentimento: positivo, 67,9; negativo, 17,4; neutro, 14,7

Tabela 5. Cont.

S.Nenhum título do artigo		Publicados Ano	Artigo Tipo	Conjunto de dados/tamanho da amostra	Metodologia de Estudo	Aulas de Emoção	Resultados/descobertas
7	Análise de sentimento e Modelagem de tópicos em tweets sobre educação on-line durante a COVID-19 [109]	2021	Diário	Conjunto de dados do Twitter contendo 17.155 tweets sobre e-learning	TextBlob, VADER e SentiWordNet—Para comparação: SVM, LR, DT, RF, SGD, KNN, GNB, CNN, LSTM, CNN-LSTM e Bi-LSTM	Positivo, negativo, neutro	SVM atinge precisão de 0,95 usando TF-IDF com SMOTE
8	Análise de sentimento para Curso de Educação a Distância Materiais: Uma Máquina Abordagem de aprendizagem [110]	2020	Diário	6059 comentários	Aprendizado de máquina técnicas (árvore de decisão, MLP, XGB, SVC, logística multinomial regressão, Gaussiano NB, e k-vizinhos) Extração de recursos: TF-IDF, Word2Vec, N-grama híbrido Classificação: Elman	Positivo, negativo, neutro	Maior precisão: LR (0,775)
9	Curso de e-learning recomendação baseada em análise de sentimento usando Elman híbrido semelhança [111]	2023	Diário	10.000 tweets, textos curtos, e comentários de redes sociais sites	redundância mínima relevância máxima modelo e aprimorado otimização de aquila (EMRMR_EAO) modelo	Positivo, negativo, neutro	Precisão: 99,98 por cento
10	Análise de Variância Emocional: Uma nova análise de sentimento conjunto de recursos para Artificial Inteligência e Máquina Aplicações de aprendizagem [112]	2023	Diário	37 alunos DEEP individuais diários	Variância emocional análise	Positivo, negativo, neutro	Precisão: 88,7 por cento
11	Usuário baseado em aprendizagem profunda avaliação de experiência em ensino à distância [113]	2022	Diário	160.000 tuítes	LSTM com Word2Vec incorporação	Positivo, negativo, neutro	Precisão: 76 por cento
12	AOH-Senti: Orientado a Aspectos Abordagem Híbrida para Análise de sentimento de Feedback dos alunos [114]	2023	Diário -----		SVM, MNB, LR, RFC, DTC e KNN	Positivo, negativo, neutro	98,7 por cento agregado precisão usando o RFC algoritmo

Tabela 5. Cont.

S.Nenhum título do artigo		Publicados Ano	Artigo Tipo	Conjunto de dados/tamanho da amostra	Metodologia de Estudo	Aulas de Emoção	Resultados/descobertas
13	Idioma para conclusão: Sucesso em um ambiente educacional Mineração de dados massivamente aberta Aula on-line [115] Uma análise de aprendizagem	2015	Conf.	320 alunos, 50 palavras em discussão	Ferramentas de PNL (WAT, TAALES, TAAS)	Positivo negativo	Precisão: 67,8 por cento, F1 pontuação: 0,650
14	Metodologia para Detecção Sentimento em fóruns estudantis: A Estudo de caso à distância Educação [116]	2015	Diário	64 alunos, 371 mensagens	Palavra de opinião NioSto algoritmo de extração	Positivo, negativo, neutro	27,27 por cento positivo, 55,56 por cento neutro, e 17,17 por cento negativo
15	Uma decisão aprimorada Sistema de suporte através Mineração de Professores Online Dados de bate-papo [117]	2018	Diário	6650 K12 em serviço acadêmicos na China tinham participaram, em 17.624 postagens distintas	Ingênuo de rótulo único matemático regra de classificação	Positivo, negativo, neutro	Classificado: técnico descrição (961), técnica análise (1638), técnica crítica (2235), pessoal descrição (613), pessoal análise (5875) e pessoal crítica (1166) Precisão, pontuação F1, precisão, e recordar, obtendo pontuações de 91 por cento, 90 por cento, 90 por cento e 89 por cento, respectivamente
16	Baseado em aprendizado de máquina abordagem para sentimento análise sobre ensino a distância de tweets em árabe [118]	2022	Diário	Conjunto de dados do Twitter, 14.000 tuítes	Regressão logística modelo	Positivo, negativo, neutro	
17	Análise do Aluno Feedback usando Deep Aprendizagem [119] Sentimento Baseado em Léxico	2019	Diário	---	CNN, SVM com Word2Vec	Positivo, negativo, neutro ---	
18	Análise dos Professores Avaliação [120] Análise de sentimento de	2016	Diário	Feedback de 1.748 alunos	Knime	Positivo, negativo, neutro	Precisão: 91,2 por cento
19	Feedback do aluno usando Aprendizado de máquina e Baseado em Léxico Abordagens [121]	2017	Conf.	1230 comentários extraídos do nosso instituto portal educacional	TF-IDF, N-gramas com SVM e RF	Positivo, negativo, neutro	Precisão: 0,93, Medição F: 0,92

Tabela 5. Cont.

S.Nenhum título do artigo		Publicados Ano	Artigo Tipo	Conjunto de dados/tamanho da amostra	Metodologia de Estudo	Aulas de Emoção	Resultados/descobertas
20	Melhorar a atratividade internacional das instituições de ensino superior com base na mineração de texto e na análise de sentimento [122]	2018	Diário	1.938 avaliações de 65 escolas de negócios diferentes	PNL	Positivo, negativo, neutro	A satisfação do estudantes em direção ao ES instituições é significativamente variada e depende do tema em discussão nas suas opiniões compartilhadas online
21	Sentimento de feedback do aluno Modelo de análise usando Vários aprendizados de máquina Esquemas: Uma Revisão [123]	2019	Diário	950 postagens	Bayes ingênuo multinomial (MNB), descida gradiente estocástica, SVM, floresta aleatória e perceptron multicamadas (MLP)	Positivo, negativo, neutro	83 por cento, 79 por cento, 80 por cento, 72 por cento e 83 por cento para o classificador MNB, SGD, SVM, floresta aleatória e MLP
22	Mineração de sentimentos em um ambiente de aprendizagem colaborativa: capitalizando big data [124]	2019	Diário	12.300 tuítes, 10.500 Comentários do Facebook e 8450 Feedback do Moodle mensagens	NB e SVM	Positivo, negativo, neutro	As abordagens SM podem ser usadas para compreender o sentimento dos alunos em um ambiente de aprendizagem colaborativa A mídia social SA
23	Aprendizagem em cursos on-line abertos e massivos: evidências das mídias sociais mineração [125]	2015	Diário	402.812 tuítes	Ferramenta de busca de opinião e abordagens de mineração de mídia social	Positivo, negativo, neutro	fornece uma compreensão abrangente das tendências de aprendizagem MOOC 8,5 + (-2,5)
24	Análise de sentimento de Comentário dos alunos usando Baseado em Léxico Abordagem [126]	2017	Conf.	Banco de dados de palavras de sentimento: 745 palavras	Abordagem baseada em léxico	Fortemente positivo, moderadamente positivo, fracamente positivo, fortemente negativo, moderadamente negativo, fracamente negativo ou neutro.	+ 6 = 12 por (5) e dividida pelo número total de palavras de opinião em todos comentários. O resultado é 9/12 = 1,3333
25	Mineração de opinião de estudantes em relação à educação Sistema usando grupo do Facebook [127]	2017	Conf.	Comentários de mestrandos do Facebook Grupo acadêmico: 250 comentários	Modelo probabilístico de rede bayesiana	Positivo, negativo, neutro	Pontuação de sentimento, encontramos 56% de comentários positivos, 32% neutros e 12% negativos

Tabela 6. Estudos de análise de sentimento baseada em aspectos no domínio educacional.

S.Nenhum título do artigo		Publicados Ano	Artigo Tipo	Tamanho da amostra	Estudar Metodologia	Incorporação de palavras	Aspectos Extraídos	Resultados/descobertas
1	Mineração de opinião baseada em aspectos no feedback do aluno para Desempenho de ensino do corpo docente Avaliação [128]	2019	Diário	Conjunto de dados construído a partir dos últimos cinco anos de comentários dos alunos de Universidade Sukkur IBA como bem como em um padrão Conjunto de dados SemEval-2014	Modelo LSTM de duas camadas	Domínio Acadêmico, OpinRank, Glove.6B.100D	Pedagogia de ensino, comportamento, conhecimento, avaliação, experiência, geral	Extração de aspecto (91 por cento) e detecção de polaridade de sentimento (93 por cento)
2	Estrutura fracamente supervisionada para sentimento baseado em aspectos Análise das avaliações dos alunos sobre MOOCs [129]	2020	Diário	105 mil avaliações de alunos coletadas do Coursera e um conjunto de dados contendo feedback de 5.989 alunos	LSTM, CNN	FastText, GloVe, Word2Vec, MOOC	Curso, instrutor, avaliação, tecnologia	Pontuação F1: LSTM fracamente supervisionado (incorporação de domínio: 92,5, GloVe: 93,3), CNN fracamente supervisionada (incorporação de domínio: 90,1, GloVe: 91,5)
3	Sentimento Baseado em Aspectos Análise de Tweets Árabes no Setor de educação usando um Seleção de recursos híbridos Método [130]	2020	Conf.	7.943 tweets em árabe relacionados a Universidade Qassim na Arábia Saudita	SVM	ANOVA unidirecional	Ensino, meio ambiente, serviços eletrônicos, assuntos de pessoal, assuntos acadêmicos, atividades, assuntos estudantis, ensino superior, diversos	Pontuação F: detecção de aspecto 60 por cento (0,76)
4	Fusão Multi-Atenção Modelagem para Sentimento Análise do Big Educacional Dados [131]	2020	Diário	Conjunto de dados educacionais: 5.052; conjunto de dados do curso: 705	TD-LSTM, AE-LSTM, ATAE-LSTM, IAN, BATER	—————	Dificuldade, conteúdo, praticidade e professor	Conjunto de dados educacionais: Multi-AFM: 94,6; conjunto de dados do curso: Multi-AFM: 81,4
5	Mineração de opinião baseada em aspectos de avaliações de alunos on-line Cursos [132]	2020	Conf.	21 mil avaliações de alunos anotadas manualmente, coletadas de Curso	1D-CNN, árvore de decisão, Bayes ingênuo, SVM, impulsionando	FastText, GloVe, Word2Vec, conjunto de dados próprio	Instrutor, estrutura, conteúdo, design, geral	FastText: precisão – 86,78, recall – 89,52, pontuação F1 – 88,13; Word2Vec: precisão – 87,08, recall – 89,34, pontuação F1 – 88,20; GloVe: precisão – 86,75, recall – 88,89, pontuação F1 – 87,81; Conjunto de dados próprio: precisão – 86,70, recall – 89,54, pontuação F1 – 88,10
6	Avaliação de avaliações on-line Sistema de Ensino Superior Instituição: um aspecto baseado Ferramenta de análise de sentimento [133]	2017	Conf.	Dados do Twitter e do Facebook	Apache OpenNLP, Biblioteca de PNL de Stanford	Tags POS (classe gramatical)	As opiniões sobre a instituição abordam muitos aspectos e qualidades intrínsecas e analisam cada um desses aspectos	Precisão de 72,56 por cento
7	Sentimento baseado em aspecto Análise para Melhorar Online Programa de aprendizagem baseado em Feedback do Aluno [134]	2022	Conf.	162 novos graduados de BINUS (Bina Nusantara Universidade) programa online	Biblioteca Stanford NLTK	Polaridade padrão AFINN de palavras em inglês para cada token com marcação POS de substantivo	Punição por trapaça, instalações de aula, administração de faculdade, material de aprendizagem, guia de aprendizagem, benefício do sistema educacional, experiências de aprendizagem felizes	Classificação bem-sucedida de aspectos em classes de sentimentos positivos, negativos e neutros

Tabela 6. Cont.

S.Nenhum título do artigo	Publicados Ano	Artigo Tipo	Tamanho da amostra	Estudar Metodologia	Incorporação de palavras	Aspectos Extraídos	Resultados/descobertas	
8	BERT habilitado para conhecimento para análise de sentimento baseada em aspectos [135]	2021	Diário	Ofertas MOOC em dois Plataformas MOOC de universidades chinesas 9.123 postagens de 7.590 diferentes alunos on-line em diferentes cursos de programação de linguagem avançada	JOELHO, CG-BERT, R-GAT+BERT, BERT+Forro	SKG	—	O modelo BERT + SKG supera todos os métodos de linha de base em precisão e precisão macro-F1 <0,80, macro-F1 0,75
9	Sentimento baseado em aspecto Análise para o Ensino Universitário Análise [136]	2022	Diário	Duas pesquisas diferentes: (i) Pesquisa específica de estudantes sobre a COVID-19 (1805); (ii) avaliações de cursos de estudantes semestrais (9348)	TextBlob, NLTK, pacote spaCy e talento	—	Flexibilidade, ensino, ritmo, misc, tecnologia, motivação, informação	Os resultados revelam que os alunos não gostavam do ensino online devido à informação insuficiente e aos métodos de ensino desajustados. No entanto, os alunos gostaram da flexibilidade e da possibilidade de aprender num ritmo individual. Melhoria de 3 a 5 vezes na pontuação F1 na maioria dos casos em um sistema usando apenas a precisão do
10	Modelos fracamente supervisionados de Aspecto-Sentimento para Online Fóruns de discussão do curso [137]	2015	Conf.	Conjunto de dados MOOC de m diferentes disciplinas (negócios, tecnologia, história e ciências)	Modelo probabilístico conjunto (PSL-Joint)	Palavras-semente e regras lógicas ponderadas	Palestra, quiz, certificado, social	
11	Análise de sentimento baseada em aspectos da opinião dos alunos usando técnicas de aprendizado de máquina [138]	2017	Conf.	2.000 tuítes	Naive Bayes (NB), complementar ingênuo Bayes (CNB) e algoritmo PART Classificador de vetor de suporte linear	—	Ensino, colocação, instalações, taxas, esportes, organização de eventos, transporte	algoritmo LDA PART propagado: POS (1), Neg (1); recordar POS (1), Neg (0,994); Medida F POS (1), Neg (0,997)
12	Gatilhos e Tweets: Implícitos Sentimento Baseado em Aspectos e Análise Emocional de Conversa da comunidade relevante para Educação Pós-COVID-19 [139]	2022	Diário	Dados de bate-papo do Twitter	(SVC), regressão logística, ingênuo multinomial Bayes, floresta aleatória	TF-IDF-BoW	Segurança, qualidade da educação e direito educacional, segurança financeira	ASBA: regressão logística (81 por cento), SA geral: SVC linear (91 por cento)

4.2. RQ2: Desafios/Limitações para Capturar as Emoções dos Alunos Usando Baseado em Texto Análise de sentimentos

Tem havido um interesse crescente em usar a análise de sentimentos para capturar os sentimentos dos alunos. emoções e melhorar a eficácia dos sistemas educativos nos últimos anos. Baseado em texto análise de sentimento, que pode analisar automaticamente enormes volumes de dados de múltiplas fontes, como mídias sociais, fóruns de discussão e registros de bate-papo, é um potencial estratégia para atingir esse objetivo. No entanto, detectar e interpretar com precisão os emoções a partir de dados textuais apresenta desafios e limitações significativas.

Os autores investigaram alguns dos desafios e limitações caracterizados em estudos recentes e forneceu sugestões para possíveis soluções. Uma revisão abrangente da literatura relevante, incluindo artigos recentes sobre análise de sentimento na educação, apoia nossas descobertas. Alguns dos desafios significativos são mostrados na Tabela 7 e brevemente discutido abaixo:

Tabela 7. Desafios da análise de sentimento baseada em texto na captura das emoções dos alunos.

S.Sem desafio(s)	Referências)
1 Classificação dos enunciados textuais dos alunos	[140]
2 Sobreposição de classes de emoções (ambiguidade de classes)	[141–143]
3 Lidando com palavras bipolares	[144]
4 Comentários/respostas falsas	[145.146]
5 Falta de dados confiáveis para treinamento e avaliação	[147]
6 Dificuldade de identificar e interpretar com precisão o sarcasmo e a ironia em dados baseados em chat	[148]
7 Dados não estruturados	[149–151]

4.2.1. Classificação das Enunciações Textuais dos Alunos

As declarações dos alunos são palavras espontâneas como “Uau! esse assunto foi interessante” ao executar uma tarefa ou fornecer feedback sobre um evento específico [140]. Estudante enunciados são considerados uma das formas eficazes de registrar o feedback dos alunos sobre a atividade pedagógica e ajudando a compreender as emoções dos alunos [152]. No entanto, registrar e classificar as declarações dos alunos são tarefas desafiadoras. Esses enunciados são geralmente muito curtos e precisam fornecer mais informações factuais. Para enunciados textuais, dados de bate-papo de uma plataforma de aprendizagem on-line foram usados para detectar emoções usando técnicas de análise de sentimento baseadas em texto para detecção de emoções [153]. Vários estudos usaram chatbots automáticos para registrar e analisar dados de bate-papo dos alunos usando léxico (por exemplo, abordagens baseadas em corpus e dicionário) e técnicas de aprendizado de máquina (baseadas em regras e classificadores lineares) [154.155]. Essas técnicas de análise de sentimento (baseadas em léxico/máquina abordagens de aprendizagem) fornecem resultados substanciais na detecção de emoções. No entanto, eles requerem melhorias adicionais para fornecer uma classificação livre de erros de expressões em emoção classes (isto é, feliz, triste, irritado).

4.2.2. Sobreposição de classes de emoções

O desequilíbrio e a sobreposição de classes são desafios de classificação bem conhecidos em máquinas. aprendizado que despertou os acadêmicos por mais de uma década. O problema de sobreposição de classes geralmente ocorre devido a significados/regiões ambíguos nos dados onde os dados se qualificam para mais de uma classe com base em sua probabilidade razoável [156]. Pequenas alterações entre amostras de duas classes diferentes normalmente são difíceis de capturar usando apenas dados características sugeridas por especialistas do domínio. A aprendizagem desequilibrada recebeu recentemente ampla atenção da comunidade científica, resultando em diversas abordagens dedicadas e algoritmos como técnica de sobreamostragem de minoria sintética (SMOTE) e técnicas de sobreajuste e subajuste [157]. A comunidade de pesquisa anteriormente negligenciou a questão dos dados desequilibrados no contexto da classificação de sentimentos, uma vez que a maioria dos conjuntos de dados analisados foram deliberadamente projetados para ter uma quantidade igual de resultados positivos e negativos comentários [158]. No entanto, onde as boas classificações muitas vezes superam as negativas, o equilíbrio a suposição de dados não se aplica. Os autores em [159] estiveram entre os primeiros a reconhecer

o problema e demonstrar que a utilização de conjuntos de dados realistas e desequilibrados resultou na construção de um classificador com desempenho significativamente melhor na realidade. O SMOTE foi recentemente aplicado a representações de texto sobreamostradas construídas por uma rede de tensores neurais recursivos para utilizar um conjunto de dados desequilibrado para classificação de emoções [160]. A sobreposição de emoções diferentes nas aulas torna difícil classificar as emoções dos alunos com precisão, e frases dos alunos como “Oh, cometi um erro” retratam características de aulas “tristes” e “zangadas”, que se tornam difíceis de serem classificadas pelo algoritmo de aprendizado de máquina.

4.2.3. Lidando com palavras bipolares

A análise de sentimento é o campo de classificação que extrai a polaridade e as classifica em diferentes classes de sentimento (ou seja, feliz, triste, zangado, etc.). Quando duas palavras com polaridades conflitantes são combinadas, elas produzem uma contradição geral que pode exibir comportamentos positivos e negativos, conhecidas como frases bipolares. Considerando a expressão “notas para aprovação”, que geralmente tem polaridade positiva, ela também pode ser negativa em relação ao progresso dos alunos. Salas-Zárate et al. [161] trabalharam no domínio da saúde e usaram N-gramas para encontrar a polaridade dos aspectos usando técnicas de análise de sentimento em nível de aspecto. Eles usaram dados do Twitter usando N-gramas, resultando em 81,93% de precisão na classificação de sentimentos em diferentes classes. Outro estudo usou “SentiWordNet” para lidar com palavras bipolares na análise de sentimento para analisar técnicas estatísticas de computação afetiva como conhecimento [162]. A bipolaridade é um problema comum na análise de sentimentos dos alunos, pois o feedback dos alunos consiste em palavras de duplo sentido. Por exemplo, uma frase de feedback do aluno, “O exame foi bastante fácil, mas tive pouco tempo para tentar todas as questões”, é uma frase bipolar e os algoritmos convencionais de aprendizagem automática para classificar emoções têm um desempenho inferior com tais frases. Outro problema com a classificação dos sentimentos dos alunos são as frases confusas à medida que os alunos expressam os seus sentimentos sobre qualquer evento ou tópico de discussão. Portanto, esperamos uma resposta/resposta não estruturada composta por certas palavras bipolares, como “desafiador”, que devem ser abordadas adequadamente antes da classificação em classes de emoções.

4.2.4. Comentários/Respostas Falsos

Uma das limitações dos sistemas de resposta dos alunos (SRSs) existentes são as respostas falsas dos alunos durante a avaliação do curso/ensino. A maioria dos SRSs são pré-elaborados com questões objetivas como “avaliar a metodologia de ensino do instrutor (1 a 5)” sobre o conteúdo e métodos de ensino e sua satisfação com ambos. Os alunos selecionam a primeira opção disponível para responder a essas perguntas devido à sua falta de interesse e motivação.

As instituições educacionais contam com essas respostas para avaliar um curso ou o desempenho do instrutor. Vários estudos trabalharam na identificação de respostas falsas em termos de notícias falsas e análises de produtos fabricadas. E. Tacchini et al. [163] usaram um conjunto de dados de 15.500 postagens de 909.236 usuários para detectar notícias falsas no Facebook. Eles usaram as técnicas de regressão logística (LR) e algoritmo booleano de crowdsourcing (BLC) para detecção de notícias falsas, resultando em 94,3% e 90% de precisão de detecção, respectivamente. S. Aphiwongsophon [164] discutiu o impacto das notícias falsas na sociedade tecnologicamente avançada de hoje, considerando ao mesmo tempo que a detecção de notícias falsas é uma tarefa crítica. O estudo deles teve como objetivo identificar notícias falsas usando classificadores de aprendizado de máquina usando três métodos diferentes. As notícias falsas detectadas pelo NB apresentaram acurácia de 96,08%. As notícias falsas detectadas pelo NB apresentaram acurácia de 96,08%. Ao mesmo tempo, o SVM e o NN apresentam precisão de 99,90% para detecção de notícias falsas. Todos os estudos acima trabalharam na detecção de notícias falsas; no entanto, detectar respostas falsas dos alunos e, ao mesmo tempo, fornecer feedback exige um trabalho substancial.

4.2.5. Falta de dados confiáveis para treinamento e avaliação

Os pesquisadores apontaram certos desafios que os modelos de análise de sentimento enfrentam em relação aos dados baseados em chat. Um dos desafios críticos identificados é a necessidade de dados rotulados, o que pode impactar significativamente a precisão dos modelos. Dados rotulados

é essencial para treinar modelos de aprendizado de máquina supervisionados para classificar dados de texto em categorias de sentimento com precisão. No entanto, em cenários baseados em chat, a aquisição de dados rotulados pode ser um desafio devido à natureza dinâmica das conversas e à necessidade de anotadores humanos rotularem os dados manualmente. Além disso, a qualidade dos dados rotulados também pode impactar o desempenho dos modelos. Patil e Nandi [147] enfatizaram que os dados rotulados devem ser diversos, representativos da população-alvo e anotados por especialistas para garantir precisão e confiabilidade.

Há uma necessidade crescente de coletar e utilizar dados de elocuições em tempo real dos alunos para enfrentar esses desafios. Os dados em tempo real podem capturar o contexto das conversas, a natureza dinâmica das interações e as mudanças no sentimento ao longo do tempo. Esses dados podem então ser usados para treinar modelos de análise de sentimento que sejam mais precisos e robustos. No entanto, a coleta e análise de dados em tempo real também colocam preocupações éticas e de privacidade significativas, que devem ser abordadas de forma adequada. Concluindo, a escassez e a qualidade dos dados rotulados continuam a ser um desafio significativo para os modelos de análise de sentimento, especialmente em cenários baseados em chat. A coleta de dados de declarações em tempo real dos alunos pode ajudar a superar esses desafios e melhorar a precisão e a eficácia dos modelos de análise de sentimentos em contextos educacionais.

4.2.6. Identificação de sarcasmo e ironia em dados de bate-papo

O bate-papo dos alunos muitas vezes pode incluir sarcasmo e ironia, o que representa desafios significativos para a análise de sentimentos. Conforme observado pelos autores de [148], as discussões online frequentemente empregam termos linguísticos, como siglas/abreviaturas e emoticons, e não considerá-los pode levar a resultados imprecisos de análise de sentimento. A dificuldade é agravada pela ausência de informações contextuais nos dados baseados em chat, tornando difícil identificar quando uma mensagem é sarcástica ou irônica. Esta falta de contexto pode resultar em modelos de análise de sentimento que classificam mal as mensagens e não conseguem captar as emoções e atitudes diferenciadas dos alunos em ambientes educacionais. Portanto, os modelos de análise de sentimentos precisam levar em conta o impacto do sarcasmo e da ironia no bate-papo dos alunos para melhorar a precisão da análise de sentimentos em contextos educacionais. Vários estudos exploraram o impacto do sarcasmo e da ironia na análise de sentimento e consideraram-no um dos principais desafios na análise de sentimento baseada em texto, como em [165].

4.2.7. Dados não estruturados

As plataformas de aprendizagem on-line criam enormes quantidades de dados não estruturados, como redações de alunos, postagens em fóruns e comentários em mídias sociais. A incorporação destas fontes de dados em modelos de análise de sentimento tem o potencial de fornecer uma compreensão mais abrangente das emoções dos alunos. No entanto, como apontaram os autores em [149], esta abordagem enfrenta vários obstáculos, incluindo limpeza e integração de dados. A natureza não estruturada dos dados também pode dificultar a distinção adequada de emoções e atitudes.

Outros estudos apontaram as desvantagens do uso de dados não estruturados para análise de sentimento. Por exemplo, os autores em [150] afirmaram que a variedade de uso da linguagem e a complexidade do contexto podem levar a modelos de análise de sentimento que fornecem resultados imprecisos ou não confiáveis. Além disso, os autores de [151] afirmaram que a natureza subjetiva da análise de sentimento torna desafiador estabelecer um critério para avaliar a precisão do modelo.

Apesar destes desafios, a análise de sentimento de dados não estruturados em contextos educacionais continua a ser uma área de investigação promissora.

4.3. RQ3: Uso da Análise de Sentimento Facial no Domínio Educacional

As técnicas de FSA surgiram como uma ferramenta benéfica em ambientes de aprendizagem online, permitindo analisar as emoções e sentimentos dos alunos com base nas expressões faciais. Usando visão computacional e algoritmos de aprendizado de máquina, essas técnicas identificam e analisam sinais faciais, como mudanças nos movimentos musculares faciais, para inferir estados emocionais, como felicidade, tristeza, confusão ou envolvimento. Para analisar gravações de vídeo ou interações de vídeo em tempo real em plataformas de aprendizagem on-line, métodos como reconhecimento facial

detecção de marcas, reconhecimento de emoções faciais e modelos de aprendizagem profunda foram usados. Usando a FSA, educadores e pesquisadores podem reunir insights sobre as respostas emocionais, o nível de envolvimento e a compreensão dos alunos. Esses dados podem ser utilizados para melhorar táticas de ensino, fornecer assistência personalizada e criar ambientes de aprendizagem online mais inclusivos e eficazes. À medida que a tecnologia avança, os algoritmos FSA evoluem, abrindo novos caminhos para melhorar os ambientes de aprendizagem online e os resultados dos alunos.

Os autores revisaram exaustivamente a literatura existente sobre a classificação das emoções faciais dos alunos nesta questão de pesquisa. Vários estudos de pesquisa foram realizados para investigar a FSA em ambientes educacionais. Nossas descobertas revelaram que nove artigos foram publicados entre 2015 e 2023, com foco na análise de sentimentos de expressões faciais.

A Tabela 8 fornece uma visão geral desses estudos, apresentando as técnicas utilizadas, as classes de emoções extraídas e os resultados resultantes.

Tabela 8. Estudos de análise de sentimento facial no domínio educacional.

S.Nenhum título do artigo		Publicados Ano	Artigo Tipo	Conjunto de dados/tamanho da amostra	Metodologia de Estudo	Aulas de Emoção	Resultados/descobertas
1	Modelagem adaptativa Ambiente de e-learning usando expressões faciais e lógica difusa [166]	2020	Diário	Corpora de 12 alunos contém 72 atividades de aprendizagem e 1.735 pontos de dados de estados emocionais distintos	CNN	Raiva, nojo, medo, felicidade, tristeza, surpresa, neutro	A abordagem proposta fornece fluxos de aprendizagem adaptativos que correspondem às capacidades de aprendizagem de todos os alunos de um grupo
2	Uso de emoção facial reconhecimento em sistemas de e-learning [167]	2017	Diário	Imagens frontais dos participantes gravadas via Skype, tamanho 11.680 × 10	kNN, floresta aleatória, CARRINHO, SVM	Felicidade, medo, tristeza, raiva, surpresa e nojo	Maior precisão: SVM 98,24
3	Um sistema de e-learning com Emoção Multifacial Reconhecimento Usando Máquina supervisionada Aprendizagem [168]	2015	Conferência	Yale Face Database (YFD) para treinamento e detecção de rosto Conjunto de dados e benchmark (FDDB) e Labeled Faces in the Wild (LFW) para avaliação	SVM	7 emoções principais	
4	Extração de humor usando Características faciais para melhorar Curvas de aprendizagem de alunos em sistemas de e-learning [169] Identificação não intrusiva da atenção do aluno e	2016	Diário	Cohn – Kanade com codificação AU banco de dados de expressões faciais consiste em 486 sequências de 97 rostos	Função de base radial NN algoritmo, SVM	Feliz, triste, confuso, perturbado, surpreso	O algoritmo proposto mostrou uma taxa de sucesso de mais de 70% em avaliando o humor do aluno
5	Encontrando sua correlação com o facial detectável Emoções [170]	2020	Conferência	O conjunto de dados das imagens brutas consistia em 3.500 imagens	CNN	Atenção, calma, confusa, enojada, medo, feliz, triste, surpresa	93% de precisão
6	Reconhecimento de expressão facial com Convolutional Neural Redes: Lidando com poucos dados e a ordem da amostra de treinamento [171]	2017	Diário	Cohn – Kanade estendido (CK p), facial feminino japonês Expressões (JAFPE) e Universidade de Binghamton Modelo 3D Banco de dados de Expressão Facial (BU-3DFE)	CNN	Raiva, nojo, medo, felicidade, tristeza e surpresa	96,76% de precisão no banco de dados CKp
7	Em direção ao automatizado Observação de sala de aula: Prevendo Positivo e Clima Negativo [172]	2019	Vídeos rotulados por classe da Conferência 241 CNN e Bi-LSTM			Clima positivo e clima negativo	Precisão: 0,40 e 0,51, respectivamente

Tabela 8. Cont.

S.Nenhum título do artigo	Publicados Ano	Artigo Tipo	Conjunto de dados/tamanho da amostra	Metodologia de Estudo	Aulas de Emoção	Resultados/descobertas
8 Proposta Modelo sobre o Determinação do Aluno Atendimento a Distância Educação com rosto Reconhecimento Tecnologia [173]	2021	Diário	Gestos faciais capturados pela câmera LMS	Algoritmo de reconhecimento Eigenfaces com filtros gaussianos	Mais de 80% de precisão alcançada	
9 Um novo aprendizado profundo Modelo para reconhecimento e registro facial à distância Aprendizagem [174]	2022	Diário	Os conjuntos de dados Faces94, Faces95, Faces96 e Grimace contêm 7.873 imagens	CNN	Eigenfaces emoções	Precisão de 100% para os conjuntos de dados Faces94 e Grimace e atinge 99,86% para Faces95. Modelo Faces96 atinge precisão de 99,54% Precisão
10 Detecção automática dos estados afetivos dos alunos no ambiente de sala de aula usando redes neurais convolucionais híbridas [175]	2019	Diário	8.000 faces únicas em um único quadro de imagem e 12.000 faces múltiplas em um único quadro de imagem	CNN híbrida	Envolvido, tédio e neutro	de 86% e 70% para estados afetivos colocados e espontâneos de sala de aula dados, respectivamente.

4.4. RQ4: Desafios/Limitações para Capturar as Emoções dos Alunos Usando Análise de Sentimento Facial

A utilização da FSA emergiu como um método altamente promissor para capturar as emoções dos alunos. Esta abordagem, no entanto, tem vários desafios importantes. Um O maior desafio é o reconhecimento e a interpretação precisos das expressões faciais, bem como as emoções podem ser sutis e dependentes do contexto [176]. Além disso, variações na cultura normas e diferenças individuais nas expressões faciais representam desafios para a emoção universal reconhecimento [177]. Além disso, a presença de fatores de confusão como oclusões, variações nas condições de iluminação e a complexidade das expressões faciais dinâmicas podem impactar significativamente a precisão dos modelos FSA [178].

Através de uma análise sistemática da literatura, vários desafios foram identificados na capturar as emoções dos alunos. Esses desafios abrangem vários aspectos do processo e destacar as complexidades de capturar e interpretar com precisão as emoções dos alunos estados. Em primeiro lugar, examinamos as limitações na identificação precisa de emoções através de expressões faciais. análise. Em seguida, investigamos o desafio colocado pelas diferenças culturais na interpretação das emoções. O ponto subsequente destaca a eficácia limitada da FSA na detecção de emoções. Além disso, abordamos a influência de fatores como condições de iluminação e qualidade da câmera na qualidade da análise. Por último, exploramos os desafios como com análise de emoções em tempo real, principalmente devido a limitações computacionais e de processamento. Estes desafios estão resumidos na Tabela 9 e discutidos nos parágrafos subsequentes.

Tabela 9. Desafios da análise de sentimento facial na captura das emoções dos alunos.

S.Sem desafio(s)	Referências)
1	Precisão limitada na identificação de emoções [179-181]
2	Diferenças culturais nas expressões faciais [182-185]
3	Eficácia limitada na identificação de emoções sutis [186-189]
4	Dependência da iluminação e qualidade da câmera [190–193]
5	Falta de análise em tempo real [194.195]

4.4.1. Precisão limitada na identificação de emoções

Devido à complexidade e subjetividade das emoções, os modelos de análise de sentimentos baseados em gestos faciais enfrentam desafios significativos no reconhecimento preciso das emoções. As emoções são multifacetadas e podem ser influenciadas por diversos fatores externos e internos, desafiando a sua interpretação através das expressões faciais. Expressões faciais fazem nem sempre refletem adequadamente os verdadeiros sentimentos de um indivíduo [179]. Os estudantes, por exemplo, podem apresentar expressões faciais que podem não corresponder aos seus reais estados emocionais ou exibir emoções que diferem das expressões faciais esperadas geralmente associadas a essas emoções.

Outras pesquisas revelaram novos desafios na análise de sentimento baseada em gestos faciais. Pesquisadores [180] investigaram as deficiências dos algoritmos de detecção de expressões faciais em reconhecer nuances emocionais sutis. Eles descobriram que esses algoritmos poderiam luta para detectar mudanças sutis nas expressões faciais, potencialmente levando a erros de reconhecimento de emoções. Em um estudo realizado por Kaminska et al. (2021) [181], os autores avaliaram o impacto das variações culturais no reconhecimento de emoções faciais. Suas descobertas revelaram que variações na expressão facial entre culturas podem reduzir a eficácia da emoção modelos de identificação quando aplicados em diferentes contextos culturais.

4.4.2. Diferenças Culturais nas Expressões Faciais

Modelos de análise de sentimentos baseados em gestos faciais enfrentam desafios na contabilização de diferenças culturais nas expressões faciais, levando a uma análise imprecisa das emoções dos alunos. As diferenças culturais nas expressões faciais foram identificadas como um aspecto crítico que influencia a percepção de emoções e reconhecimento. Indivíduos de diversas origens culturais podem expressar emoções por meio de diferentes expressões faciais, levando em consideração o contexto cultural na análise de sentimento essencial. Por exemplo, em algumas culturas, balançar a cabeça da esquerda para a direita é frequentemente empregado para mostrar concordância ou afirmação, semelhante a dizer “sim”. Enquanto estiver em

Nas sociedades ocidentais, balançar a cabeça da esquerda para a direita geralmente indica desacordo ou negação, equivalente a dizer “não”.

Li Y. et al. [182] avaliaram o impacto da cultura no reconhecimento de expressões faciais e descobriram diferenças substanciais entre culturas. As suas descobertas enfatizaram a importância de combinar conhecimento cultural e contexto ao desenvolver sistemas de identificação de emoções precisos e culturalmente sensíveis. Em outro estudo, os autores exploraram a função da formação cultural na percepção das emoções. Eles enfatizaram a importância de considerar as diferenças culturais para melhorar a confiabilidade e a validade dos modelos de análise emocional [183].

Além disso, Zhang et al. [184] exploraram a detecção de emoções faciais interculturais e descobriram que fatores culturais influenciam consideravelmente a percepção das emoções faciais. As suas descobertas destacaram a importância de adaptar os modelos FSA a vários contextos culturais para produzir resultados de reconhecimento de emoções mais precisos e confiáveis.

Além das diferenças culturais, outros estudos identificaram desafios relacionados à natureza dinâmica das expressões faciais. Wang et al. [185] destacaram as limitações da análise facial estática e enfatizaram a importância de considerar a dinâmica temporal em modelos de reconhecimento de emoções. Eles propuseram incorporar informações temporais para capturar a natureza evolutiva das expressões faciais e melhorar a precisão da análise de sentimentos.

No geral, estes estudos destacam os desafios que os modelos FSA enfrentam na contabilização das diferenças culturais nas expressões faciais e na análise eficaz das emoções dos alunos.

4.4.3. Eficácia limitada na identificação de emoções sutis

Os algoritmos de análise de sentimentos baseados em gestos faciais encontram dificuldades no reconhecimento de emoções sutis, particularmente aquelas familiares à aprendizagem on-line, como tédio ou confusão. Essas emoções são frequentemente transmitidas por meio de expressões faciais sutis que podem ser um desafio para sistemas automatizados identificarem e analisarem. Os métodos tradicionais de reconhecimento de expressões faciais lutam para capturar e analisar efetivamente essas emoções sutis [186]. Os estudos realizados entre 2015 e 2023 revelaram novos desafios na detecção de emoções subtis através da análise de sentimentos baseada em gestos faciais. Por exemplo, Wang Y. et al. [187] investigaram as limitações dos algoritmos de reconhecimento de expressões faciais na coleta de microexpressões, como estreitamento dos olhos ou leve enrugamento do nariz que mostra raiva ou frustração, que são expressões faciais breves e temporárias que refletem emoções ocultas. Suas descobertas destacaram a necessidade de técnicas mais sofisticadas para detectar e analisar esses sinais emocionais sutis.

Além disso, outro estudo concentrou-se nas dificuldades em reconhecer emoções como confusão e frustração no contexto educacional [188]. Os autores descobriram que estas emoções são frequentemente acompanhadas por ligeiras alterações nas expressões faciais, tornando -as difíceis de identificar apenas a partir de pistas visuais. As descobertas enfatizam a necessidade de técnicas multimodais que integram expressões faciais junto com outras modalidades, como voz, texto ou dados fisiológicos, para melhorar a precisão do reconhecimento de emoções.

Além disso, outro estudo investigou o efeito das oclusões faciais, como máscaras faciais ou obstruções parciais, no reconhecimento de emoções [189]. Eles descobriram que as oclusões podem impactar consideravelmente o desempenho dos modelos FSA, especialmente quando os rostos dos alunos não estão completamente visíveis. Superar esses obstáculos requer o desenvolvimento de sistemas robustos capazes de lidar com oclusões e, ao mesmo tempo, capturar e interpretar expressões faciais de maneira eficaz.

Em conclusão, os algoritmos de análise de sentimentos baseados em gestos faciais encontram dificuldades em reconhecer de forma confiável emoções sutis, especialmente aquelas observadas em contextos de aprendizagem online.

A complexidade associada à análise eficaz dessas emoções é ainda mais complicada pelas limitações na captura de microexpressões, no reconhecimento de mudanças sutis nas expressões faciais e na contabilização de oclusões faciais. Para resolver estas questões, devem ser investigadas metodologias multimodais e formas mais sofisticadas de recolher e analisar sinais emocionais subtis.

4.4.4. Dependência da iluminação e da qualidade da câmera

A precisão dos modelos de análise de sentimentos baseados em gestos faciais pode ser afetada por fatores como a qualidade da iluminação e a câmera usada para coletar emoções faciais. De acordo com um estudo, iluminação inadequada ou câmeras de baixa qualidade podem impactar substancialmente a análise de expressões faciais e emoções, resultando em resultados incorretos [190].

Outras pesquisas examinaram o efeito da iluminação e da qualidade da câmera na análise de sentimento baseada em gestos faciais. Por exemplo, um estudo avaliou os impactos de diferentes condições de iluminação no reconhecimento de expressões faciais [191]. Os autores descobriram que as variações de iluminação podem afetar a visibilidade e a intensidade das características faciais, afetando a precisão da detecção de emoções.

Além disso, um estudo investigou o impacto da qualidade da câmera na análise da expressão facial [192]. O estudo descobriu que imagens de baixa resolução ou com ruído de câmeras de baixa qualidade podem afetar o reconhecimento preciso das emoções. Eles enfatizaram a necessidade de câmeras de alta qualidade para capturar expressões faciais e produzir imagens consistentes e resultados precisos.

Outro estudo avaliou o efeito das mudanças no posicionamento da cabeça na detecção de emoções faciais, iluminação e qualidade da câmera. Eles descobriram que posições anormais da cabeça poderiam dificultar a captura de expressões faciais, resultando em menor desempenho do modelo de análise de sentimento [193].

Esses estudos destacam a importância de considerar a iluminação, a qualidade da câmera e as variações do cartão ao projetar e implantar modelos de análise de sentimento baseados em gestos faciais.

4.4.5. Falta de análise em tempo real

Os modelos de análise de sentimento baseados em gestos faciais podem enfrentar desafios no fornecimento de análise em tempo real das emoções e sentimentos dos alunos devido ao tempo necessário para processamento e análise de imagens. Os desafios computacionais de análise de expressões faciais podem causar atraso na aquisição de resultados, restringindo a capacidade desses modelos de fornecer feedback em tempo real a alunos e instrutores em ambientes de aprendizagem online. Uma extensa pesquisa realizada explorou a questão da análise em tempo real na análise de sentimento baseada em gestos faciais. Deshmukh et al. [194] avaliaram o desempenho em tempo real de algoritmos de reconhecimento de expressões faciais. Eles descobriram que as demandas computacionais poderiam retardar a análise em tempo real, especialmente quando se lida com conjuntos de dados massivos ou algoritmos complicados. Além disso, outro estudo investigou o reconhecimento de emoções em tempo real usando abordagens de aprendizagem profunda [195]. Devido aos enormes requisitos de processamento dos modelos de aprendizagem profunda, a sua investigação enfatizou as dificuldades. Esses estudos destacam as dificuldades que os algoritmos de análise de sentimentos baseados em gestos enfrentam ao fornecer análises em tempo real das emoções dos alunos. Embora os avanços em hardware e algoritmos continuem a melhorar a velocidade de análise, a complexidade computacional continua a ser uma barreira crucial para fornecer feedback rápido em ambientes de aprendizagem online.

Considerando os desafios de análise de sentimento facial e baseado em texto discutidos acima, combinar expressões faciais, voz, palavras escritas e sinais fisiológicos, incluindo sinais de EEG, poderia nos ajudar a compreender melhor as emoções de um indivíduo. Essas várias perspectivas sobre as emoções podem ser combinadas para detectar sentimentos sutis, como irritação, tédio ou falta de interesse. A combinação de diferentes modalidades pode ser um desafio; no entanto, combinar múltiplos métodos para analisar emoções correlaciona-se eficazmente com a complexidade das emoções humanas. Criar uma tecnologia melhor que compreenda as emoções poderia ajudar a tornar os recursos educacionais mais compreensíveis e benéficos. Eles poderiam fornecer ajuda personalizada, adaptada às necessidades emocionais e cognitivas de cada indivíduo.

5. Conclusões e direções futuras

Esta revisão sistemática da literatura e meta-análise baseada em PRISMA forneceu informações valiosas sobre a aplicação da análise de sentimentos baseada em texto e da FSA na educação, especificamente em disciplinas STEM, para ajudar alunos e educadores. Nossa revisão abordou quatro principais

questões de pesquisa sobre a aplicação e os desafios da análise de sentimento na aprendizagem online, revisando artigos relevantes para o tempo publicados entre 2015 e 2023.

Em relação ao RQ1, a revisão revelou que a análise de sentimento baseada em texto tem sido frequentemente utilizada na educação para melhorar as experiências de aprendizagem dos alunos. Vários estudos de pesquisa mostraram que a análise de sentimento pode ajudar no envolvimento dos alunos, na geração de feedback e na aprendizagem personalizada. A análise de dados textuais permitiu aos instrutores compreender melhor as emoções, percepções e requisitos de aprendizagem dos seus alunos, permitindo intervenções e assistência mais direcionadas.

Em relação ao RQ2, a revisão identificou vários problemas e limitações relacionados com a análise de sentimento baseada em texto no contexto da aprendizagem online. Foram identificados desafios significativos, incluindo a falta de dados rotulados, o impacto do sarcasmo e da ironia no texto e a necessidade de análise em tempo real das declarações dos alunos. Estas dificuldades exigem mais investigação e o desenvolvimento de novas técnicas para melhorar a precisão e a eficácia da análise de sentimentos baseada em texto em ambientes de aprendizagem online.

Passando para o RQ3, a revisão esclareceu a crescente popularidade da FSA na educação e na aprendizagem online. Estudos demonstraram que a análise de expressões faciais pode nos ajudar a compreender as emoções, os níveis de envolvimento e os processos cognitivos dos alunos.

A FSA fornece informações valiosas para sistemas de aprendizagem adaptativos, modelagem de alunos e computação afetiva, resultando em experiências educacionais mais personalizadas e bem-sucedidas.

Finalmente, o RQ4 investigou os desafios e limitações da FSA na aprendizagem online.

As preocupações levantadas na revisão destacaram a identificação e interpretação precisas das expressões faciais, o impacto das variações culturais, a detecção de emoções sutis e a influência da iluminação e da qualidade da câmera. Esses desafios destacam a importância de algoritmos robustos, conjuntos de dados padronizados e considerações sobre diversidade cultural ao implementar a análise de sentimentos por gestos faciais.

No geral, esta revisão sistemática da literatura fornece uma compreensão aprofundada das aplicações, desafios e limitações baseadas em texto e FSA no domínio educacional.

As conclusões demonstram o potencial das abordagens de análise de sentimentos para melhorar as experiências de aprendizagem e identificar áreas que requerem mais estudo e desenvolvimento para abordar as limitações identificadas. Ao abordar estas questões, a análise de sentimentos pode continuar a desempenhar um papel vital na melhoria dos ambientes de aprendizagem online e no aumento do envolvimento, satisfação e desempenho acadêmico dos alunos.

Apesar dos insights apresentados por esta revisão, certas lacunas importantes de pesquisa relativas à análise de sentimentos em ambientes educacionais on-line precisam ser abordadas.

Atualmente, nenhum estudo está explorando a análise de sentimentos em tempo real de dados de bate-papo para fornecer intervenções aos alunos. A maioria dos modelos de análise de sentimento baseia-se na análise post hoc de dados textuais, mas a análise em tempo real do chat poderia permitir a adaptação dinâmica da instrução e do apoio. A integração da expressão facial ou do reconhecimento de gestos em tempo real com a análise de sentimentos do chat pode enriquecer ainda mais a compreensão dos estados do aluno. No entanto, o desenvolvimento de modelos precisos em tempo real que respondam adequadamente continua a ser um desafio em aberto. Mais pesquisas são necessárias para criar conjuntos de dados anotados maiores que abranjam vários contextos educacionais e possam ser usados para treinar modelos de análise de sentimento mais robustos. Também são necessárias mais pesquisas sobre análise de sentimento multimodal, que combina informações textuais, visuais e auditivas para obter maior precisão.

Além disso, mais pesquisas precisam ser realizadas para investigar técnicas avançadas de redes neurais, como transformadores, e como elas podem melhorar a precisão da classificação de sentimentos para dados textuais informais. A investigação também deve explorar as nuances culturais de mostrar e interpretar sentimentos para aumentar as competências de compreensão contextual das tecnologias de análise de sentimentos. Esses estudos podem fornecer mais evidências sobre como essas ferramentas impactam resultados importantes, como a motivação, o envolvimento e o desempenho acadêmico dos alunos. Em última análise, colmatar estas lacunas de investigação através de esforços interdisciplinares será vital para desbloquear todo o potencial da análise de sentimentos para proporcionar uma aprendizagem personalizada e emocionalmente consciente em grande escala.

Contribuição dos Autores: Concepção e desenho do estudo: AA, IUR, MMN, SBAK e NK; dados arrecadação: AA, IUR e SBAK; análise e interpretação dos resultados: AA, IUR, MMN e SBAK; preparação do rascunho do manuscrito: AA, IUR, MMN, SBAK e NK Todos os autores revisados os resultados e aprovou a versão final do manuscrito. Todos os autores leram e concordaram com os versão publicada do manuscrito.

Financiamento: Este manuscrito é financiado pela doação do UK-Saudi Challenge Fund do programa Going Global Partnerships do British Council. O título do projeto é “IntelliStudent—A Cutting-edge Plataforma de aprendizagem auxiliada por computador para aprimorar pedagogias de ensino e aprendizagem on-line: uma Projeto de Parceria Reino Unido-Saudita”.

Declaração do Conselho de Revisão Institucional: Não aplicável.

Termo de Consentimento Livre e Esclarecido: Não aplicável.

Declaração de disponibilidade de dados: Não há dados privados ou ocultos dos leitores. Todos os materiais e os dados são relatados no manuscrito e podem ser facilmente acessados através das referências fornecidas na seção bibliografia.

Agradecimentos: Este artigo faz parte do “IntelliStudent — Uma plataforma de aprendizagem auxiliada por computador de ponta para aumentar as pedagogias de ensino e aprendizagem on-line: uma parceria entre o Reino Unido e a Arábia Saudita”. Project”, que é financiado e apoiado por uma doação do UK-Saudi Challenge Fund do Reino Unido Programa Going Global Partnerships do Conselho. O programa constrói comunidades mais fortes, mais inclusivas, sistemas de ensino superior e TVET conectados internacionalmente. Os autores também gostariam de reconhecer a Escola de Computação e Engenharia da Universidade de West London (UWL), e Laboratório de Engenharia de Sistemas Inteligentes, Prince Sultan University (PSU), por seu valioso apoio.

Conflitos de interesse: Os autores declaram não ter nenhum conflito de interesse a relatar em relação o presente estudo.

Abreviações

As seguintes abreviações são usadas neste manuscrito:

PRISMA Itens de relatório preferidos para revisões sistemáticas e meta-análises

STEM Ciência, tecnologia, engenharia e matemática

Curso on-line aberto massivo MOOC

FSA Análise de sentimento facial

RV Realidade virtual

RA Realidade aumentada

Eletroencefalograma

SA Análise de sentimentos

RQ Questão de pesquisa

PNL Processamento de linguagem natural

TEA Transtorno do espectro do autismo

Baías ingênuas

SVM Máquina de vetores de suporte

CNNs Redes neurais convolucionais

RNNs Redes neurais recorrentes

Dicionário VADER Valence para raciocínio de sentimento

LDA Alocação latente de Dirichlet

BERTO Representações de codificadores bidirecionais de transformadores

Referências

1. Fatores, F. Mercado de e-Learning deve atingir US\$ 848,12 bilhões com um CAGR de 17,54% até 2030 — Relatório de Fatos e Fatores (FnF). Disponível online: <https://www.globenewswire.com/news-release/2023/02/02/2600283/0/en/E-Learning-Market-is-Projected-to-Hit-USD-848-12-Billion-at-a-CAGR-of-17-54-by-2030-Report-by-Facts-Factors-FnF.html> (acessado em 27 de maio de 2023).
2. Acharya, S.; Reza, M. Rastreamento de envolvimento emocional em tempo real de alunos usando intensidades emocionais biométricas humanas. Na máquina Aprendizagem para Biometria; Elsevier: Amsterdã, Holanda, 2022; páginas 143–153.
3. Castiblanco Jiménez, IA; Gómez Acevedo, JS; Marcolin, F.; Vezzetti, E.; Moos, S. Rumo a uma estrutura integrada para medir envolvimento do usuário com produtos interativos ou físicos. Internacional J. Interagir. Des. Fabrico. (IJIDeM) 2023, 17, 45–67. [RefCruz]

4. Slavich, GM; Zimbardo, PG Ensino transformacional: fundamentos teóricos, princípios básicos e métodos básicos. Educ. Psicol. 2012 , 24, 569–608. [\[RefCruz\]](#) [\[Pub Med\]](#)
5. Sobnath, D.; Kaduk, T.; Rehman, UI; Isiaq, O. Seleção de recursos para o envolvimento de estudantes com deficiência no Reino Unido após o ensino superior: uma abordagem de aprendizado de máquina para um modelo de emprego preditivo. Acesso IEEE **2020**, 8, 159530–159541. [\[RefCruz\]](#)
6. Haq, UI; Anwar, A.; Rehman, UI; Asif, W.; Sobnath, D.; Sherazi, HHR; Nasralla, MM Formação dinâmica de grupos com aprendizagem colaborativa de tutor inteligente: Uma nova abordagem para a colaboração da próxima geração. Acesso IEEE **2021**, 9, 143406–143422. [\[RefCruz\]](#)
7. Gordo, CM; LaRosa, J. Usando Kahoot! na sala de aula para criar envolvimento e aprendizagem ativa: uma tecnologia baseada em jogos solução para iniciantes em eLearning. Gerenciar. Ensinar. 2017 , 2, 151–158. [\[RefCruz\]](#)
8. Marechal, C.; Mikolajewski, D.; Tyburek, K.; Prokopowicz, P.; Bougueroua, L.; Ancourt, C.; Wegrzyn-Wolska, K. Pesquisa sobre métodos multimodais baseados em IA para detecção de emoções. Alto desempenho. Modelo. Simul. Aplicativo de Big Data **2019**, 11400, 307–324.
9. Fraiwan, M.; Alafeef, M.; Almomani, F. Medindo o interesse visual humano usando análise de entropia multiescala de sinais EEG. J. Ambiente. Intel. Humanizar. Computação. **2021**, 12, 2435–2447. [\[RefCruz\]](#)
10. Ferri, F.; Grifoni, P.; Guzzo, T. Aprendizagem online e ensino remoto emergencial: oportunidades e desafios em emergências situações. Sociedades **2020**, 10, 86. [\[CrossRef\]](#)
11. Feidakis, M.; Daradoumis, T.; Cabalã, S.; Conesa, J. Incorporando consciência emocional em ambientes de e-learning. Internacional J. Emerg. Tecnologia. Aprender. (IJET) **2014**, 9, 39–46. [\[RefCruz\]](#)
12. Maxey, K.; Norman, D. Aprendizagem combinada no Tennessee: como as percepções dos professores do ensino médio impactam os níveis de implementação, o envolvimento dos alunos e o desempenho dos alunos. Ph.D. Tese, Lipscomb University, Nashville, TN, EUA, 2019.
13. Nazir, A.; Rao, Y.; Wu, L.; Sun, L. Questões e desafios da análise de sentimento baseada em aspectos: uma pesquisa abrangente. IEEE Trans. Afeto. Computação. **2020**, 13, 845–863. [\[RefCruz\]](#)
14. Filatova, E. Ironia e Sarcasmo: Geração e Análise de Corpus Usando Crowdsourcing. Nos Anais da Oitava Internacional Conferência sobre Recursos Linguísticos e Avaliação (LREC'12), Istambul, Turquia, maio de 2012; págs.
15. Fei, Z.; Yang, E.; Li, DDU; Mordomo, S.; Ijomah, W.; Li, X.; Zhou, H. Análise de emoções baseada em rede de convolução profunda para cuidados de saúde mental. Neurocomputação **2020**, 388, 212–227. [\[RefCruz\]](#)
16. Oghu, E.; Ogbuju, E.; Abiodun, T.; Oladipo, F. Uma revisão das abordagens de análise de sentimento para garantia de qualidade no ensino e aprendizagem. Touro. Soc. Informar. Teoria Apl. **2022**, 6, 177–188.
17. Dolianiti, FS; Iakovakis, D.; Dias, SB; Hadjileontiadou, S.; Diniz, JA; Hadjileontiadis, L. Técnicas de análise de sentimento e aplicações na educação: Uma pesquisa. Em Anais da Conferência Internacional sobre Tecnologia e Inovação na Aprendizagem, Ensino e Educação, Salônica, Grécia, 20–22 de junho de 2018; págs.
18. Zhou, J.; Sim, JM Análise de sentimento na pesquisa em educação: uma revisão de publicações em periódicos. Interagir. Aprender. Meio Ambiente. **2023**, 31, 1252–1264. [\[RefCruz\]](#)
19. Kastrati, Z.; Dalipi, F.; Imran, AS; Pireva Nuci, K.; Wani, MA Análise de sentimento do feedback dos alunos com PNL e profunda aprendizagem: Um estudo de mapeamento sistemático. Apl. Ciência. **2021**, 11, 3986. [\[CrossRef\]](#)
20. Wankhade, M.; Rao, ACS; Kulkarni, C. Uma pesquisa sobre métodos, aplicações e desafios de análise de sentimento. Artefato. Intel. Rev. **2022**, 55, 5731–5780. [\[RefCruz\]](#)
21. Babu, NV; Kanaga, EGM Análise de sentimento em dados de mídia social para detecção de depressão usando inteligência artificial: uma revisão. Computação SN. Ciência. **2022**, 3, 1–20. [\[RefCruz\]](#)
22. Gaikar, DD; Marakarkandy, B.; Dasgupta, C. Usando dados do Twitter para prever o desempenho de filmes de Bollywood. Ind. Gerente. Sistema de dados **2015**, 115, 1604–1621. [\[RefCruz\]](#)
23. Rehman, UI; Sobnath, D.; Nasralla, MM; Winnett, M.; Anwar, A.; Asif, W.; Sherazi, HHR Recursos de aplicativos móveis para pessoas com autismo em um cenário pós-COVID-19: Status atual e recomendações para aplicativos que usam IA. Diagnóstico **2021**, 11, 1923. [\[RefCruz\]](#)
24. Anwar , A.; Rehman, UI; Husamaldin, L.; Ijaz-ul-Haq. Educação Inteligente para Pessoas com Deficiência (PcDs): Estrutura Conceitual para Classificação de Emoções de PcDs a partir de Enunciados de Alunos (SUs) durante a Aprendizagem Online. Em Proceedings of the 2022 IEEE International Smart Cities Conference (ISC2), Pafos, Chipre, 26–29 de setembro de 2022; páginas 1–7.
25. Behdenna, S.; Barigou, F.; Belalem, G. Análise de sentimento em nível de documento: uma pesquisa. Sistema Trans.-Context-Aware endossado pela EAI. Apl. **2018**, 4, e2. [\[RefCruz\]](#)
26. Fawzy, M.; Fakhr, MW; Rizka, MA Word Embeddings e Arquiteturas de Redes Neurais para Análise de Sentimentos Árabes. Em Anais da 16ª Conferência Internacional de Engenharia da Computação de 2020 (ICENCO), Cairo, Egito, 29–30 de dezembro de 2020; pp. 92–96.
27. Tembhurne, JV; Diwan, T. Análise de sentimento em entradas textuais, visuais e multimodais usando redes neurais recorrentes. Multimed. Ferramentas Appl. **2021**, 80, 6871–6910. [\[RefCruz\]](#)
28. Droga, NC; Moreno-García, MN; De la Prieta, F. Análise de sentimento baseada em aprendizagem profunda: Um estudo comparativo. Eletrônicos **2020**, 9, 483. [\[CrossRef\]](#)
29. Shaik , T.; Tao, X.; Li, Y.; Dann, C.; McDonald, J.; Redmond, P.; Galligan, L. Uma revisão das tendências e desafios na adoção de métodos de processamento de linguagem natural para análise de feedback educacional. Acesso IEEE **2022**, 10, 56720–56739. [\[RefCruz\]](#)

30. Yu, L.C.; Lee, L.H.; Hao, S.; Wang, J.; Ei.; Hu, J.; Lai, K.R.; Zhang, X. Construindo recursos afetivos chineses em dimensões de excitação de valência . Em Anais da Conferência de 2016 do Capítulo Norte-Americano da Associação de Linguística Computacional: Tecnologias de Linguagem Humana, San Diego, CA, EUA, 12–17 de junho de 2016; págs. 540–545.
31. Asghar, M.Z.; Khan, A.; Ahmad, S.; Qasim, M.; Khan, I.A. Estrutura de análise de sentimento aprimorada pelo Lexicon usando regras esquema de classificação. *PLoS ONE* **2017**, 12, e0171649. [\[RefCruz\]](#)
32. Deng, S.; Sinha, A.P.; Zhao, H. Adaptando léxicos de sentimento a textos de mídia social de domínios específicos. *Decis. Sistema de suporte*. **2017**, 94, 65–76. [\[RefCruz\]](#)
33. Mathapati, S.; Manjula, S.; Venugopal, K. Análise de sentimento e mineração de opinião nas mídias sociais: uma revisão. *Globo. J. Computação. Ciência. Tecnologia*. **2016**, 6, 2017.
34. Denecke, K. Usando sentiwordnet para análise de sentimento multilíngue. Nos Anais da 24ª Internacional IEEE de 2008 Conferência sobre Workshop de Engenharia de Dados, Cancún, México, 7 a 12 de abril de 2008; páginas 507–512.
35. Guerini, M.; Gatti, L.; Turchi, M. Análise de sentimento: como derivar polaridades anteriores do SentiWordNet. *arXiv* **2013**, arXiv:1309.5843.
36. Khan, F.H.; Qamar, U.; Bashir, S. Uma abordagem semissupervisionada para análise de sentimento usando força de sentimento revisada com base no SentiWordNet. *Sabe. Inf. Sist.* **2017**, 51, 851–872. [\[RefCruz\]](#)
37. Elbagir, S.; Yang, J. Análise de sentimento do Twitter usando kit de ferramentas de linguagem natural e sentimento VADER. Em Anais da Multiconferência Internacional de Engenheiros e Cientistas da Computação, Hong Kong, China, 13–15 de março de 2019; Volume 122, pág. 16.
38. Tymann, K.; Lutz, M.; Palsbroker, P.; Gips, C. GerVADER-Uma adaptação alemã da ferramenta de análise de sentimento VADER para redes sociais Textos de mídia. In *Proceedings of the LWDA, Berlim, Alemanha*, 30 de setembro a 2 de outubro de 2019; páginas 178-189.
39. Bisio, F.; Meda, C.; Gastaldo, P.; Zunino, R.; Cambria, E. Análise de sentimento em nível de conceito com SenticNet. Em um guia prático para Análise de sentimentos; Springer: Berlim/Heidelberg, Alemanha, 2017; pp. 173–188.
40. Pendurado, C.; Wu, W.R.; Chou, H.M. Melhoria da análise de sentimento por meio da reavaliação de palavras objetivas no SenticNet para avaliações de hotéis. *Lang. Recurso. Avaliação*. **2021**, 55, 585–595. [\[RefCruz\]](#)
41. Hossain, M.S.; Rahman, M.F. Análise do sentimento do cliente e previsão de avaliações de produtos de seguros usando aprendizado de máquina abordagens. *Ônibus FIIB. Rev.* **2022**, 23197145221115793. [\[CrossRef\]](#)
42. Bakar, N.S.A.; Rahmat, R.A.; Othman, M. ferramenta de classificação de polaridade UF para análise de sentimentos na língua malaia. *IAES Int. J. Artefato. Intel.* **2019**, 8, 259.
43. Mohammad, S.M.; Turney, P.D. Nrc léxico emocional. *Nacional. Res. Conselho* **2013**, 2, 234.
44. Tabak, F.S.; Evrim, V. Comparação de léxicos emocionais. In *Proceedings of the 2016 HONET-ICT, Nicósia, Chipre*, 13–14 de outubro 2016; páginas 154–158.
45. De Smedt, T.; Daelemans, W. Padrão para python. *J. Mach. Aprender. Res.* **2012**, 13, 2063–2067.
46. Gatti, L.; van Stegeren, J. Melhorando a análise de sentimento holandesa em Pattern. *Computação. Linguista. Net. J.* **2020**, 10, 73–89.
47. Gujjar, J.P.; Kumar, A. análise HP Sentiment: Textblob para tomada de decisões. *Internacional J. Ciência. Res. Eng. Tendências* **2021**, 7, 1097–1099.
48. Bose, R.; Aithal, P.; Roy, S. Análise de sentimento com base em comentários de tweeters sobre aplicação de drogas por idioma habitual kit de ferramentas e opiniões de textblob de países distintos. *Internacional J.* **2020**, 8, 3684–3696.
49. Wan, Y.; Gao, Q. Um sistema de classificação de sentimento conjunto de dados do Twitter para análise de serviços aéreos. Em *Proceedings of the 2015 IEEE International Conference on Data Mining Workshop (ICDMW)*, Atlantic City, NJ, EUA, 14–17 de novembro de 2015; pp. .
50. Alsayat, A. Análise da tomada de decisão do cliente com base em big data social usando aprendizado de máquina: um estudo de caso de hotéis em Meca. *Computação Neural. Apl.* **2023**, 35, 4701–4722. [\[RefCruz\]](#)
51. Tang, D.; Qin, B.; Liu, T. Aprendizado profundo para análise de sentimento: abordagens bem-sucedidas e desafios futuros. *Wiley Interdisciplinar. Rev. Dados mínimos Sabe. Descoberta* **2015**, 5, 292–303. [\[RefCruz\]](#)
52. Dey, L.; Chakraborty, S.; Biswas, A.; Bose, B.; Tiwari, S. Análise de sentimento de conjuntos de dados de revisão usando bayes ingênuos e classificador k-nn. *arXiv* **2016**, arXiv:1610.09982.
53. Goel, A.; Gautam, J.; Kumar, S. Análise de sentimento em tempo real de tweets usando Naive Bayes. Em Anais da 2ª Conferência Internacional sobre Tecnologias de Computação de Próxima Geração (NGCT) de 2016, Dehradun, Índia, 14–16 de outubro de 2016; pp. 257–261.
54. Ahmad, M.; Aftab, S.; Ali, I. Análise de sentimento de tweets usando svm. *Internacional J. Computação. Aplicativo* **2017**, 177, 25–29. [\[RefCruz\]](#)
55. Ahmad, M.; Aftab, S.; Bashir, M.S.; Hameed, N.; Ali, I.; Nawaz, Z. Otimização SVM para análise de sentimento. *Internacional J. Adv. Computação. Ciência. Apl.* **2018**, 9, 393–398. [\[RefCruz\]](#)
56. Al Amrani, Y.; Lazaar, M.; El Kadir, K.E. Floresta aleatória e abordagem híbrida baseada em máquina de vetores de suporte para análise de sentimento. *Procedia Computação. Ciência.* **2018**, 127, 511–520. [\[RefCruz\]](#)
57. Fauzi, M.A. Abordagem Florestal Aleatória para Análise de Sentimentos em Indonésio. *Indonésia. J. Eletr. Eng. Computação. Ciências* **2018**, 12, 46–50.
58. Lião, S.; Wang, J.; Yu, R.; Sato, K.; Cheng, Z. CNN para compreensão de situações com base na análise de sentimento de dados do Twitter. *Procedia Computação. Ciência.* **2017**, 111, 376–381. [\[RefCruz\]](#)
59. Feng, Y.; Cheng, Y. Análise de sentimento de texto curto baseada em CNN multicanal com mecanismo de atenção multi-head. *Acesso IEEE* **2021**, 9, 19854–19863. [\[RefCruz\]](#)
60. Murthy, G.; Allu, S.R.; Andhavarapu, B.; Bagadi, M.; Belusonti, M. Análise de sentimento baseada em texto usando LSTM. *Internacional J. Eng. Res. Tecnologia. Res.* **2020**, 9.

61. Longo, F.; Zhou, K.; Ou, W. Análise de sentimento de texto baseada em LSTM bidirecional com atenção multi-head. Acesso IEEE **2019**, *7*, 141960–141969. [[RefCruz](#)]
62. Borele, P.; Borikar, DA Uma abordagem para análise de sentimento utilizando rede neural artificial com análise comparativa de diferentes técnicas. IOSR J. Computação. Eng. (IOSR-JCE) **2016**, *18*, 64–69.
63. Sharma, D.; Sabharwal, M.; Goyal, V.; Vij, M. Técnicas de análise de sentimento para dados de mídia social: uma revisão. Em Anais da Primeira Conferência Internacional sobre Tecnologias Sustentáveis para Inteligência Computacional: Anais do ICTSCI 2019, Jaipur, Índia, 29–30 de março de 2019; pp. 75–90.
64. Hoang, M.; Bihorac, OA; Rouces, J. Análise de sentimento baseada em aspectos usando bert. Nos Anais da 22ª Conferência Nórdica sobre Lingüística Computacional, Turku, Finlândia, 30 de setembro a 2 de outubro de 2019; pp. 187–196.
65. Zhao, L.; Li, L.; Zhen, X.; Zhang, J. Uma análise de sentimento baseada em BERT e abordagem de detecção de entidade chave para textos financeiros online. Em Anais da 24ª Conferência Internacional IEEE de 2021 sobre Trabalho Cooperativo em Design Apoiado por Computador (CSCWD), Dalian, China, 5–7 de maio de 2021; pp.
66. Mohan, M.; Abhinav, A.; Ashok, A.; Akhil, A.; Achinth, P. Depressão de Depressão usando Expressão Facial e Análise de Sentimento. Em Anais da Conferência Asiática sobre Inovação em Tecnologia de 2021 (ASIANCON), Pune, Índia, 27–29 de agosto de 2021; páginas 1–6.
67. Altuwairqi, K.; Jarraya, SK; Allinjaw, A.; Hammami, M. Análise do comportamento do aluno para medir os níveis de envolvimento em ambientes de aprendizagem online. Processo de vídeo de imagem de sinal. **2021**, *15*, 1387–1395. [[RefCruz](#)]
68. Ming, Y.; Qian, H.; Guangyuan, L. Método de reconhecimento de expressão facial CNN-LSTM fundido com atenção de duas camadas Mecanismo. Computação. Intel. Neurosci. **2022**, *2022*, 7450637. [[RefCruz](#)]
69. Guo, W.; Xu, Z.; Guo, Z.; Mao, L.; Hou, Y.; Huang, Z. Avaliação da dor usando unidades de ação facial e rede bayesiana. Em Anais da 40ª Conferência de Controle Chinês (CCC) de 2021, Xangai, China, 26–28 de julho de 2021; págs.
70. Mollahosseini, A.; Hasani, B.; Mahoor, MH Affectnet: Um banco de dados para expressão facial, valência e computação de excitação em estado selvagem. IEEE Trans. Afeto. Computação. **2017**, *10*, 18–31. [[RefCruz](#)]
71. Adnan, MM; Rahim, MSM; Rehman, A.; Mehmood, Z.; Sabá, T.; Naqvi, RA Anotação automática de imagens baseada em modelos de aprendizagem profunda: uma revisão sistemática e desafios futuros. Acesso IEEE **2021**, *9*, 50253–50264. [[RefCruz](#)]
72. Angadi, S.; Reddy, análise de sentimento multimodal VS usando seleção de recursos relevoF e classificador de floresta aleatório. Internacional J. Computação. Apl. **2021**, *43*, 931–939. [[RefCruz](#)]
73. Zhou, L.; Li, W.; Du, Y.; Lei, B.; Liang, S. Reconhecimento facial adaptativo invariante à iluminação por meio de contraste local não linear multicamadas recurso. J. Vis. Comum. Representação de imagem. **2019**, *64*, 102641. [[CrossRef](#)]
74. Podder, T.; Bhattacharya, D.; Majumdar, A. Reconhecimento de expressão facial em tempo real com eficiência de tempo com CNN e aprendizagem por transferência. Sadhan - a **2022**, *47*, 177. [[CrossRef](#)]
75. Heredia, J.; Cardinale, Y.; Dongo, I.; Díaz-Amado, J. Um método multimodal de reconhecimento de emoções visuais para instanciar uma ontologia. Em Anais da 16ª Conferência Internacional sobre Tecnologias de Software, online, 6–8 de julho de 2021; SCITEPRESS-Publicações de Ciência e Tecnologia: Setúbal, Portugal, 2021; págs.
76. Kirana, KC; Wibawanto, S.; Herwanto, HW Reconhecimento facial de emoções baseado no algoritmo viola-jones no ambiente de aprendizagem. Em Anais do Seminário Internacional sobre Aplicação de Tecnologia de Informação e Comunicação de 2018, Semarang, Indonésia, 21–22 de setembro de 2018; páginas 406–410.
77. Paulo, T.; Shammi, UA; Ahmed, MU; Rahman, R.; Kobashi, S.; Ahad, MAR Um estudo sobre detecção de rostos usando o algoritmo Viola-Jones em vários fundos, ângulos e distâncias. Internacional J. Biomédica. Computação suave. Zumbir. Ciência. Desligado. J. Biomédica. Sistema difuso. Assoc. **2018**, *23*, 27–36.
78. Hirzi, MF; Efendi, S.; Sembiring, RW Literatura Estudo de Reconhecimento Facial usando o Algoritmo Viola-Jones. Em Anais da Conferência Internacional de Inteligência Artificial e Sistemas Mecatrônicos (AIMS) de 2021, Bandung, Indonésia, 28–30 de abril de 2021; páginas 1–6.
79. Suhaimin, MSM; Hijazi, MHA; Kheau, CS; Ligado, CK Detecção de máscara em tempo real e reconhecimento facial usando eigenfaces e histograma de padrão binário local para sistema de atendimento. Touro. Eletr. Eng. Informar. **2021**, *10*, 1105–1113. [[RefCruz](#)]
80. Mukhopadhyay, S.; Sharma, S. Expressão facial em tempo real e reconhecimento de emoções usando rostos próprios, LBPH e algoritmos de pesca. Em Anais da 10ª Conferência Internacional sobre Computação em Nuvem, Ciência de Dados e Engenharia de 2020 (Confluence), Noida, Índia, 29–31 de janeiro de 2020; págs. 212–220.
81. Feliz, S.; Jorge, A.; Routray, A. Um sistema de classificação de expressões faciais em tempo real usando padrões binários locais. Em Anais da 4ª Conferência Internacional sobre Interação Inteligente entre Computadores e Humanos (IHCI) de 2012, Kharagpur, Índia, 27–29 de dezembro de 2012; páginas 1–5.
82. Shan, C.; Gong, S.; McOwan, PW Reconhecimento de expressão facial baseado em padrões binários locais: Um estudo abrangente. Imagem Vis. Computação. **2009**, *27*, 803–816. [[RefCruz](#)]
83. Zhao, X.; Zhang, S. Reconhecimento de expressão facial usando padrões binários locais e incorporação localmente linear de kernel discriminante. EURASIP J. Adv. Processo de sinal. **2012**, *2012*, 20. [[CrossRef](#)]
84. Hegde, N.; Preetha, S.; Bhagwat, S. Classificador de expressão facial usando técnica melhor: Algoritmo FisherFace. Em Anais da Conferência Internacional sobre Avanços em Computação, Comunicações e Informática (ICACCI) de 2018, Bangalore, Índia, 19–22 de setembro de 2018; páginas 604–610.

85. Kandhro, IA; Uddin, M.; Hussain, S.; Chaudhery, TJ; Shorfuzzaman, M.; Meshref, H.; Albalhaq, M.; Alsaqour, R.; Khalaf, O.I. **Impacto dos métodos de ativação, otimização e regularização no modelo de expressão facial usando CNN. Computação. Intel. Neurosci.** **2022**, *2022*, 3098604. [\[RefCruz\]](#)
86. Refat, MAR; Sarker, S.; Kaushal, C.; Kaur, A.; Islam, MK WhyMyFace: uma nova abordagem para reconhecer expressões faciais usando CNN e aumentos de dados. Em *Tecnologias Emergentes em Mineração de Dados e Segurança da Informação: Anais do IEMIS 2022, Volume 3*; Springer: Berlim/Heidelberg, Alemanha, 2022; páginas 553–563.
87. Jang, GJ; Parque, JS; Jo, A.; Kim, JH Reconhecimento de emoções faciais usando modelos de forma ativa e reconhecedores estatísticos de padrões. Em *Anais da Nona Conferência Internacional sobre Banda Larga e Computação Sem Fio, Comunicação e Aplicações de 2014, Guangdong, China, 8–10 de novembro de 2014*; páginas 514–517.
88. Shbib, R.; Zhou, S. Análise de expressão facial usando modelo de forma ativa. *Internacional J. Processo de sinal. Processo de imagem. Reconhecimento de padrões.* **2015**, *8*, 9–22. [\[RefCruz\]](#)
89. Ratliff, MS; Patterson, E. Reconhecimento de emoções usando expressões faciais com modelos de aparência ativa. Em *Anais da Terceira Conferência Internacional IASTED sobre Interação Humano-Computador, Innsbruck, Áustria, 17–19 de março de 2008*.
90. Martin, C.; Werner, U.; Gross, HM Um sistema de reconhecimento de expressão facial em tempo real baseado em modelos de aparência ativa usando imagens em cinza e imagens de borda. Em *Anais da 8ª Conferência Internacional IEEE sobre Reconhecimento Automático de Rostos e Gestos de 2008, Amsterdã, Holanda, 17–19 de setembro de 2008*; páginas 1–6.
91. Zadeh, A.; Chong Lim, Y.; Baltrusaitis, T.; Morency, LP Especialistas em convolução restringiram o modelo local para detecção de pontos de referência faciais em 3D. Em *Anais da Conferência Internacional IEEE sobre Workshops de Visão Computacional, Veneza, Itália, 22–29 de outubro de 2017*; páginas 2519–2528.
92. Hamm, J.; Kohler, CG; Gur, RC; Verma, R. Sistema automatizado de codificação de ação facial para análise dinâmica de expressões faciais em distúrbios neuropsiquiátricos. *J. Neurosci. Métodos* **2011**, *200*, 237–256. [\[RefCruz\]](#) [\[Pub Med\]](#)
93. Skienziel, T.; Rosch, AG; Schultheiss, OC Avaliando a validade convergente entre o software automatizado de reconhecimento de emoções Noldus FaceReader 7 e o Facial Action Coding System Scoring. *PLoS ONE* **2019**, *14*, e0223905. [\[RefCruz\]](#) [\[Pub Med\]](#)
94. Carcagni, P.; Del Coco, M.; Leão, M.; Distant, C. Reconhecimento de expressão facial e histogramas de gradientes orientados: A estudo compreensivo. *SpringerPlus* **2015**, *4*, 1–25. [\[RefCruz\]](#) [\[Pub Med\]](#)
95. Azem, A.; Sharif, M.; Xá, J.; Raza, M. Transformada de característica invariante em escala hexagonal (H-SIFT) para extração de características faciais. *J. Apl. Res. Tecnologia.* **2015**, *13*, 402–408. [\[RefCruz\]](#)
96. Karthikeyan, C.; Jaber, B.; Deepak, V.; Vamsidhar, E. Reconhecimento facial aprimorado baseado em processamento de imagem para dispositivos móveis usando transformação de recurso invariável em escala. Em *Anais da Conferência Internacional sobre Tecnologias de Computação Inventivas (ICICT) de 2020, Coimbatore, Índia, 26–28 de fevereiro de 2020*; páginas 716–722.
97. Calipolite, A.; Galliakis, M.; Menychtas, A.; Maglogiannis, I. Análise de emoções em plataformas de infoentretenimento à beira do leito de hospitais usando recursos robustos e acelerados. Em *Proceedings of the Artificial Intelligence Applications and Innovations: 15th IFIP WG 12.5 International Conference, AIAI 2019, Hersonissos, Creta, Grécia, 24–26 de maio de 2019; Processo 15*; pp. 127–138.
98. Madupu, RK; Kothapalli, C.; Yarra, V.; Harika, S.; Basha, CZ Sistema automático de reconhecimento de emoções humanas usando expressões faciais com rede neural de convolução. Em *Anais da 4ª Conferência Internacional sobre Eletrônica, Comunicação e Tecnologia Aeroespacial (ICECA) de 2020, Coimbatore, Índia, 5–7 de novembro de 2020*; pp.
99. Apicela, A.; Arpaia, P.; Frosolone, M.; Improta, G.; Moccaldi, N.; Pollastro, A. Sistema de medição baseado em EEG para monitoramento envolvimento dos alunos na aprendizagem 4.0. *Ciência. Rep.* **2022**, *12*, 5857. [\[CrossRef\]](#)
100. Ladino Nocua, AC; Cruz González, JP; Castiblanco Jiménez, IA; Gómez Acevedo, JS; Marcolín, F.; Vezzetti, E. Avaliação do envolvimento cognitivo do aluno usando dados de frequência cardíaca no ensino à distância durante o COVID-19. *Educ. Ciência.* **2021**, *11*, 540. [\[CrossRef\]](#)
101. Xá, SMA; Usman, SM; Khalid, S.; Rehman, UI; Anwar, A.; Hussain, S.; Ulá, SS; Elmannai, H.; Algarni, AD; Manzoor, W. Um modelo conjunto para previsão de emoções do consumidor usando sinais de EEG para aplicações de neuromarketing. *Sensores* **2022**, *22*, 9744. [\[RefCruz\]](#)
102. Selçuk, AA Um guia para revisões sistemáticas: PRISMA. *Turco. Arco. Otorrinolaringol.* **2019**, *57*, 57. [\[CrossRef\]](#)
103. Nguyen, VD; Van Nguyen, K.; Nguyen, NLT Variantes de memória de longo e curto prazo para análise de sentimento no corpus de feedback de estudantes vietnamitas. Em *Anais da 10ª Conferência Internacional sobre Conhecimento e Engenharia de Sistemas (KSE) de 2018, Cidade de Ho Chi Minh, Vietnã, 1–3 de novembro de 2018*; páginas 306–311.
104. Estrada, MLB; Cabada, RZ; Bustillos, RO; Graff, M. Mineração de opinião e reconhecimento de emoções aplicado a ambientes de aprendizagem. *Sistema Especialista Apl.* **2020**, *150*, 113265. [\[RefCruz\]](#)
105. Hew, KF; Hu, X.; Qiao, C.; Tang, Y. O que prevê a satisfação dos alunos com MOOCs: árvores que aumentam o gradiente supervisionadas abordagem de aprendizado de máquina e análise de sentimento. *Computação. Educ.* **2020**, *145*, 103724. [\[CrossRef\]](#)
106. Onan, A. Análise de sentimento sobre avaliações massivas de cursos online abertos: Uma abordagem de mineração de texto e aprendizagem profunda. *Computação. Apl. Eng. Educ.* **2021**, *29*, 572–589. [\[RefCruz\]](#)
107. Nkomo, LM; Ndukwe, IG; Daniel, BK Rede social e análise de sentimentos: investigação das perspectivas dos alunos sobre gravação de palestra. *Acesso IEEE* **2020**, *8*, 228693–228701. [\[RefCruz\]](#)
108. Rääf, SA; Knöös, J.; Dalipi, F.; Kastrati, Z. Investigando a experiência de aprendizagem de alunos MOOCs usando modelagem de tópicos e análise de sentimentos. Em *Anais da 19ª Conferência Internacional sobre Ensino Superior e Treinamento Baseado em Tecnologia da Informação (ITHET) de 2021, Sydney, Austrália, 4–6 de novembro de 2021*; páginas 1–7.

109. Mujahid, M.; Lee, E.; Rustam, F.; Washington, PB; Ullah, S.; Reshi, AA; Ashraf, I. Análise de sentimento e modelagem de tópicos em tweets sobre educação online durante o COVID-19. *Apl. Ciência*. **2021**, 11, 8438. [\[CrossRef\]](#)
110. OSMANOGLU, U.Ö.; Atak, ON; Çaygılar, K.; Kayhan, H.; Talat, C. Análise de sentimento para materiais de cursos de educação a distância: A abordagem de aprendizado de máquina. *J.Educ. Tecnologia. Aprenda on-line*. **2020**, 3, 31–48. [\[RefCruz\]](#)
111. Vedavathi, N.; KM, AK Recomendação de curso de e-learning com base na análise de sentimento usando similaridade híbrida de Elman. *Sistema baseado em conhecimento*. **2023**, 259, 110086.
112. Tan, L.; Bronzeado, tudo bem; Sze, CC; Goh, WWB Emotional Variance Analysis: Um novo recurso de análise de sentimento definido para Artificial Aplicações de inteligência e aprendizado de máquina. *PLoS ONE* **2023**, 18, e0274299. [\[RefCruz\]](#)
113. Sadigov, R.; Yildırm, E.; Kocaçınar, B.; Patlar Akbulut, F.; Catal, C. Avaliação da experiência do usuário baseada em aprendizagem profunda à distância aprendizado. *Clusto. Computação*. **2023**, 26, 1–13. [\[RefCruz\]](#)
114. Kathuria, A.; Gupta, A.; Singla, R. AOH-Senti: Abordagem Híbrida Orientada a Aspectos para Análise de Sentimento do Feedback dos Alunos. *Computação SN. Ciência*. **2023**, 4, 152. [\[CrossRef\]](#)
115. Crossley, S.; McNamara, DS; Padeiro, R.; Wang, Y.; Paquette, L.; Barnes, T.; Bergner, Y. Idioma até a conclusão: sucesso em uma aula on-line aberta e massiva de mineração de dados educacionais. In *Proceedings of the 7th Annual Conference on Educational Data Mining, EDM2015, Madrid, Espanha, 26–29 de junho de 2015*
116. Kagklis, V.; Karatrantou, A.; Tantoula, M.; Panagiotakopoulos, CT; Verykios, VS Uma metodologia de análise de aprendizagem para detectar sentimentos em fóruns estudantis: Um estudo de caso em educação a distância. *EUR. J. e-Learn à distância aberta*. **2015**, 18, 74–94. [\[RefCruz\]](#)
117. Fátima, N.; Rahman, MA Um sistema aprimorado de apoio à decisão por meio da mineração de dados de bate-papo on-line de professores. *Internacional J. Elétron. Eng*. **2018**, 10, 426–436.
118. Almalki, J. Uma abordagem baseada em aprendizado de máquina para análise de sentimentos no ensino à distância a partir de tweets em árabe. *Computação PeerJ. Ciência*. **2022**, 8, e1047. [\[RefCruz\]](#) [\[Pub Med\]](#)
119. Asmita, S.; Anuja, T.; Ash, D. Análise do feedback dos alunos usando aprendizagem profunda. *Internacional J. Computação. Apl. Tecnologia. Res* **2019**, 8, 161–164. [\[RefCruz\]](#)
120. Rajput, Q.; Haider, S.; Ghani, S. Análise de sentimento baseada no léxico da avaliação dos professores. *Apl. Computação. Intel. Computação suave*. **2016**, 2016, 2385429. [\[CruzRef\]](#)
121. Nasim, Z.; Rajput, Q.; Haider, S. Análise de sentimento do feedback dos alunos usando aprendizado de máquina e abordagens baseadas em léxico. Em *Anais da Conferência Internacional sobre Pesquisa e Inovação em Sistemas de Informação (ICRIIS) de 2017, Langkawi, Malásia, 16–17 de julho de 2017*; páginas 1–6.
122. Santos, CL; Rita, P.; Guerreiro, J. Melhorar a atratividade internacional das instituições de ensino superior com base na mineração de textos e análise de sentimento. *Internacional J.Educ. Gerenciar*. **2018**, 32, 431–447. [\[RefCruz\]](#)
123. Kandhro, IA; Chhajro, MA; Kumar, K.; Lashari, HN; Khan, U. Modelo de análise de sentimento de feedback do aluno usando vários esquemas de aprendizado de máquina: uma revisão. *Indian J. Sci. Tecnologia*. **2019**, 12, 1–9. [\[RefCruz\]](#)
124. Jena, R. Mineração de sentimentos em um ambiente de aprendizagem colaborativa: Capitalizando em big data. *Comporte-se. Inf. Tecnologia*. **2019**, 38, 986–1001. [\[RefCruz\]](#)
125. Shen, CW; Kuo, CJ Aprendizagem em cursos on-line abertos e massivos: evidências da mineração de mídia social. *Computação. Zumbir. Comporte-se*. **2015**, 51, 568–577. [\[RefCruz\]](#)
126. Aung, KZ; Myo, NN Análise de sentimento dos comentários dos alunos usando abordagem baseada em léxico. Em *Anais da 16ª Conferência Internacional sobre Ciência da Computação e Informação (ICIS) do IEEE/ACIS 2017, Wuhan, China, 24–26 de maio de 2017*; páginas 149–154.
127. Tanwani, N.; Kumar, S.; Jalbani, AH; Soomro, S.; Channa, MI; Nizamani, Z. Mineração de opinião de estudantes sobre o sistema educacional usando grupo do Facebook. Em *Anais da Primeira Conferência Internacional sobre as Últimas Tendências em Engenharia Elétrica e Tecnologias de Computação (INTELLECT) de 2017, Karachi, Paquistão, 15–16 de novembro de 2017*; páginas 1–5.
128. Sindhu, I.; Daudpota, SM; Badar, K.; Bakhtyar, M.; Baber, J.; Nurunnabi, M. Mineração de opinião baseada em aspectos sobre o feedback dos alunos para avaliação de desempenho docente do corpo docente. *Acesso IEEE* **2019**, 7, 108729–108741. [\[RefCruz\]](#)
129. Kastrati, Z.; Imran, AS; Kurti, A. Estrutura fracamente supervisionada para análise de sentimento baseada em aspectos nas avaliações dos alunos sobre MOOCs. *Acesso IEEE* **2020**, 8, 106799–106810. [\[RefCruz\]](#)
130. Alassaf, M.; Qamar, AM Análise de sentimento baseada em aspectos de tweets árabes no setor educacional usando um método híbrido de seleção de recursos. Em *Anais da 14ª Conferência Internacional sobre Inovações em Tecnologia da Informação (IIT) de 2020, Al Ain, Emirados Árabes Unidos, 17–18 de novembro de 2020*; pp. 178–185.
131. Zhai, G.; Yang, Y.; Wang, H.; Du, S. Modelagem de fusão multitarefa para análise de sentimento de big data educacional. *Mínimo de Big Data Anal.* **2020**, 3, 311–319. [\[RefCruz\]](#)
132. Kastrati, Z.; Arifaj, B.; Lubishtani, A.; Gashi, F.; Nishliu, E. Mineração de opinião baseada em aspectos de avaliações de alunos sobre cursos on-line. Em *Anais da 6ª Conferência Internacional sobre Computação e Inteligência Artificial de 2020, Tianjin, China, 25–27 de maio de 2022*; páginas 510–514.
133. Balachandran, L.; Kirupananda, A. Sistema de avaliação de avaliações online para instituições de ensino superior: uma ferramenta de análise de sentimento baseada em aspectos. Em *Anais da 11ª Conferência Internacional sobre Software, Conhecimento, Gestão de Informação e Aplicações (SKIMA) de 2017, Malabe, Sri Lanka, 6–8 de dezembro de 2017*; páginas 1–7.

134. Heryadi, Y.; Wijanarko, BD; Murad, DF; Isso, C.; Hashimoto, K. Análise de sentimento baseada em aspectos para melhorar o programa de aprendizagem online com base no feedback do aluno. Em Anais da Conferência Internacional IEEE de 2022 sobre Cibernética e Inteligência Computacional (CyberneticsCom), Malang, Indonésia, 16–18 de junho de 2022; págs. 505–509.
135. Zhao, A.; Yu, Y. BERT habilitado para conhecimento para análise de sentimento baseada em aspectos. Sistema baseado em conhecimento. **2021**, 227, 107220. [Ref Cruzada]
136. Schurig, T.; Zambach, S.; Mukkamala, RR; Petry, M. Análise de sentimento baseada em aspectos para análise de ensino universitário. 2022. Artigos de pesquisa ECIS 2022. 2022. Disponível online: https://aisel.aisnet.org/ecis2022_rp/13 (acessado em 18 de julho de 2023).
137. Ramesh, A.; Kumar, SH; Foulds, J.; Getoor, L. Modelos de sentimento de aspecto fracamente supervisionados para fóruns de discussão de cursos online. Em Anais da 53ª Reunião Anual da Association for Computational Linguistics e da 7ª Conferência Conjunta Internacional sobre Processamento de Linguagem Natural (Volume 1: Long Papers), Pequim, China, 26–31 de julho de 2015; pp. 74–83.
138. Sivakumar, M.; Reddy, EUA Análise de sentimento baseada em aspectos da opinião dos alunos usando técnicas de aprendizado de máquina. Em Proceedings of the 2017 International Conference on Inventive Computing and Informatics (ICICI), Coimbatore, Índia, 23–24 de novembro de 2017; pp. 726–731.
139. Ismail, H.; Khalil, A.; Hussein, N.; Elabyad, R. Gatilhos e Tweets: Análise Implícita de Sentimentos e Emoções Baseadas em Aspectos de Conversas Comunitárias Relevantes para a Educação Pós-COVID-19. Conhecimento de Big Data. Computação. **2022**, 6, 99. [CrossRef]
140. Phillips, T.; Saleh, A.; Glazewski, KD; Hmelosilver, CE; Lee, S.; Mott, B.; Lester, JC Comparando Métodos de Processamento de Linguagem Natural para Classificação de Texto de Pequenos Dados Educacionais. Em Proceedings of the Companion Proceedings 11th International Conference on Learning Analytics & Knowledge, Irvine, CA, EUA, 12–16 de abril de 2021.
141. Cao, Y.; Zhang, P.; Xiong, A. Análise de sentimento baseada em aspecto expandido e léxico de palavras com polaridade ambígua. Internacional J. Adv. Computação. Ciência. Apl. **2015**, 6, 97–103. [RefCruz]
142. Piryani, R.; Madhavi, D.; Singh, VK Mapeamento analítico de pesquisa de mineração de opinião e análise de sentimento durante 2000–2015. Inf. Processo. Gerenciar. **2017**, 53, 122–150. [RefCruz]
143. Bhargava, S.; Choudhary, S. Análise comportamental de sentimental deprimido no Twitter: Baseado na abordagem de aprendizado de máquina supervisionado. Em Anais da 3ª Conferência Internacional sobre Internet das Coisas e Tecnologias Conectadas (ICIoTCT), Jaipur, Índia, 26–27 de março de 2018; págs. 26–27.
144. Catal, C.; Nangir, M. Um modelo de classificação de sentimento baseado em vários classificadores. Apl. Computação suave. **2017**, 50, 135–141. [RefCruz]
145. Shu, K.; Sliva, A.; Wang, S.; Tang, J.; Liu, H. Detecção de notícias falsas nas redes sociais: uma perspectiva de mineração de dados. ACM SIGKDD Explorar. Notícias. **2017**, 19, 22–36. [RefCruz]
146. Chen, T.; Li, X.; Yin, H.; Zhang, J. Chame a atenção para rumores: redes neurais recorrentes baseadas em atenção profunda para detecção precoce de rumores. Em Proceedings of the Trends and Applications in Knowledge Discovery and Data Mining: PAKDD 2018 Workshops, BDASC, BDM, ML4Cyber, PAISI, DaMEMO, Melbourne, VIC, Austrália, 3 de junho de 2018; Artigos Seleccionados Revisados 22; págs. 40–52.
147. Sayyad, S.; Kumar, S.; Bongale, A.; Kamat, P.; Patil, S.; Kotecha, K. Estimativa de vida útil restante baseada em dados para processo de fresamento: sensores, algoritmos, conjuntos de dados e direções futuras. Acesso IEEE **2021**, 9, 110255–110286. [RefCruz]
148. Varol, O.; Ferrara, E.; Davis, C.; Menczer, F.; Flammini, A. Interações on-line humano-bot: detecção, estimativa e caracterização. Em Proceedings of the International AAAI Conference on Web and Social Media, Montreal, QC, Canadá, 15–18 de maio de 2017; Volume 11, pp.
149. Arora, M.; Kansal, V. Incorporação de nível de personagem com rede neural convolucional profunda para normalização de texto de dados não estruturados para análise de sentimento do Twitter. Soc. Rede. Anal. Min. **2019**, 9, 1–14. [RefCruz]
150. Al-Natour, S.; Turetken, O. Uma avaliação comparativa de análise de sentimento e classificações de estrelas para avaliações de consumidores. Internacional J. Inf. Gerenciar. **2020**, 54, 102132. [CrossRef]
151. Ghiassi, M.; Skinner, J.; Zimbra, D. Análise de sentimento da marca no Twitter: um sistema híbrido usando análise de n-gramas e análise dinâmica rede neural artificial. Sistema Especialista Apl. **2013**, 40, 6266–6282. [RefCruz]
152. Sedova, K.; Sedlacek, M.; Svaricek, R.; Majcik, M.; Navratilova, J.; Drexlerova, A.; Kychler, J.; Salamounova, Z. Quem fala mais aprende mais? A relação entre a conversa dos alunos em sala de aula e o desempenho dos alunos. Aprender. Instr. **2019**, 63, 101217. [RefCruz]
153. Hinkle, CM; Koretsky, MD Rumor à prática profissional: Oportunidades de aprendizagem dos alunos através da participação em clubes de engenharia. EUR. J. Eng. Educ. **2019**, 44, 906–922. [RefCruz]
154. Lakshmi, KN; Reddy, YK; Kireeti, M.; Swathi, T.; Ismail, M. Projeto e implementação de bot de bate-papo para estudantes usando AIML e LSA. Internacional J. Innov. Tecnologia. Explorar. Eng. **2019**, 8, 1742–1746.
155. Chang, CY; Hwang, GJ; Gau, ML Promovendo o sucesso da aprendizagem e a autoeficácia dos alunos: uma abordagem de chatbot móvel para formação em enfermagem. Ir. J. Educ. Tecnologia. **2022**, 53, 171–188. [RefCruz]
156. Das, B.; Krishnan, NC; Cook, DJ Tratamento de sobreposição e desequilíbrio de classes para detectar situações imediatas em casas inteligentes. Em Proceedings of the 2013 IEEE 13th International Conference on Data Mining Workshops, Dallas, TX, EUA, 7–10 de dezembro de 2013; pp. 266–273.
157. Ele, H.; Garcia, EA Aprendendo com dados desequilibrados. IEEE Trans. Sabe. Engº de Dados **2009**, 21, 1263–1284.
158. Blitzer, J.; Dredze, M.; Pereira, F. Biografias, bollywood, boom-boxes e liquidificadores: Adaptação de domínio para classificação de sentimentos. Em Anais da 45ª Reunião Anual da Associação de Linguística Computacional, Praga, República Tcheca, 25–26 de junho de 2007; págs.

159. Queimaduras, N.; Bi, Y.; Wang, H.; Anderson, T. Análise de sentimento de avaliações de clientes: conjuntos de dados balanceados versus não balanceados. Em *Proceedings of the Knowledge-Based and Intelligent Information and Engineering Systems: 15th International Conference, KES 2011, Kaiserslautern, Alemanha, 12–14 de setembro de 2011*; Processo, Parte I 15; Springer: Berlin/Heidelberg, Alemanha, 2011; páginas 161–170.
160. Amjad, A.; Qaiser, S.; Anwar, A.; Ijaz-ul-Haq; Ali, R. Analisando os sentimentos do público em relação às vacinas COVID-19: Uma abordagem de análise de sentimentos. Em *Anais da Conferência Internacional IEEE de Cidades Inteligentes de 2021 (ISC2)*, Manchester, Reino Unido, 7 a 10 de setembro de 2021; páginas 1–7.
161. Salas-Zarate, MdP; Medina-Moreira, J.; Lagos-Ortiz, K.; Luna-Aveiga, H.; Rodriguez-Garcia, MA; Valencia-Garcia, R. Análise de sentimento em tweets sobre diabetes: uma abordagem em nível de aspecto. *Computação. Matemática. Métodos Med.* **2017**, 2017, 5140631. [\[RefCruz\]](#)
162. Flekova, L.; Preotiu-Pietro, D.; Ruppert, E. Analisando a adequação do domínio de um léxico de sentimento identificando palavras distributivamente bipolares. In *Proceedings of the 6th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis*, Lisboa, Portugal, 17 de setembro de 2015; pp. 77–84.
163. Tacchini, E.; Ballarin, G.; Della Vedova, ML; Moret, S.; De Alfaro, L. Alguns gostam de farsa: detecção automatizada de notícias falsas em redes sociais. *redes. arXiv* **2017**, arXiv:1704.07506.
164. Fang, K. Técnicas de aprendizado profundo para detecção de notícias falsas. *Mach. Aprender.* **2022**, 16, 511–518. [\[RefCruz\]](#)
165. Sykora, M.; Elayan, S.; Jackson, TW Uma análise qualitativa de sarcasmo, ironia e hashtags # relacionadas no Twitter. *Sociedade de Big Data.* **2020**, 7, 2053951720972735.
166. Megahed, M.; Mohammed, A. Modelagem de ambiente de E-learning adaptativo usando expressões faciais e lógica difusa. *Sistema Especialista Apl.* **2020**, 157, 113460. [\[CrossRef\]](#)
167. Ayvaz, U.; Gürüler, H.; Devrim, MO Uso de reconhecimento de emoções faciais em sistemas de e-learning. *Inf. Tecnologia. Aprender. Ferramentas* **2017**, 60. [\[RefCruz\]](#)
168. Ashwin, T.; José, J.; Raghu, G.; Reddy, GRM Um sistema de e-learning com reconhecimento multifacial de emoções usando aprendizado de máquina supervisionado. Nos *Anais da Sétima Conferência Internacional IEEE sobre Tecnologia para Educação (T4E)* de 2015, Warangal, Índia, 10–12 de dezembro de 2015; págs. 23–26.
169. Al-Alwani, A. Extração de humor usando características faciais para melhorar as curvas de aprendizagem de alunos em sistemas de e-learning. *Internacional J. Adv. Computação. Ciência. Apl.* **2016**, 7, 444–453. [\[RefCruz\]](#)
170. Tabassum, T.; Allen, AA; De, P. Identificação não intrusiva da atenção do aluno e descoberta de sua correlação com detectável emoções faciais. Em *Anais da Conferência ACM Sudeste de 2020*, Tampa, FL, EUA, 2–4 de abril de 2020; páginas 127–134.
171. Lopes, AT; De Aguiar, E.; De Souza, AF; Oliveira-Santos, T. Reconhecimento de expressões faciais com redes neurais convolucionais: Lidando com poucos dados e a ordem da amostra de treinamento. *Reconhecimento de padrões.* **2017**, 61, 610–628. [\[RefCruz\]](#)
172. Ramakrishnan, A.; Ottmar, E.; LoCasale-Crouch, J.; Whitehill, J. Rumo à observação automatizada de sala de aula: Prevendo clima positivo e negativo. Em *Anais da 14ª Conferência Internacional IEEE de 2019 sobre Reconhecimento Automático de Rostos e Gestos (FG 2019)*, Lille, França, 14–18 de maio de 2019; páginas 1–8.
173. Ozdemir, D.; Ugur, ME Proposta de modelo de determinação de frequência de alunos em educação a distância com reconhecimento facial tecnologia. *Turco. Online J. Educação a Distância.* **2021**, 22, 19–32. [\[RefCruz\]](#)
174. Salameh, ABS; Akyüz, HI Um novo modelo de aprendizagem profunda para reconhecimento e registro facial no ensino à distância. *Internacional J. Emergir. Tecnologia. Aprender. (Online)* **2022**, 17, 29. [\[CrossRef\]](#)
175. TS, A.; Guddeti, RMR Detecção automática de estados afetivos de alunos em ambiente de sala de aula usando redes neurais convolucionais híbridas. *Educ. Inf. Tecnologia.* **2020**, 25, 1387–1415.
176. Gandhi, A.; Adhvaryu, K.; Poria, S.; Cambria, E.; Hussain, A. Análise de sentimento multimodal: Uma revisão sistemática da história, conjuntos de dados, métodos de fusão multimodal, aplicações, desafios e direções futuras. *Inf. Fusão* **2022**, 91, 424–444. [\[RefCruz\]](#)
177. Wang, Z.; Zeng, F.; Liu, S.; Zeng, B. OAENet: Conjunto de atenção orientada para reconhecimento preciso de expressões faciais. *Reconhecimento de padrões.* **2021**, 112, 107694. [\[CrossRef\]](#)
178. Bodini, M. Uma revisão da extração de pontos de referência faciais em imagens e vídeos 2D usando aprendizagem profunda. *Conhecimento de Big Data. Computação.* **2019**, 3, 14. [\[CruzRef\]](#)
179. Nestor, MS; Fischer, D.; Arnold, D. “Mascarando” nossas emoções: toxina botulínica, expressão facial e bem-estar na idade de COVID 19. *J. Cosmet. Dermatol.* **2020**, 19, 2154–2160. [\[RefCruz\]](#)
180. Karnati, M.; Selo, A.; Bhattacharjee, D.; Yazidi, A.; Krejcar, O. Compreendendo técnicas de aprendizagem profunda para reconhecimento de emoções humanas usando expressões faciais: uma pesquisa abrangente. *IEEE Trans. Instrumento. Medidas.* **2023**, 72, 5006631. [\[RefCruz\]](#)
181. Kamińska, D.; Aktas, K.; Rizhinashvili, D.; Kuklyanov, D.; Sham, AH; Escalera, S.; Nasrollahi, K.; Moeslund, TB; Anbarjafari, G. Reconhecimento em dois estágios e além para reconhecimento de emoções faciais compostas. *Eletrônica* **2021**, 10, 2847. [\[CrossRef\]](#)
182. Li, Y.; Tao, J.; Schuller, B.; Shan, S.; Jiang, D.; Jia, J. MEC 2016: O desafio de reconhecimento de emoções multimodais do CCPR 2016. Em *Proceedings of the Pattern Recognition: 7ª Conferência Chinesa, CCPR 2016*, Chengdu, China, 5–7 de novembro de 2016; Procedimentos, Parte II 7; páginas 667–678.
183. Schirmer, A.; Adolphs, R. Percepção de emoção por rosto, voz e toque: comparações e convergência. *Tendências Cog. Ciência.* **2017**, 21, 216–228. [\[RefCruz\]](#) [\[Pub Med\]](#)
184. Zhang, M.; Chen, Y.; Lin, Y.; Ding, H.; Zhang, Y. Percepção multicanal de emoção na fala, voz, expressão facial e gestos em indivíduos com autismo: uma revisão de escopo. *J. Discurso Lang. Ouvir. Res.* **2022**, 65, 1435–1449. [\[RefCruz\]](#) [\[Pub Med\]](#)

-
185. Canção, B.; Li, K.; Zong, Y.; Zhu, J.; Zheng, W.; Shi, J.; Zhao, L. Reconhecendo microexpressão espontânea usando um fluxo de três rede neural convolucional. Acesso IEEE **2019**, *7*, 184537–184551. [\[RefCruz\]](#)
186. Cai, W.; Gao, M.; Liu, R.; Mao, J. MIFAD-net: Rede de fusão de recursos interativos multicamadas com perda de distância angular para reconhecimento de emoções faciais. *Frente. Psicol.* **2021**, *12*, 4707. [\[CrossRef\]](#)
187. Wang, Y.; Veja, J.; Ah, sim; Phan, RCW; Rahulamathavan, Y.; Ling, HC; Bronzeado, SW; Li, X. Reconhecimento eficaz de microexpressões faciais com ampliação de movimento de vídeo. *Multimed. Ferramentas Appl.* **2017**, *76*, 21665–21690. [\[RefCruz\]](#)
188. Al Chanti, D.; Caplier, A. Aprendizagem profunda para modelagem espaço-temporal de emoções espontâneas dinâmicas. *IEEE Trans. Afeto. Computação.* **2018**, *12*, 363–376. [\[RefCruz\]](#)
189. Huang, B.; Wang, Z.; Jiang, K.; Zou, Q.; Tian, X.; Lu, T.; Han, Z. Segmentação conjunta e aprendizagem de recursos de identificação para reconhecimento facial de oclusão. *IEEE Trans. Rede Neural. Aprender. Sist.* **2022**. [\[RefCruz\]](#)
190. Yang, K.; Wang, C.; Sarsenbayeva, Z.; Etiqueta, B.; Dingler, T.; Wadley, G.; Gonçalves, J. Benchmarking de detecção de emoções comerciais sistemas que usam distorções realistas de conjuntos de dados de imagens faciais. *Vis. Computação.* **2021**, *37*, 1447–1466. [\[RefCruz\]](#)
191. Meng, Z.; Liu, P.; Cai, J.; Han, S.; Tong, Y. Rede neural convolucional com reconhecimento de identidade para reconhecimento de expressão facial. Em *Anais da 12ª Conferência Internacional IEEE de 2017 sobre Reconhecimento Automático de Rosto e Gestos (FG 2017)*, Washington, DC, EUA, 30 de maio a 3 de junho de 2017; páginas 558–565.
192. Li, S.; Deng, W. Reconhecimento profundo de expressões faciais: uma pesquisa. *IEEE Trans. Afeto. Computação.* **2020**, *13*, 1195–1215. [\[RefCruz\]](#)
193. Samadiani, N.; Huang, G.; Cai, B.; Luo, W.; Chi, CH; Xiang, Y.; He, J. Uma revisão sobre reconhecimento automático de expressões faciais sistemas assistidos por dados de sensores multimodais. *Sensores* **2019**, *19*, 1863. [\[CrossRef\]](#) [\[Pub Med\]](#)
194. Deshmukh, S.; Patwardhan, M.; Mahajan, A. Pesquisa sobre técnicas de reconhecimento de expressões faciais em tempo real. *Deixe Biom.* **2016**, *5*, 155–163. [\[RefCruz\]](#)
195. Hassouneh, A.; Mutawa, A.; Murugappan, M. Desenvolvimento de um sistema de reconhecimento de emoções em tempo real usando expressões faciais e EEG baseado em aprendizado de máquina e métodos de redes neurais profundas. *Informar. Med. Desbloqueado* **2020**, *20*, 100372. [\[CrossRef\]](#)

Isenção de responsabilidade/Nota do editor: As declarações, opiniões e dados contidos em todas as publicações são exclusivamente de responsabilidade do (s) autor(es) e colaborador(es) individual(is) e não do MDPI e/ou do(s) editor(es). O MDPI e/ou o(s) editor(es) isentam-se de responsabilidade por qualquer dano a pessoas ou propriedades resultante de quaisquer ideias, métodos, instruções ou produtos mencionados no conteúdo.