

Ugur Ayvaz

Mestrado em Engenharia de Sistemas de Informação (em curso), Departamento de Engenharia de Sistemas de Informação, Assistente de pesquisa

Universidade Mugla Sıtkı Kocman, Mugla, Turquia

ugur.ayvaz@mu.edu.tr

Hüseyin Gürüler PhD

em Educação Eletrônica e de Computação, Departamento de Engenharia de Sistemas de Informação, Professor Assistente Mugla Sıtkı

Kocman University, Mugla, Turquia ORCID ID

0000-0003-1855-1882 *hguruler@mu.edu.tr*

Mehmet Osman Devrim MSc

em Engenharia de Sistemas de Informação (em andamento), Departamento de Engenharia de Sistemas de Informação, Estudante

Mugla Sıtkı Kocman University, Mugla, Turquia

mehmetosmandevrim@posta.mu.edu.tr

USO DO RECONHECIMENTO DE EMOÇÕES FACIAIS EM SISTEMAS DE E-LEARNING

Abstrato. Como o uso de computadores pessoais e a largura de banda da Internet estão aumentando, os sistemas de e-learning também estão se espalhando amplamente. Embora o e-learning tenha algumas vantagens em termos de acessibilidade à informação e flexibilidade de tempo e local em comparação com a aprendizagem formal, não proporciona interatividade presencial suficiente entre o educador e os alunos. Neste estudo, propomos um sistema de informação híbrido, que combina visão computacional e tecnologias de aprendizado de máquina para sistemas de e-learning visuais e interativos. O sistema de informação proposto detecta estados emocionais dos alunos e dá feedback a um educador sobre seus estados emocionais instantâneos e ponderados com base em expressões faciais. Desta forma, o educador estará ciente do estado emocional geral da sala de aula virtual e o sistema criará um ambiente interativo semelhante ao da aprendizagem formal. Aqui, vários algoritmos de classificação foram aplicados para aprender o estado emocional instantâneo e as melhores taxas de precisão foram obtidas usando algoritmos kNN e SVM.

Palavras-chave: e-learning, reconhecimento facial de emoções, visão computacional, aprendizado de máquina, sala de aula virtual.

1. INTRODUÇÃO

A palavra e-learning foi pronunciada pela primeira vez no seminário CBT Systems em 1999. O e-learning é chamado de “aprendizagem combinada” que seleciona todos os itens educacionais e técnicos e os reúne em um ambiente rico e interativo [1]. Assim que a ideia do e-learning foi explicada, aumentaram as expectativas de conversão da educação formal para o e-learning.

No entanto, no início dos anos 2000, as tecnologias web não conseguiam satisfazer estas elevadas expectativas no sentido do sistema de e-learning e dos materiais do curso (Figura 1) [2]. Aqui, a fase de preparação dos documentos educacionais foi um problema importante, porque era um processo demorado e caro. O conteúdo do curso e-learning não foi impressionante e benéfico o suficiente para manter os alunos no ambiente virtual por muito tempo [3]. Nos últimos quinze anos, as atividades de e-learning e os documentos de formação baseados na Web têm-se tornado comuns em todo o mundo com o aumento dos computadores pessoais e da utilização da Internet.

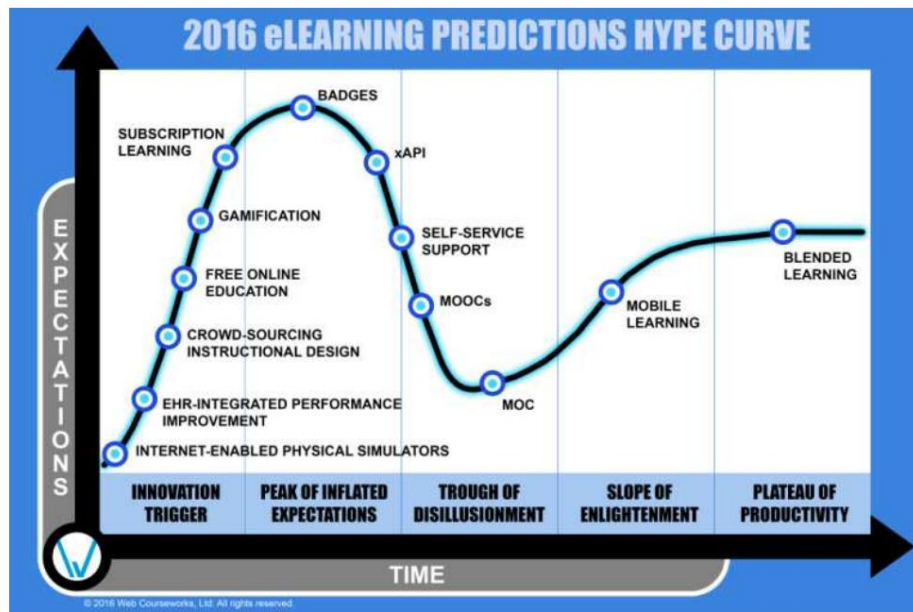


Figura 1. Curva de hype do e-learning [4]

O e-learning permite acessar materiais educacionais facilmente a qualquer hora e em qualquer lugar. Além disso, com as tecnologias de aprendizagem personalizada, a produtividade na educação para os grupos de alunos na estrutura heterogênea também está a aumentar. Hoje, o e-learning não se limita a sistemas assistidos por computador. Também é acessível a partir de dispositivos móveis. [5]. Assim, os alunos podem fazer cursos virtuais seja no computador pessoal ou em dispositivos móveis, em casa ou em um café. Essas elasticidades permitem que o aluno se sinta confortável. Esta situação levou ao aumento da eficiência e à facilitação do processo de aprendizagem.

Pesquisas recentes mostram que os estados emocionais e a motivação dos alunos influenciam direta ou indiretamente o processo de aprendizagem [6]. Isen [7] argumenta que um humor positivo não apenas nos faz sentir bem, mas também leva a tomadas de decisão mais precisas, maior criatividade e flexibilidade na resolução de problemas. Segundo Isen, o cérebro humano não é uma informação totalmente cognitiva. O cérebro humano é avaliado como um sistema que integra inseparavelmente funções emocionais e cognitivas. Os indivíduos precisam estar fisicamente, mentalmente, emocionalmente e socialmente preparados para serem capazes de compreender as informações facilmente [8]. Feidakis [9] apresentou uma revisão da consciência emocional no con

A declaração do problema. Um dos maiores problemas dos sistemas de e-learning é manter a motivação dos alunos nas salas de aula virtuais. Essa situação é mais fácil em salas de aula formais porque o educador está em contato presencial com os alunos no mesmo ambiente [10]. Nesse aspecto fica muito mais fácil observar seus estados emocionais e motivações.

Análise de estudos e publicações recentes. Vários estudos de reconhecimento facial têm sido utilizados para avaliar o estado emocional dos participantes em ambientes de e-learning. Ashwin et al. [11] propuseram um sistema de e-learning baseado em detecção facial multiusuário usando SVM com diferentes conjuntos de dados (LFW, FDDB e YFD). Al-Alwani et al. [12] realizaram extração de humor usando uma rede neural, que classifica expressões faciais de acordo com características faciais, a fim de melhorar as tendências de aprendizagem dos alunos em sistemas de e-learning. Krithika et al. [13] desenvolveram um SERS usando o padrão binário local (LBP) para reconhecimento e detecção facial. Ele encontra padrões emocionantes, perturbadores e comoventes e revela informações significativas para compreender o humor do aluno que estuda em um ambiente de e-learning. Recentemente, estudos de reconhecimento de emoções em tempo real foram encontrados no e-learning. Por exemplo, Magdin et al. [14] desenvolveram um software que avalia o estado emocional de

o usuário usando uma webcam. O sistema funciona em tempo real por meio de redes neurais. A precisão geral do seu software com base nas emoções solicitadas e nas emoções reconhecidas é de 78%. Como um estudo adaptativo de e-learning que atrai uma população estudantil diferente, um sistema de reconhecimento de emoções foi proposto para alunos com autismo de alto funcionamento [15].

O objetivo do estudo é desenvolver um novo Sistema de Reconhecimento de Emoções Faciais (FERS), que reconheça os estados emocionais e os níveis de motivação dos alunos em sistemas de e-learning do tipo videoconferência. Para criar um ambiente educacional mais interativo, este sistema transfere instantaneamente os estados emocionais dos alunos para o educador. Nosso estudo corrobora os estudos que permitem observar o nível de motivação tanto do indivíduo quanto da sala de aula virtual nos sistemas de e-learning.

2. ARQUITETURA DE SISTEMA PROPOSTA

Nesta seção, a infraestrutura de hardware e as etapas de desenvolvimento de software do sistema proposto são descritos.

2.1. Infraestrutura de hardware

Este trabalho é adequado para aplicações de e-learning através de videoconferência. Por este motivo, foram realizados trabalhos experimentais através do programa Skype. Uma vez iniciada a sala de aula virtual do programa Skype, as capturas de tela do computador do educador envolvendo imagens frontais dos participantes são gravadas em formato “.png” ou “.jpg” instantaneamente. Cada imagem gravada é lida instantaneamente e o processo de processamento da imagem é iniciado. Neste processo, a GPU é importante em termos do desempenho do sistema proposto [16].

Usamos um computador com placa gráfica Nvidia GeForce GTX 860M. O FERS proposto foi desenvolvido na plataforma Python. Python tem vários pacotes de software poderosos para processos de processamento de imagens (OpenCV, dlib, etc.) e aprendizado de máquina (scikit-learn, numpy, pandas, etc.).

2.2. Estágios de desenvolvimento de software

2.2.1. Detecção de rosto

A detecção de rosto é o primeiro passo do FERS. A detecção de rosto pode ser realizada em imagens e em vídeo em tempo real. O algoritmo Viola-Jones [17] é preferido na detecção facial em termos de operação em tempo real e detecção rápida. Existem seis emoções categorizadas (Felicidade, Medo, Tristeza, Raiva, Surpresa e Nojo) que são universalmente aceitas no FER [18].

2.2.2. Obtendo os marcos e atributos faciais

Os rostos humanos dão uma ideia sobre seu estado emocional. À medida que o humor emocional muda, também haverá mudanças nas seções do rosto. As bordas dessas seções são determinadas e seguidas por pontos de referência faciais. Neste estudo, um algoritmo de detecção de marcos faciais proposto por Sagonas et al. [19] foi usado. Sagonas executou esse algoritmo em diferentes conjuntos de dados faciais [20] – [23] e teve como objetivo obter um padrão na determinação de pontos de referência faciais.




Figura 2. Exibindo pontos de referência faciais nos rostos de vários participantes em videoconferências do Skype

Este algoritmo produz 68 pontos de referência faciais na face detectada, indicando as bordas das seções da face (Figura 2). Neste estudo, os novos atributos distintivos obtidos a partir desses marcos faciais (Figura 3).

<i><u>Attribute Description</u></i>	<i><u>Ratio</u></i>	<i><u>Name</u></i>
The ratio of face width to mouth width	d1/d2	a1
The ratio of mouth width to mouth openness	d2/d3	a2
The ratio of eye width to eye openness	d4/d5	a3
The ratio of eyebrow length to distance between two eyebrows	d6/d7	a4
The ratio of eyebrow length to distance between eye and eyebrow	d6/d8	a5
The ratio of the length of the nose to the distance between the nose and the upper lip	d9/d10	a6
The ratio of the distance between the extreme points of the eyebrows to the length of the nose	d11/d9	a7
The ratio of distance between two irises to mouth width	d12/d2	a8

Figura 3. Atributos distintivos extraídos das expressões faciais

2.2.3. Conjunto de dados de

treinamento O conjunto de dados de treinamento foi descrito em detalhes em nosso estudo anterior [24]. O conjunto de dados tem tamanho 11680x10 e é composto por atributos obtidos a partir das expressões faciais dos alunos. Uma seção deste conjunto de dados é mostrada na Figura 4.

a1	a2	a3	a4	a5	a6	a7	a8	gender	emotional_state
2,2565	3,1814	3,4315	1,9529	2,6196	2,9567	1,1655	3,1065	1	Happiness
2,2219	3,3773	3,4315	2,0676	2,6196	2,9567	1,1665	3,0018	0	Happiness
2,3032	2,4596	2,9872	1,9702	2,6798	2,208	1,2244	3,0376	0	Surprise
2,2494	2,6616	2,7613	2,5886	1,5455	1,7676	1,2773	3,2875	1	Fear
2,219	2,5633	2,754	2,5903	1,6172	1,7676	1,2489	3,2867	1	Fear
1,9155	2,1664	3,2888	3,7272	1,4998	2,4759	1,0962	3,0643	1	Disgust
1,9576	2,2183	3,2888	3,2062	1,6106	2,5466	1,1184	3,0643	1	Disgust
2,3079	4,9497	5,6874	3,1226	2,8932	3,6409	1,312	2,698	0	Anger
2,457	2,1148	5,6874	2,6519	2,9019	3,4933	1,4337	2,8067	0	Anger
2,4334	2,9872	5,3413	1,7897	2,8685	2,4703	1,2279	3,3539	0	Sadness
2,5714	2,1523	3,4	2,3637	2,4434	2,6138	1,4288	3,2292	0	Neutral
2,526	2,1926	3,0922	2,3403	2,4086	2,4641	1,4218	3,2551	0	Neutral
2,2589	3,1786	3,4315	2,0155	2,6542	2,9995	1,1665	3,1055	0	Happiness

Figura 4. Uma seção do conjunto de dados de treinamento

2.2.4. Reconhecimento de emoções

Cada instância no conjunto de dados de treinamento contém nove atributos (Figura 4). Oito deles são atributos faciais e o outro atributo é informação de gênero representada numericamente como "0" e "1" para "masculino" e "feminino". Essas instâncias são usadas tanto no processo de treinamento quanto no processo de teste de predição de classe emocional. O objetivo desta fase é prever a classe emocional de cada instância obtida após as fases de detecção de rosto e extração de características. Os desempenhos de previsão foram comparados usando quatro tipos diferentes de métodos de classificação para determinar as classes emocionais.

Support Vector Machine (SVM) provou que classificadores não lineares baseados em núcleo fornecem bons resultados em problemas práticos de aprendizado de máquina e mineração de dados [25]. O SVM determina a superfície limite entre as duas classes, maximiza a distância entre o conjunto de treinamento e os pontos mais próximos da superfície de discriminação.

O método de classificação k-vizinho mais próximo (kNN) é baseado na similaridade entre a amostra a ser classificada e as amostras da classe. As amostras de treinamento são definidas por qualidades numéricas ndimensionais. Cada amostra aponta para o espaço n-dimensional [26]. Desta forma, todas as amostras de treinamento são armazenadas em um espaço amostral n-dimensional. Esses exemplos de k-educação são os vizinhos mais próximos da amostra desconhecida A. A proximidade é encontrada calculando a distância euclidiana conforme dado na equação (1).

$$D(X, Y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (1)$$

Random Forest (RF) é um classificador feito por Breiman e Cutler, que consiste em múltiplas árvores produzidas a partir de amostras aleatórias de estados ou variáveis. Neste método, a árvore começa com um único nó que todos os dados formaram, e se todas as amostras pertencem à mesma classe, o nó termina como folha e o rótulo da classe é fornecido. Se as amostras não estiverem incluídas na mesma classe, as amostras são escolhidas para melhor se adequarem às classes [27].

O algoritmo Classification & Regression Trees (CART) possui uma estrutura que forma árvores de decisão binárias dividindo o cluster correspondente em dois subclusters mais homogêneos a cada etapa. A melhor variável independente é selecionada usando a impureza e

a variância na medida de variação. Aqui, o objetivo é produzir os subgrupos de dados mais homogêneos possíveis para a variável alvo [28].

2.2.5. Determinando o nível de motivação Nesta

seção, foram determinados os estados emocionais instantâneos e ponderados dos alunos em uma aula virtual. Desde o início da videoconferência, o estado emocional dos alunos foi transferido para o educador. O estado emocional da maioria dos alunos indica o clima emocional da aula virtual. Aqui, algumas das seis emoções universais são consideradas positivas e algumas delas negativas. Por exemplo; felicidade e surpresa são consideradas emoções positivas; tristeza, nojo, medo, raiva são emoções negativas. Os estados emocionais instantâneos dos alunos são exibidos com diferentes emojis (Figura 5).

O educador também consegue ver o nível de motivação geral da sala de aula virtual com o gráfico do nível de motivação.




Figura 5. Nível de motivação geral da sala de aula virtual

3. RESULTADOS E DISCUSSÃO

Um processo de teste em duas etapas foi realizado para determinar o melhor dos algoritmos de predição apresentados na Seção 2.2.4. Na primeira etapa, todo o conjunto de dados foi classificado estaticamente. Os resultados obtidos na primeira etapa são apresentados na Tabela 1.

tabela 1

Os resultados de classificação de algoritmos de aprendizado de máquina

Algoritmos testados	Precisão (%)
kNN	96,38
Floresta Aleatória	93,36
CARRINHO	89,11
SVM	97,15

As taxas de precisão foram classificadas como algoritmos CART, RF, kNN e SVM em ordem crescente. A razão para o maior desempenho dos algoritmos SVM e kNN é que as características são extraídas da distância euclidiana entre dois pontos faciais. Sabe-se que os algoritmos KNN e SVM são muito bem sucedidos na classificação de conjuntos de dados com tais valores esp

Na segunda etapa, a classe emocional das instâncias é prevista com algoritmos citados na Tabela 1. As classes emocionais são felicidade, surpresa, tristeza, raiva, nojo, medo e neutra. Eles são enumerados de 0 a 6, respectivamente. As instâncias cujas classes emocionais reais já são conhecidas foram selecionadas aleatoriamente de todo o conjunto de dados. Um total de 1.650 instâncias foram previstas separadamente e os resultados de previsão dos algoritmos foram registrados. A Figura 6 apresenta a classe emocional real e a previsão dos algoritmos.

Actual Class	Predicted by				Aula	Emoji
	kNN	SVM	R_forest	CART		
0	0	0	2	0	0	😊
0	2	0	2	0	1	😮
0	0	0	2	0	2	😞
0	0	4	4	0	3	😡
0	0	0	4	0	4	🤢
0	0	0	2	0	5	😱
0	0	0	0	0	6	😐
0	0	0	0	0		
0	0	0	0	0		
0	0	0	0	0		
0	0	0	0	0		
0	0	0	0	0		
0	0	0	0	0		
0	0	0	0	0		
0	0	0	0	0		

Figura 6. Classes emocionais previstas de instâncias

Conforme mostrado na Figura 6, diferentes resultados de previsão podem ser obtidos quando instâncias distintas são testadas com algoritmos diferentes. A precisão da previsão foi obtida calculando quantas previsões precisas foram feitas para cada algoritmo. A Tabela 2 fornece as precisões de previsão desses algoritmos.

mesa 2

Os resultados de previsão dos algoritmos

	kNN	RF	CARRINHO	SVM
Nº de Classe Real / Nº de Classificados Corretamente	1650/1574	1650/1534	1650/1585	1650/1621
Precisão (%)	95,39	92,97	96.06	98,24

Com o algoritmo SVM, apenas 29 das 1.650 amostras de dados diferentes foram estimadas incorretamente e um valor de alta precisão de 98,24% foi obtido. O algoritmo SVM com a função kernel RBF, que oferece o melhor desempenho como resultado dessas duas etapas, tem sido preferido para o processo de reconhecimento instantâneo de emoções.

4. CONCLUSÕES E PERSPECTIVAS PARA PESQUISAS ADICIONAIS

Neste estudo foi desenvolvido um FERS que envia ao educador os estados emocionais dos alunos da sala de aula virtual. Este sistema de apoio permite observar o nível de motivação tanto do indivíduo como de toda a sala de aula virtual nos sistemas de e-learning. Na fase experimental, o SVM foi escolhido para classificação do estado emocional porque proporcionou a melhor precisão de previsão. Concluindo, avaliar a emoção de um aluno na sala de aula virtual pode ajudar a melhorar a experiência de aprendizagem. O Skype é preferido como plataforma de teste porque é gratuito. Além disso, permite videoconferência multiusuário. No entanto, este trabalho também pode ser adaptado para outros softwares de videoconferência no futuro. À medida que a câmera se torna equipamento padrão para computadores pessoais, a usabilidade deste sistema aumenta.

RECONHECIMENTO

Este estudo é realizado no âmbito do M.Sc. Projeto de Tese (16/129). Os autores agradecem o apoio do Escritório de Projetos de Pesquisa Científica da Universidade Mugla Sitki Kocman.

REFERÊNCIAS

- [1] A. Nagy, "O Impacto do E-Learning", em: PA Bruck, A. Buchholz, Z. Karssen, A. Zerfass, (Eds). *E-Content: Tecnologias e Perspectivas para o Mercado Europeu*. Berlim: Springer-Verlag, pp. 79–96, 2005. (em inglês)
- [2] MD Lytras e A. Pouloudi, "E-Learning: Just a Waste Of Time", na *Sétima Conferência das Américas sobre Sistemas de Informação*, América, 2001. (em inglês)
- [3] S. Carliner e P. Shank, *The e-Learning Handbook: Past Promises, Present Challenges*, John Wiley & Sons, 2008. (em inglês)
- [4] A. Hicken, "Previsões da curva de hype do Elearning para 2016", 23.12.2015. [On-line]. Disponível: <http://www.webcourseworks.com/2016-elearning-hype-curve-predictions/>. [Acessado em 06.07.2017]. (Em inglês)
- [5] KI Benta, C. Marcel e FM Vaida, "Uma ferramenta de monitoramento afetivo multimodal para aprendizagem móvel," *Instituto de engenheiros elétricos e eletrônicos da sociedade da computação*, pp. 34-38, 2015. (em inglês)
- [6] M. Lewis, H. Jones e F. Barrett, *Handbook Of Emotions*, Nova York, 2000. (em inglês)
- [7] AM Isen, "Positive Affect Influences Decision Making", em *Manual de emoções*, M. Lewis e J. Haviland, Eds., Guilford, Nova York, The Guilford Press, p. 720, 2000. (em inglês)
- [8] N. Razon, "Okul Başarısını Etkileyen Faktörler", [Online]. Disponível: <http://www.ekipnormarazon.com/makale-detay/okul-basarisini-etkileyen-faktorler> [Acessado em 06.07.2017]. (em turco)
- [9] M. Feidakis, "A Review of Emotion-Aware Systems for e-Learning in Virtual Environments", em *Avaliação Formativa, Análise de Dados de Aprendizagem e Gamificação*, S. Caballé e R. Clarisó, Eds., *Academic Press*, Boston, p.217-242, 2016. (em inglês)
- [10] WK Horton, *Leading e-learning*, American Society for Training and Development, 2001. (em inglês)
- [11] TS Ashwin, J. Jose, G. Raghu e GR Reddy, "An E-learning System With Multifacial Emotion Recognition Using Supervised Machine Learning", na *Sétima Conferência Internacional sobre Tecnologia para Educação do IEEE*, 2015. (em inglês)
- [12] A. Al-Awni, "Extração de humor usando recursos faciais para melhorar as curvas de aprendizagem de alunos em sistemas de e-learning", *International Journal of Advanced Computer Science and Applications*, vol. 7, não. 11, pp. 444-453, 2016. (em inglês)
- [13] LB Krithika e GG Lakshmi Priya, "Sistema de reconhecimento de emoções do aluno (SERS) para e-learning," *Procedia Ciência da Computação*, p. 767 – 776, 2016. (em inglês)
- [14] M. Magdin, M. Turcani e L. Hudec, "Avaliando o estado emocional de um usuário usando uma webcam," *Edição especial sobre fundamentos de inteligência artificial*, vol. 4, não. 1, pp. 61-68, 2016. (em inglês)

- [15] CH Chu, WJ Tsai, MJ Liao e YM Chen, "Reconhecimento de emo  es faciais com detec   o de transi   o para alunos com autismo de alto funcionamento em e-learning adaptativo", *Soft Computing*, pp. (Ingl  s)
- [16] AW Wai, SM Tahir e YC Chang, "GPU Acceleration of Real Time Viola-Jones Face Detection", na Confer  ncia Internacional IEEE sobre Sistema de Controle, Computa  o e Engenharia, 2015. (em ingl  s)
- [17] PA Viola e MJ Jones, "Detec   o r  pida de objetos usando uma cascata refor  ada", *IEEE Computer Society Confer  ncia sobre Vis  o Computacional e Reconhecimento de Padr  es CVPR*, pp. 511-518, 2001. (em ingl  s)
- [18] P. Ekman e D. Keltner, "Express  o Facial Universal da Emo   o: Uma Velha Controv  rsia e Nova Resultados," *Nonverbal Behav.*, vol. 21, no. 1, pp. 3-21, 1997. (em ingl  s)
- [19] C. Sagonas, G. Tzimiropoulos, S. Zafeiriou e M. Pantic, "Desafio 300 Faces in-the-Wild: O primeiro desafio de localiza   o de marco facial", na Confer  ncia Internacional IEEE sobre Vis  o Computacional, 2013. (em Ingl  s)
- [20] PN Belhumeur, DW Jacobs, DJ Kriegman e N. Kumar, "Localizando partes de rostos usando um consenso de exemplares", na Confer  ncia Internacional IEEE sobre Vis  o Computacional e Reconhecimento de Padr  es (CVPR), 2011. (em ingl  s)
- [21] V. Le, J. Brandt, L. Bourdev e TS Huang, "Interactive Facial Feature Localization", na Confer  ncia Europeia sobre Vis  o Computacional, 2012. (em ingl  s)
- [22] X. Zhu e D. Ramanan, "Detec   o de rosto, estimativa de pose e localiza   o de pontos de refer  ncia na natureza", na Confer  ncia IEEE sobre Vis  o Computacional e Reconhecimento de Padr  es (CVPR), 2012. (em ingl  s)
- [23] M. Kostinger, P. Wohlhart, PM Roth e H. Bischof, "Marcos faciais anotados na natureza: um banco de dados do mundo real em grande escala para localiza   o de marcos faciais", na Confer  ncia Internacional IEEE sobre Workshops de Vis  o Computacional (Workshops ICCV) , 2011. (em ingl  s)
- [24] U. Ayvaz e H. G  r  ler, "A detec   o de express  o emocional em rela   o aos usu  rios de computador", *Revista Internacional de Tecnolog  as Inform  ticas*, vol. 10, n  o. 2, pp. 231-239, 2017. (em turco)
- [25] VN Vapnik, "Uma vis  o geral da teoria da aprendizagem estat  stica", *transa    es IEEE em redes neurais* 10, , vol. n  o. 5, pp. 988-999, 1999. (em ingl  s)
- [26] X. Wu, V. Kumar, JR Quinlan, J. Ghosh, Q. Yang e H. Motoda, "10 principais algoritmos em minera   o de dados", *Sistemas de conhecimento e informa   o*, vol. 14, n  o. 1, pp. 1-37, 2008. (em ingl  s)
- [27] A. Liaw e M. Wiener, "Classifica   o e regress  o por floresta aleat  ria", *R news*, vol. 2, n  o. 3, p  g. 18-22, 2002. (em ingl  s)
- [28] D. Steinberg e P. Colla, "CART:   rvore de classifica   o e regress  o", em *The Top Ten Algorithms in Data Mining*, X. Wu e V. Kumar, Eds., Chapman & Hall/CRC, 2009, p. 179. (em ingl  s)

O texto do artigo foi aceito pela Equipe Editorial em 06.07.2017

                                                        

                    

          

                       (                           ),                             ,                   na engenharia do sistema

           Mu  la S  tk  Ko  man,      ,          

Ugur.ayvaz@mu.edu.tr

              

PhD em Electron    e                   ,                                               

            Mu  la S  tk  Ko  man,      ,           ORCID ID

0000-0003-1855-1882 Hguruler@mu.edu.tr

Me                  

                        (                           ),        ,

                                  

           Mu  la S  tk  Ko  man,      ,          

Mehmetosmandevrim@posta.mu.edu.tr

Anota   o.                                                                    

Ao conectar-se    Internet, o sistema el  trico est   conectado. Novos

para voc  , qual    o eletrodom  stico que voc   precisa para fornecer informa    es de entrega,           

Isso   muito importante para mim, pois voc  n o precisa de um empr stimo formal
 sistema de informa  es,  yy   '          '                                             
          para                                             sistema el trico.              
                                                                '                  
 foi uma situa  o emocional em um momento de uma semana em que voc  est  trabalhando. Ent o,             
 voc  pode usar a classe virtual e o sistema
 Estabele a um formato formal e um servi o interativo. No sistema de seguran a
 Crie um algoritmo cl ssico para viver uma situa  o emocional, e
 Voc  pode usar o algoritmo kNN para SVM.

            :                   ;                          ;     '            ; m quina autom tica; classe virtual.

                                                 
                            

          
                          (                              ),                       ,
                        engenharia de haste
 Universidade Mu la S tk  Ko man, Mugla, Turquia
 Ugur.ayvaz@mu.edu.tr

              
 PhD em Eletrodom sticos e Computadores, sistema de informa  es de doutorado
 engenharia
 Universidade Mu la S tk  Ko man, Mugla, Turquia
 ORCID ID 0000-0003-1855-1882
 Hguruler@mu.edu.tr

Me                
                          (                              ),
       ,                                   
 Universidade Mu la S tk  Ko man, Mugla, Turquia
 Mehmetosmandevrim@posta.mu.edu.tr

Anota  o. Poss vel uso de computador pessoal e proposta
                             ,                                            . N o
 h  necessidade de que o eletrodom stico esteja dispon vel para uso
 informa  es de fornecimento, per odos de tempo e condi  es de uso formais
         ,                                                                
                        . Neste caso eu estou instalado em um gigabyte
 sistema de informa  es, que fornece informa  es e tecnologia de computa  o
 A m quina   adequada para opera  o de sistema el trico visual e interativo. Sistema de
 informa  es adicionais para obter recursos financeiros
 e isso permitir  que voc  se preocupe com sua situa  o emocional no momento do dia
                      . Ent o, vamos nos preparar para isso.
 obtenha uma classe emocional virtual e um sistema formalizado
         ,                        . No sistema preliminar, n o h  necessidade
 algoritmos cl ssicos para uma grande constru  o emocional, e
 Voc  pode usar o recurso de transfer ncia de dados com os algoritmos KNN e SVM.

Chave de fenda: opera  o el trica;                          ; computador
 v deo; opera  o autom tica; classe virtual.



Este trabalho est  licenciado sob a Licen a Creative Commons Atribui  o-N oComercial-Compartilhamento pela mesma Licen a 4.0 Internacional.