

# Extração de humor usando características faciais para melhorar Curvas de Aprendizagem de Alunos em Sistemas de E-Learning

Abdulkareem Al-Alwani

Departamento de Ciência da Computação e Engenharia  
Yanbu University College, Royal Commission Institute e faculdades  
Ilanbu, Arábia Saudita

**Resumo**—O interesse e envolvimento dos alunos durante as aulas é fundamental para a compreensão dos conceitos e melhora significativamente o desempenho acadêmico dos alunos. A supervisão direta das palestras pelos instrutores é a principal razão por trás a atenção dos alunos nas aulas. Ainda assim, existe uma percentagem suficiente de alunos que mesmo sob supervisão direta tendem a perder a concentração. Considerando o ambiente de e-learning, este problema é agravado pela ausência de qualquer supervisão humana. Isto exige uma abordagem para avaliar e identificar lapsos de atenção de um aluno numa sessão de e-learning. Este estudo é realizado para melhorar o envolvimento dos alunos em plataformas de e-learning, usando suas características faciais para extrair padrões de humor. Analisar o humor com base nos estados emocionais de um aluno durante uma aula on-line pode fornecer resultados interessantes que podem ser facilmente usados para melhorar a eficácia da entrega de conteúdo em uma plataforma de e-learning. Uma pesquisa é realizada entre os instrutores envolvidos no e-learning para identificar as características faciais mais prováveis que representam as expressões faciais ou padrões de humor de um aluno. Uma abordagem de rede neural é usada para treinar o sistema usando conjuntos de recursos faciais para prever expressões faciais específicas. Além disso, também é proposto um algoritmo baseado em associação de dados especificamente para extrair informações sobre estados emocionais, correlacionando múltiplos conjuntos de características faciais. Esta estrutura mostrou resultados promissores em estimular o interesse dos alunos, variando o conteúdo a ser entregue. Diferentes combinações de expressões faciais inter-relacionadas para períodos de tempo específicos foram usadas para estimar padrões de humor e subsequentemente o nível de envolvimento de um aluno em um ambiente de e-learning. Os resultados alcançados durante o curso da pesquisa mostraram que os padrões de humor de um aluno fornecem uma boa correlação com seu interesse ou envolvimento durante aulas on-line e podem ser usados para variar o conteúdo para melhorar o envolvimento dos alunos no sistema de e-learning. Mais expressões faciais e categorias de humor podem ser incluídas para diversificar a aplicação do método proposto.

**Palavras-chave**—*Extração de humor; Características faciais; Reconhecimento facial; Educação online; E-Learning; Estado de atenção; Aprendendo estilos*

## I. INTRODUÇÃO

O principal problema surge no E-Learning, pois não há um supervisor que avalie como os alunos estão respondendo física e emocionalmente ao conteúdo ministrado. Normalmente, quando os alunos fazem algum curso online, eles podem perder a concentração e o foco, resultando em um baixo desempenho acadêmico. Lidar com esta questão pode avançar muito no processo de e-learning, uma vez que o interesse de cada aluno pode ser avaliado e as melhorias necessárias podem ser feitas no conteúdo para envolver o usuário durante a aula on-line. A fim de

Para contornar o problema da observação do aluno em uma plataforma de e-learning, esta pesquisa é realizada com o objetivo de analisar a relação entre as expressões faciais de um aluno matriculado em um sistema de e-learning e as formas de melhorar a atitude de aprendizagem desses alunos utilizando informações extraídas desses recursos.

O e-learning é um meio para transmitir educação a qualquer hora e em qualquer lugar e, devido aos recentes avanços na tecnologia da informação, os sistemas de educação on-line podem ser considerados uma bênção e um importante ativo da tecnologia da informação. A transferência de conhecimento através de ferramentas de tecnologia da informação requer planejamento e execução cuidadosos, pois o ambiente de aprendizagem fornecido ao aluno durante o e-learning oferece uma visão complexa sobre a curva de aprendizagem do aluno. Para melhorar a experiência de e-learning, o processo de aprendizagem torna-se imperativo, pois governa principalmente quanto e quão bem um aluno pode absorver conhecimento durante aulas on-line [1]. Entrega de conteúdo, exames e feedback do aluno são medidas importantes que têm um efeito direto na curva de aprendizagem dos alunos, bem como nos objetivos do e-learning. Ainda assim, o período de tempo necessário para relacionar e observar todas estas medidas deve ser suficientemente longo para dar conta de todos os detalhes possíveis [2].

Essas medidas também são as mesmas utilizadas no ensino tradicional ou no campus, onde o professor tem interação direta com os alunos. Inicialmente, os computadores e a tecnologia da informação foram usados como ferramentas para improvisar a aprendizagem. Este conceito evoluiu posteriormente para sistemas de e-learning completos. As universidades começaram agora a oferecer cursos online e desenvolveram plataformas de e-learning que atendem às necessidades de quase todos os estudantes. O e-learning permitiu que estudantes fora do campus fossem educados em casa ou simplesmente em qualquer lugar do mundo.

A entrega de conhecimento através do e-learning oferece inúmeras vantagens, mas a maioria de seus recursos só pode ser plenamente utilizada se o envolvimento e o interesse do aluno permanecerem contínuos ao longo do curso da educação on-line [3]. uma preferência pessoal por adquirir conhecimento no seu próprio tempo e ritmo, o que permite que pessoas de todas as esferas da vida tenham a oportunidade de aprender e educar-se sem quaisquer restrições de tempo e espaço.

Com esta evolução nas tecnologias de e-learning e o aumento do número de alunos, os requisitos para melhorar a experiência de educação online são cada vez mais exigentes. Entende-se que estudos mais aprofundados são

necessário para determinar as variáveis que podem realmente afetar o ambiente educacional online de forma positiva [4].

O feedback natural sobre o conteúdo que está sendo entregue pode ser obtido automaticamente dos alunos, usando suas expressões faciais como uma ferramenta para medir o interesse do conteúdo e o envolvimento do aluno na aula on-line [5]. As expressões faciais podem fornecer informações críticas sobre o interesse do aluno e participação na aprendizagem educacional online. Os rostos fornecem informações detalhadas sobre o estado de espírito, humor e também estado emocional de um indivíduo. Estudos ao longo da história mostraram que as expressões faciais são a principal representação das emoções humanas. As expressões faciais podem ser consideradas como a principal fonte de informação, depois das palavras, para estimar os pensamentos e o estado de espírito de um indivíduo [6].

O reconhecimento facial tem provado ser uma ferramenta importante na automatização da tutoria, pois auxilia na melhoria dos resultados de aprendizagem dos alunos, bem como no desenvolvimento da experiência de aprendizagem [7][8]. No final, isso leva a uma melhoria no envolvimento do aluno no ambiente de aprendizagem.

Esta pesquisa visa melhorar os resultados de aprendizagem dos alunos durante o estudo de cursos on-line. Isso pode ser considerado como a análise da interação em tempo real entre o aluno e a máquina e a avaliação do envolvimento do aluno durante a sessão de E-learning, que está em constante mudança ao longo do curso. tempo. Esta variável de engajamento pode ser plotada em função do tempo e pode ser considerada como uma função do tempo. Esta função de engajamento será chamada de curva de aprendizagem do aluno no restante deste artigo, pois sua variação em função do tempo afeta diretamente a aptidão e o interesse de aprendizagem dos alunos.

A afirmação básica feita neste estudo é que a falta de envolvimento/engajamento dos alunos durante as aulas on-line devido à falta da presença física dos professores é o principal fator que impede os alunos de alcançar os resultados de aprendizagem dos cursos on-line. Isto deve-se em grande parte à ausência de qualquer supervisão directa do professor sobre o processo de aprendizagem dos alunos que, em tal contexto de aprendizagem, podem distrair-se de muitas maneiras do que estão a estudar, sem que haja ninguém presente para os supervisionar naquilo que estão a aprender.

Um aluno que estuda utilizando recursos online não pode participar de uma comunicação verbal, então os principais atributos que podem ser observados para determinar o humor e a atitude de um aluno são suas características faciais e linguagem corporal [9].

O principal motivo por trás deste estudo foi desenvolver uma metodologia para identificar os principais padrões de humor com alta probabilidade em um ambiente de e-learning. Os dados se acumulam continuamente quando os dados visuais são registrados em tempo real. O espaço amostral se torna grande e exige mais poder computacional. Para abordar esta questão específica, o objetivo secundário desta pesquisa foi integrar uma técnica de mineração sequencial que possa identificar padrões de humor com alta probabilidade. As regras foram extraídas usando o algoritmo Apriori para reduzir o espaço amostral de humor, marcando padrões de características faciais frequentes em cinco categorias de humor predefinidas.

Nas seções subsequentes, a literatura é revisada, seguida por uma discussão da metodologia de pesquisa para aplicação do

técnica proposta e ao final os resultados são apresentados com considerações finais.

## II. REVISÃO DA LITERATURA

O e-learning apresenta muitas oportunidades de aprendizagem para pessoas que não podem frequentar escolas, faculdades ou universidades regulares. Dada a importância do e-learning nesta era da informação, muita investigação tem sido realizada para melhorar o desempenho e a adaptabilidade do e-learning. Esta secção apresentará estudos passados, presentes e prospectivos realizados com o objectivo de melhorar o ecossistema de e-learning.

As metodologias de ensino on-line e de e-learning transcenderam a novos níveis após o boom da era da tecnologia da informação. Como resultado, a qualidade da educação e o número de alunos online aumentaram substancialmente. Ainda assim, a forma modernizada de e-learning cria problemas que afetam a curva de aprendizagem do aluno devido à indisponibilidade de qualquer supervisão direta [10].

Um instrutor pode fornecer algumas informações sobre a satisfação do aluno durante as aulas [11], portanto, o envolvimento do aluno nas aulas tem correlação direta com a aptidão profissional do instrutor [9]. A supervisão direta não só facilita o aprendizado, mas também mantém o aluno sincronizado com os objetivos do curso devido à comunicação instantânea com o instrutor a qualquer momento durante a aula. A falta de comunicação mostrou que os alunos afetados podem experimentar altos níveis de frustração [11].

Como o ensino supervisionado é muito crítico para as curvas de aprendizagem dos alunos, os cursos online apresentam um conjunto diferente de desafios para instrutores e alunos. Os alunos on-line podem nunca visitar um campus físico e podem ter dificuldade em estabelecer relacionamentos com professores e colegas.

Os pesquisadores que estudam alunos a distância devem compreender e levar em conta essas diferenças ao investigar a satisfação do aluno [12], mencionaram três tipos importantes de interação em cursos de aprendizagem on-line: (a) conteúdo do aluno, (b) aluno-instrutor e (c) aluno-aluno. Ele enfatizou que os instrutores devem facilitar ao máximo todos os tipos de interações que estimulem a atenção em seus cursos on-line.

O e-learning requer o uso de vídeo, áudio e texto para simular a aula tradicional e o ambiente de aprendizagem o mais próximo possível. Os ambientes de e-learning podem ser usados para diversos fins educacionais. As tendências modernas indicam que a educação baseada no e-learning se equipará aos métodos de ensino tradicionais num futuro próximo. Em um ambiente de e-learning, professor e aluno não estão em interação direta e o conteúdo é fornecido pelo instrutor por meio de plataformas on-line, utilizando interfaces multimídia e de software.

Como não há meios de comunicação instantânea, a máquina só pode entender o que registra usando interfaces homem-máquina padrão. Como não existe comunicação verbal entre o aluno e a plataforma de e-learning, as expressões faciais são o único meio que pode fornecer informações concretas sobre o humor e envolvimento do aluno durante a aula [13]. Por exemplo, quando os alunos mostram expressões confusas, um dos padrões de humor comuns pode ser uma ou uma combinação das seguintes características faciais, ou seja, sobrancelhas

abaixados ou unidos, rugas verticais ou horizontais na testa e contato visual inconsistente, etc. Para entender se o aluno está entendendo o que está sendo entregue, o professor deve sentir os indicadores não-verbais sutis exibidos pelas expressões dos alunos [14].

As características faciais e sua relevância para as emoções foram rigorosamente investigadas por Ekman et. al [26][27][28][29] em diversas publicações e seu trabalho é considerado uma das contribuições mais significativas para a análise emocional baseada em atributos faciais. O sistema de codificação de atuação facial pode fornecer informações sobre reações emocionais faciais instantâneas, mas ainda assim a necessidade de determinar um humor completo com base em várias unidades de ação, pois elas variam de pessoa para pessoa e de situação para situação.

As características faciais (testa, olhos, nariz, boca, etc.) são os atributos fundamentais amplamente utilizados em sistemas de reconhecimento facial, pois seus movimentos ajudam a determinar a construção da expressão de um rosto humano [15].

O reconhecimento facial pode ser usado com eficiência para identificar e categorizar expressões faciais em tempo real. Algoritmos de aprendizado de máquina também foram empregados para reconhecimento facial para aumentar a precisão e o tempo de detecção [16]. As expressões faciais são basicamente impulsos emocionais traduzidos em movimentos musculares físicos, como franzir a testa, levantar as sobrancelhas ou curvar os lábios. Os autores em [17] apresentaram as perspectivas benéficas do uso de métodos inteligentes para extrair expressões faciais para melhorar a velocidade de processamento da análise de imagens. Bancos de dados de expressões faciais foram preenchidos em vários estudos para desenvolver algoritmos interessantes para diversas aplicações.

O estudo de reconhecimento de emoções pode ser amplamente categorizado em três etapas: detecção de rosto, extração de características faciais e classificação de emoções. Pesquisa detalhada foi realizada em cada um deles. Estas três categorias estão preocupadas com o contexto central relativo à questão do reconhecimento de emoções faciais.

Numa imagem, detectar a presença de um rosto humano é uma tarefa complexa devido às possíveis diferenças atribuídas a diferentes rostos. Os variados atributos físicos de um rosto são a principal causa dessa variação. As emoções que são a combinação de unidades de ação facial [31] em um rosto humano também afetam a aparência facial.

As redes neurais podem ser usadas ativamente para classificar a orientação de um aluno em categorias predeterminadas, que podem ser associadas usando o algoritmo Apriori para permitir a intervenção HMI em tempo real para melhorar o envolvimento. O objetivo era avaliar em tempo real se os sistemas de e-learning podem ser improvisados para reconhecer as expressões faciais e o estado de atenção de um aluno usando algoritmos de classificação e associação de dados. Esses sistemas podem então ser usados para melhorar a entrega de conteúdo de plataformas de e-learning por meio da extração de humor em tempo real. Materiais e atividades de aprendizagem apropriados para um aluno podem ser incorporados para alterar seu estado de humor durante a atividade de e-learning.

A detecção de rosto pode ser amplamente classificada em quatro categorias: abordagem baseada em conhecimento, invariante de recursos

abordagem, abordagem baseada em modelo e abordagem baseada em aparência [33] [34] [35] [36].

A abordagem baseada na aparência mapeia o rosto humano em termos de intensidades de pixel. Como apenas padrões faciais são usados em seu processo de treinamento, a eficiência não é boa. Até o tempo necessário é longo, pois o número de padrões que precisam ser testados é grande.

Descobriu-se que uma rede neural é bastante eficaz na captura de padrões faciais complexos a partir de imagens faciais. Ambas as abordagens de aprendizagem supervisionada e não supervisionada são usadas para treinar a rede neural. Como é questionável encontrar um conjunto de dados de treinamento suficiente, redes neurais não supervisionadas são mais preferíveis. Além de redes neurais, máquinas de vetores de suporte (SVM) [37], eigenfaces, abordagens baseadas em distribuição, classificadores Nave Bayes, modelos ocultos de Markov (HMM) [38] e abordagens teóricas de informação também podem ser usadas para detecção de rosto em sistemas baseados em aparência. abordagem [33][34][35][36]. Em vez de minimizar o erro de treinamento como nas redes neurais, o SVM opera minimizando o limite superior do limite do erro de generalização em vez de minimizar o erro de treinamento como nas redes neurais. Eigen enfrenta usa Eigen

decomposição do espaço e provou ser um método de aprendizagem visual preciso. O classificador Nave Bayes é mais eficiente na estimativa das funções de densidade condicional em sub-regiões faciais. O HMM difere das abordagens baseadas em modelo e na aparência, pois não requer o alinhamento exato usado nestas abordagens, em vez disso, o HMM constitui um padrão de face como uma série de vetores de observação.

O envolvimento do aluno no e-learning baseia-se diretamente em como ele pode se engajar para focar e ouvir o conteúdo que está sendo ministrado. Expressões faciais em instantes curtos podem ser enganosas e uma análise baseada em períodos de tempo para determinar estados emocionais pode fornecer resultados interessantes. Por exemplo, confusão e frustração foram estudadas usando padrões temporais e baseados em ordem usando dados de afeto contínuo [30]. Um estudo semelhante foi realizado por Craig et al [32], que também incluiu o tédio. Os autores relataram que a confusão está associada a movimentos indiretos de diálogo do tutor e feedback negativo do tutor.

Da mesma forma, descobriu-se que a frustração está associada ao feedback negativo do tutor, e o tédio não parece ser detectável no conjunto de três recursos de diálogo [32]. O tempo de um estado emocional também pode desempenhar um papel importante na tutoria automatizada, conforme relatado pelos autores em [31]. Este estudo investigou a relação entre afeto e aprendizagem. No entanto, a identificação dos locais exatos onde a emoção ocorreu durante o processo de aprendizagem não foi abordada, limitando a eficácia do sistema Auto Tutor.

### III. OBJETIVOS DE PESQUISA

Uma troca coerente de informações entre o aluno e a máquina é fundamental para um E-learning eficaz e baseia-se na curva de aprendizagem do aluno. Os objetivos da pesquisa neste estudo foram formulados para desenvolver uma técnica prática para compreender o interesse do aluno durante a sessão de E-learning. O interesse do aluno pode, assim, ser aprimorado com técnicas de envolvimento de vídeo. Os objetivos da pesquisa para atingir este objetivo são listados a seguir:

O primeiro objetivo foi investigar se as expressões faciais são o meio mais pertinente de expressão não verbal durante o e-learning e podem, por sua vez, ajudar o sistema de e-learning a identificar o interesse e o nível de compreensão dos alunos.

O segundo objetivo foi listar as características faciais mais comuns que descrevem o envolvimento de um aluno em uma palestra. Uma lista de 54 características foi compilada e usada em uma pesquisa para identificar as características faciais mais pertinentes para descrever a expressão dos alunos.

O terceiro objetivo foi desenvolver uma metodologia para relacionar características faciais para compreender as expressões de um aluno durante diversos estados emocionais descrevendo seu envolvimento na palestra com alta probabilidade em tempo real.

A próxima seção consiste na metodologia buscada para identificar características faciais importantes e apresentará detalhes sobre como as características faciais registradas em determinados intervalos de tempo podem fornecer informações suficientes sobre o humor de um aluno em tempo real com redução do poder computacional e do espaço amostral.

#### 4. METODOLOGIA DE PESQUISA

A metodologia de pesquisa adotada nesta pesquisa foi conduzida em fases. Primeiro, foi realizada uma pesquisa entre instrutores envolvidos em e-learning para investigar e identificar as características faciais mais prováveis que representam as expressões faciais e, ao longo do tempo, os padrões de humor de um aluno. Uma abordagem de rede neural é então usada para treinar o sistema usando conjuntos de recursos faciais para prever expressões faciais específicas. O algoritmo baseado em associação de dados foi selecionado na abordagem proposta para extrair informações sobre estados emocionais, correlacionando vários conjuntos de características faciais usando níveis de suporte e confiança. Isso foi feito para melhorar o agrupamento dos conjuntos de dados relevantes. A metodologia foi projetada para analisar o interesse do aluno, variando o conteúdo que está sendo entregue. Diferentes combinações de expressões faciais inter-relacionadas para períodos de tempo específicos foram usadas para estimar padrões de humor e subsequentemente o nível de envolvimento de um aluno em um ambiente de e-learning.

Um conjunto de dados treinados de características faciais que representem o estado emocional do aluno é o principal requisito para avaliar o envolvimento de um aluno em um ambiente de e-learning. Os dados devem ser coletados primeiro, correlacionados com indicadores emocionais e depois reutilizados como dados de treinamento para extrair diferentes expressões que descrevem características faciais. O algoritmo de associação de dados é aplicado para relacionar características em expressão ao longo de um período de tempo para descobrir padrões de humor negativos de um aluno durante uma aula online. A metodologia aqui apresentada para prosseguir os objetivos acima referidos consiste em três grandes fases, que são as seguintes:

##### A. Categorização de características faciais usando um instrumento de pesquisa:

Antes de embarcar em uma investigação detalhada sobre a eficácia da observação de características faciais para avaliar o interesse do aluno durante uma aula on-line. Uma pesquisa é realizada para avaliar se a análise de características faciais é o meio mais pertinente de compreender o comportamento de um aluno durante o e-learning. Em segundo lugar, o inquérito registou observações de acadêmicos

sobre quais características faciais descrevem parcialmente o humor ou estado emocional de um aluno.

A fim de construir uma linha de base para as características faciais, foi realizado um inquérito no ano lectivo de 2014/2015 e 198 acadêmicos de várias universidades foram contactados para obter a sua resposta. Foram abordados especialistas em ensino on-line com no mínimo 2 anos de experiência de ensino em nível pós-secundário.

A pesquisa foi encaminhada com uma breve explicação dos objetivos da pesquisa com duas questões do instrumento que foram,

- O processo de medição do grau de envolvimento/envolvimento dos alunos durante o estudo dos cursos on-line ajudará os alunos a se concentrarem mais e, como resultado, a melhorar os resultados da aprendizagem? Quais expressões faciais você acha que são mais óbvias e recorrentes nas palestras?
- Liste as características faciais mais pertinentes para olhos, sobrancelhas, lábios e cabeça que constituem as expressões faciais do aluno, representando seu estado de espírito e envolvimento durante uma aula.

##### B. Treinamento e classificação de conjunto de dados de características faciais usando redes neurais:

Algoritmos de classificação fazem uso de técnicas de aprendizagem supervisionada para prever a classe de dados anteriormente não observados, usando um modelo de treinamento a partir de dados existentes [18]. Uma forma eficiente de definir um modelo de classificação é caracterizá-lo como um conjunto de regras de classificação abrangentes para fornecer relevância e precisão, simultaneamente. Um extenso conjunto de dados "Cohn-Kanade" foi selecionado para treinamento e classificação do nosso modelo de rede neural.

O banco de dados de expressões faciais codificado pela AU Cohn-Kanade [19] está disponível para fins de pesquisa on-line e é usado na análise de imagens faciais e para estudos perceptivos. Este banco de dados consiste em 486 sequências de 97 faces. Cada sequência começa com uma expressão neutra, levando gradualmente ao pico




Figura 1. Atributos de distância ajudando na medição de características faciais

expressão. Este banco de dados fornece uma base sólida para nossos modelo NN treinado, agilizando o processo de reconhecimento facial.

A coleta de recursos pode ser realizada usando algoritmos de extração de recursos apresentados na literatura. Reconhecimento e

a interpretação do humor ou atitude de aprendizagem de um aluno é realizada através da análise das características faciais durante a aula. Redes neurais são usadas para treinar nosso sistema no banco de dados de expressões faciais "Cohn-Kanade" e as mesmas foram usadas para identificar o estado de envolvimento de um aluno durante uma palestra online. As características faciais foram caracterizadas em quatro categorias principais com base na resposta da pesquisa: olhos, sobrancelhas, lábios, cabeça (incl. mão/dedos no rosto).

Um algoritmo NN de função de base radial [20] que foi usado neste estudo para classificar expressões faciais com base em características faciais (Tabela 1). A Figura 1 mostra os pontos de distância para olhos, sobrancelhas e lábios que foram utilizados para definir características faciais para o treinamento do algoritmo NN. Qualquer mudança nas métricas de distância aponta para uma determinada instância de característica facial e a combinação dessas características faciais pode ser usada para classificar as cinco expressões faciais.

Como a distância fornece certos limites para tomar decisões relacionadas às expressões faciais, esses limites podem ser usados para classificar padrões desconhecidos [25]. A Figura 2 mostra o modelo de decisão de nível superior de NN usado em nosso modelo proposto para classificação de características faciais.

Nesta figura são mostrados os pixels e combinações de dois atributos de distância que fornecem informações sobre a posição da sobrancelha em relação ao olho. A matriz mostrada aqui pode ser usada para representar graficamente um recurso se D1 e D2 forem plotados em um gráfico 2-D. O modelo de classificação proposto já está treinado para identificar a afinidade da região pertencente aos valores D1 e D2 adquiridos, e correlaciona os valores D1 e D2 a um determinado recurso, ou seja, neste caso o recurso „21” baseado no treinamento anterior dados. Portanto é necessário treinar o modelo proposto com uma base de dados maior para melhorar a probabilidade de detecção de uma determinada característica.

### C. Extração de humor usando características faciais

A Mineração Associativa de Dados é considerada uma importante técnica de mineração de dados e tem sido extensivamente pesquisada e utilizada para mineração de dados por pesquisadores. A Associação de Dados ajuda na mineração de regras baseadas em associação entre itens com base em transações de conjuntos de itens e é considerada uma ferramenta importante para descoberta de regras em conjuntos de dados muito grandes [21]. A associação de dados pode fornecer uma estimativa de relacionamentos desconhecidos e regras de decisão em um conjunto de dados, o que pode melhorar muito o processo de tomada de decisão e previsão [22].

A mentalidade de um aluno pode ser bem comunicada através de suas expressões faciais durante uma aula on-line. A mudança de humor de um aluno pode ser observada por meio dos seguintes instrumentos: expressões faciais, mãos e linguagem corporal. Esses instrumentos podem ser observados individualmente ou em combinação, porém, em ambos os casos, os padrões de associação de dados podem ser extraídos para se obter uma melhor compreensão do comportamento do aluno durante a aprendizagem online. Esta abordagem de associação de dados é muito eficiente e fornece resultados precisos nos casos em que uma categoria sozinha não pode ser usada para avaliar a compreensão precisa do estado de espírito de um aluno [24]. Uma combinação de categorias de características faciais com alta probabilidade de ocorrência reduz o espaço de decisão em muitas dobras. As expressões faciais de cada aluno em cada curso online podem representar dados muito grandes. Portanto, um algoritmo bem estabelecido é apresentado

aqui para extrair humores de um grande conjunto de características faciais. O algoritmo é modificado para ser usado na identificação do humor dos alunos e, posteriormente, na tomada de decisões precisas sobre seu nível de interesse durante a entrega de um curso online.

A extração de humor usando associação de dados é realizada em duas etapas [24] [25].




Figura 2. Uma abordagem de decisão de função de base radial baseada em distância para características faciais

Aproximar categorias ou conjuntos de itens, que ocorrem com frequência, e associar dados para extrair regras que se baseiam nas relações entre esses itens é o primeiro passo da classificação. Na etapa subsequente, os itens são avaliados para segregar conjuntos de itens que ocorrem com frequência e têm uma proporção de ocorrência maior que o limite mínimo de suporte [23].

Na segunda fase, todas as regras possíveis são extraídas do conjunto de itens, e o número de regras dependerá de todas as combinações possíveis dos itens em um determinado conjunto de itens, por exemplo, se um conjunto de itens tiver a forma  $\{a_1, a_2, a_3\}$ , então as regras que podem ser extraídas são  $\{a_1 \rightarrow a_2, a_3\}$ ,  $\{a_2 \rightarrow a_1, a_3\}$ ,  $\{a_3 \rightarrow a_1, a_2\}$ ,  $\{a_1 \rightarrow a_2 \rightarrow a_3\}$ ,  $\{a_1 \rightarrow a_3 \rightarrow a_2\}$ ,  $\{a_3 \rightarrow a_2 \rightarrow a_1\}$  etc.

Uma regra  $\{X \rightarrow Y\}$ , onde X e Y são características faciais, pode ser verificada usando níveis de confiança e limites de suporte. Os limites de suporte e confiança são usados como restrições ou limites para extração de regras. Os limites de apoio e confiança fornecem uma medida para eliminar as regras que não atendem ao critério do limite. Em suma, a mineração associativa de dados é usada para extração de humor, empregando suporte especificado pelo usuário e níveis de confiança para características faciais relacionadas e esta abordagem pode ser usada para desenvolver um medidor para avaliar a extensão da correlação entre características faciais em um conjunto de dados.

O algoritmo a priori [24] é uma técnica eficiente para associação de dados que pode ser usada para gerar conjuntos de recursos frequentes a partir de recursos faciais de banco de dados. O algoritmo [25] faz estimativa iterativa dos itens mais frequentes com base em métricas de suporte e confiança. Outras métricas também podem ser utilizadas, mas estas são as métricas padrão para avaliar a frequência de um conjunto de itens e a objetividade do humor de um aluno durante a aprendizagem on-line.

O nível de suporte é usado para estimar a frequência com que um relacionamento é estabelecido entre várias características faciais em um conjunto de dados, enquanto o nível de confiança fornece uma medida para determinar a frequência da característica facial "B" em características observadas que também contêm a característica "A" durante o tempo. t'. O período de tempo para observar o envolvimento e a atenção de um aluno depende do conteúdo que está sendo entregue e de partes significativas do conteúdo que requerem atenção completa dos alunos para compreensão.

O suporte determina a frequência com que um atributo de distância que aparece no SET „A” também aparece no SET „B” para um determinado número de amostras, enquanto a confiança determina com que frequência os atributos de distância do SET „B” se correlacionam com os atributos de distância no SET „A”.

As métricas de suporte e confiança mencionadas acima podem ser representado matematicamente como

Apoiar:

$$\frac{|A \cap B|}{|B|} \quad (1)$$

Confiança:

$$\frac{|A \cap B|}{|A|} \quad (2)$$

As etapas a seguir são propostas para uma arquitetura robusta de extração de humor para avaliar o interesse e a atenção de um aluno em relação ao conteúdo educacional entregue online. Essas etapas formarão a base do algoritmo proposto para extração de humor usando características faciais.

- Geração frequente de conjuntos de recursos: Considerando N transações, todos os conjuntos de recursos frequentes são estimados com base nos níveis de suporte. Este é um processo iterativo para identificar e gerar conjuntos de recursos candidatos. Esta parte de

o algoritmo envolve duas fases. Na primeira fase, ele verifica cada conjunto de recursos, começando com um único recurso facial do conjunto de recursos até o conjunto de recursos de tamanho máximo.

Na segunda fase, novos conjuntos de recursos são estimados a partir da iteração anterior e o suporte é testado em relação ao limite de suporte. O número de iterações nesta etapa depende do tamanho máximo do conjunto de itens, ou seja,  $(k_{\max} + 1)$  é o número total de iterações e  $k_{\max}$  é o maior tamanho de um conjunto de recursos que ocorre com frequência.

- Geração e remoção de candidatos: nesta etapa, novos conjuntos de recursos candidatos são gerados com base nos conjuntos de recursos  $(k-1)$  encontrados na iteração anterior, seguido de remoção usando níveis de suporte.
- Contagem de suporte: nesta etapa, a frequência de ocorrência de conjuntos de recursos candidatos após a remoção é determinada e os níveis de suporte são atualizados.
- Extração de Humor: Uma abordagem nivelada é usada para descobrir regras baseadas na associação de dados entre características faciais consequentes e antecedentes em conjuntos de características frequentes. Inicialmente, todas as regras com um único consequente são selecionadas para gerar novas regras candidatas. A seleção destas regras é baseada nos respectivos níveis de confiança. As regras geradas pelo algoritmo Apriori podem ser grandes em número, dependendo do banco de dados que está sendo pesquisado.

Como caso de teste, 30 alunos de uma aula de matemática foram observados durante uma sessão de e-learning de uma hora e as expressões foram extraídas usando o método Apriori explicado acima. A sessão teórica foi dividida em subseções de 10 minutos, onde cada subseção abordou um problema matemático específico. A Tabela 1 lista as divisões de 10 minutos de uma aula de uma hora.

TABELA I. MÓDULOS ENSINADOS DURANTE O TEMPO DE 6 X 10 MINUTOS EM SESSÃO DE UMA HORA

| S.Não | Subsessão                 |
|-------|---------------------------|
|       | Introdução                |
| 1     | Matrizes                  |
| 2 3   | Multiplicação de Matrizes |
| 4     | Divisão de Matrizes       |
| 5     | Operações de matriz 2 x 2 |
| 6     | Operações de matriz 4 x 4 |

Foram selecionados para o estudo alunos com idade média de 15 anos. Todos os alunos eram do 10º ano de uma escola particular. Os alunos foram selecionados com base em seu desempenho acadêmico e exposição suficiente a ambientes de e-learning. Nenhuma informação pré-requisito foi fornecida a eles sobre a natureza deste exercício.

Uma câmera digital de 35 mm foi usada com taxa de quadros de 10 fps para registrar as características faciais. Usando associação entre características faciais, as expressões faciais foram buscadas para extrair o humor de um aluno durante um período de 6 x 10 minutos durante o aprendizado. O algoritmo NN baseado em função de base radial [20] foi empregado para classificar o humor com base nas características faciais. O algoritmo a priori é posteriormente usado para criar conjuntos de recursos frequentes ou conjuntos de humor dos quais as regras mais pertinentes podem ser extraídas para declarar um padrão de humor válido.

Um feedback por escrito foi obtido de cada aluno após cada sessão de 10 minutos, composto pelas duas perguntas a seguir:

1) Mencione em quais partes da palestra você esteve

- Feliz
- Triste
- Confuso
- Perturbado
- Surpreso

2) Quais partes do quadro de 10 minutos você não entendeu ou ficou desatento (1 a 10)?

Com base nesta topologia todas as três fases foram executadas sequencialmente, e os resultados do estudo são apresentados na próxima seção

102 dos 200 participantes forneceram seu feedback com base no resultado da pesquisa que foi formulado e foi usado para categorizar cinco expressões principais e 23 características faciais. Eles estão listados na Tabela 2 e na Tabela 3.

Surpreendentes 88 por cento dos entrevistados concordaram que as expressões faciais revelam o envolvimento de um aluno na aula e podem ser usadas para avaliar a resposta de um aluno ao conteúdo que está sendo entregue. Isso forneceu uma base sólida para nossa análise subsequente, que foi realizada para classificar características faciais usando redes neurais.

TABELA II. EXPRESSÕES FACIAIS DEFININDO O HUMOR DE UM ALUNO EM UM SALA DE AULA

| S. Sem expressões faciais | 1. Feliz | Frequência |
|---------------------------|----------|------------|
|                           |          | 91         |
| 2. Triste 3.              |          | 96         |
| Confuso 4.                |          | 94         |
| Perturbado                |          | 90         |
| 5. Surpreso               |          | 87         |

TABELA III. PRINCIPAIS CARACTERÍSTICAS FACIAIS QUE CONSTITUEM AS CINCO PRINCIPAIS EXPRESSÕES FACIAIS DE UM ALUNO

| S. Sem características faciais                                       | Frequência |
|--|------------|
| 1. Olhos focados na tela   | 90         |
| 2. Olhos aumentados  | 75         |
| 3. Olhos encolhendo  | 76         |
| 4. Olhos girando 5.  | 81         |
| Olhos piscando 6.  | 92         |
| Olhos em contato com a tela 7. Olhos bem abertos 8. Lábios apertados | 85         |
|  | 80         |
|  | 67         |
| 9. Lábios lendo suavemente   | 88         |
| 10. Lábios-Sorria, ria 11.   | 94         |
| Lábios pontiagudos   | 73         |
| 12. Sobrancelhas   | 95         |
| levantadas 13. Sobrancelhas  | 73         |
| abaixadas 14. Separação  | 87         |
| de sobrancelhas 15. Unir   | 69         |
| sobrancelhas 16. Coçar as  | 91         |
| sobrancelhas 17.   | 89         |
| Balançar a cabeça 18.  | 81         |
| Cabeça caindo 19. Balançar a cabeça                                  | 102        |

|   |    |
|---|----|
| 20. Mãos no rosto ou usá-las como apoio 21. Coçar a | 84 |
| cabeça 22. Coçar as orelhas                         | 79 |
| 23. Coçar o nariz                                   | 68 |
|   | 75 |

A Tabela 4 mostra o desempenho comparativo do modelo de Rede Neural de Base Radial [20], modelo de Markov Oculto (HMM) [38] e modelo de Máquina de Vetores de Suporte (SVM) [37] testados neste estudo. Todos esses algoritmos foram implementados em Matlab e integrados ao módulo de visão LabView para processar e classificar dados de imagens. Todos os modelos foram treinados usando atributos de distância de características faciais do banco de dados Cohn-Kanade e também de um banco de dados personalizado que foi preenchido com expressões faciais do espaço amostral de 30 alunos. O modelo NN [20] usado neste estudo superou o HMM e o SVM para o banco de dados Cohn-Kanade neste estudo e provou ser mais confiável, dado que o espaço amostral é grande.

As seguintes expressões faciais foram direcionadas para o treinamento do modelo proposto.

- a) feliz
- b) Triste
- c) Confuso
- d) Perturbado
- e) Surpreso

TABELA IV. PRECISÃO DE CLASSIFICAÇÃO EM BANCOS DE DADOS PERSONALIZADOS E EXISTENTES

| Não | Facial Expressão | Precisão de classificação em banco de dados existente |        |       |     | Precisão de classificação em banco de dados personalizado |       |     |
|-----|------------------|---|--------|-------|-----|---|-------|-----|
|     |                  | NN  | SVM    | HMM   | NN  | SVM   | HMM   |     |
| 1   | Feliz            | 90,1 %  | 92,2 % | 87,2% | 81% | 83%   |       | 74% |
| 2   | Triste           | 88,1 %  | 85,0 % | 82,6% | 78% | 80,8%   | 78,2% |     |
| 3   | Confuso          | 80,6 %  | 78,2 % | 73,4% | 77% | 64,5%   | 72,2% |     |
| 4   | Perturbado       | 86,2 %  | 81,0 % | 80%   |     | 72%   | 76,3% | 69% |
| 5   | Surpreso         | 85,3 %  | 84,7 % | 84%   | 72% | 71%   | 74%   | 75% |

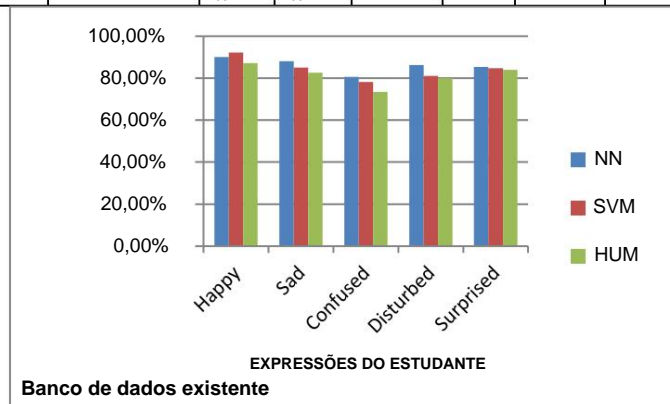


Figura 3. Precisão de classificação no banco de dados existente






Figura 4. Precisão de classificação no banco de dados personalizado

Com base em diferentes conjuntos de distâncias, os conjuntos de recursos foram preenchidos e testados quanto à confiabilidade usando o conjunto de dados Cohn-Kanade. As expressões foram prontamente classificadas com alta precisão, quando as imagens de teste foram selecionadas do mesmo banco de dados utilizado para treinar nosso modelo NN. No entanto, a precisão caiu para um nível aceitável quando um conjunto de imagens personalizadas de 30 alunos foi usado como conjunto de dados de teste. Esse problema pode ser contornado usando um modelo personalizado para imagens e iteração de treinamento de rede neural em novos conjuntos de dados. Uma tendência semelhante foi observada para a classificação SVM e HMM realizada no conjunto de dados Cohn-Kanade. Para o conjunto de dados personalizado, os resultados do SVM e do HMM mostraram taxas de classificação aleatórias que podem ser atribuídas ao pequeno espaço amostral de características faciais.

A resposta dos alunos foi registrada pedindo-lhes que atribuísssem uma pontuação de 10 à sua atenção durante cada sessão de 10 minutos e com base no seu feedback; a atenção foi correlacionada com as sequências de expressões faciais extraídas ou simplesmente com padrões de humor. A extração de humor foi realizada durante cada sessão de 10 minutos da aula de matemática de uma hora para todos os 30 alunos. O total de padrões de humor extraídos usando Apriori e padrões corretos com base nos resultados de correlação são mostrados na Tabela 5

TABELA V. PADRÕES DE HUMOR VÁLIDOS EXTRAÍDOS DURANTE UM PERÍODO DE TEMPO DE 6 X 10 MINUTOS EM SESSÃO DE UMA HORA PARA 30 ALUNOS

| Humor/Expressão | Extraído Humor Padrões | Correto Humor Padrões | Porcentagem Erro |
|-----------------|------------------------|-----------------------|------------------|
| Feliz           | 122                    | 92                    | 75,4%            |
| Triste          | 110                    | 87                    | 79,0%            |
| Confuso         | 125                    | 89                    | 71,2%            |
| Perturbado      | 109                    | 78                    | 71,5%            |
| Surpreso        | 98                     | 82                    | 83,6%            |

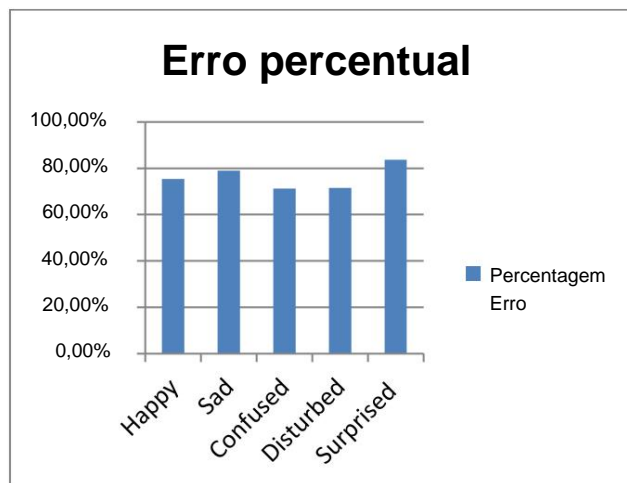


Figura 5. Erro percentual na classificação de humor/expressão facial

Os resultados mostraram que os padrões de humor extraídos apresentavam alta correlação com o feedback fornecido pelos alunos. Em todos os casos, o algoritmo proposto apresentou uma taxa de sucesso superior a 70% na avaliação do humor do aluno. Isto mostrou que a expressão de um aluno durante um período de 10 minutos pode ser usada para prever e extrair o humor de um aluno, que por sua vez pode ser usado para avaliar a atenção do aluno na aula. Os resultados mostraram que a abordagem proposta era muito robusta devido à integração da classificação baseada em redes neurais e do algoritmo Apriori para extração de humor. A diferença nas taxas de sucesso para cada humor pode estar relacionada a configurações básicas de teste, banco de dados incompleto e configurações mais simples de treinamento de NN.

O método proposto de classificação e extração de humor não tenta abordar a teoria completa das emoções no contexto do e-learning, mas sim desenvolver uma metodologia para identificar qualquer humor persistente que esteja afetando a atenção do aluno em um e-learning. ambiente, que é uma consideração importante conforme destacado em [31] [32] para estados de tédio, confusão e frustração. Os resultados apresentados nesta pesquisa mostram que a técnica proposta é promissora na avaliação de cinco estados de humor em um ambiente ativo de e-learning que foram selecionados por meio de uma pesquisa. A porcentagem de sucesso na avaliação de cada estado emocional é superior a 70%. Em trabalhos futuros, mais estados emocionais podem ser testados e, com base nos resultados deste estudo, espera-se uma taxa de sucesso semelhante, dado que é utilizado um extenso banco de dados de características faciais.

## V. CONCLUSÃO

A arte de compreender como diferentes alunos compreendem o conteúdo educacional durante uma sessão de estudo on-line requer investigação detalhada sobre o comportamento e o emocional.



estado do aluno ao longo da aula [33][34]. Esta pesquisa foi realizada com o objetivo de determinar possíveis formas de observar e analisar o comportamento de um aluno com o objetivo de compreender os eventos que desencadeiam seu distanciamento emocional durante uma aula online.

Os dados visuais adquiridos usando câmeras de alta definição contêm muitas informações quando armazenados por um longo período de tempo e precisam ser registrados continuamente, acumulando-se assim em dados muito grandes. As abordagens de mineração de dados podem ajudar de maneira semelhante na mineração de padrões de dados tão grandes. Regras importantes baseadas em características de correlação de atributos de classificação como distância podem ser adquiridas para caracterizar oscilações de humor e mudanças que afetam as curvas de aprendizagem de um aluno em um ambiente de e-learning. Os resultados podem ajudar a compreender melhor o ecossistema completo de um ambiente de E-learning onde a interação ativa aluno-máquina e o elevado nível de envolvimento do aluno são a principal preocupação. A entrega de conteúdo de e-learning, bem como as discrepâncias de atitude de um aluno, podem então ser abordadas de forma adequada para aumentar o envolvimento e a atenção do aluno durante o e-learning. Isso pode ser feito durante ou após a sessão de e-learning com base na preferência do aluno e/ou do administrador do e-learning

A principal contribuição desta pesquisa é a abordagem integrada com reconhecimento facial de rede neural e extração de humor baseada em Apriori, que mostrou probabilidade superior a 70% de detecção de 5 estados emocionais ou humores.

As expressões faciais descrevem o estado emocional do aluno e a análise do conteúdo e dos métodos de entrega pode ser realizada para alcançar a experiência ideal em um ambiente de e-learning [35]. No entanto, é difícil conceber sistemas de entrega de conteúdos padrão universais para cada aluno, portanto, sessões de teste específicas podem ser incorporadas num sistema de e-learning para permitir a personalização de acordo com as curvas de aprendizagem do aluno.

Os resultados assimilados por meio de uma pesquisa de vários acadêmicos mostraram que as características faciais são o melhor método para observar mudanças no humor de um aluno e causas relevantes podem ser extraídas relacionando a linha do tempo com a entrega do conteúdo e as sucessivas mudanças nas expressões faciais do aluno. O problema abordado neste estudo limita-se a determinar como um humor pode ser extraído pela associação de conjuntos de características compostos por várias expressões faciais. A causa das alterações no humor e no estado mental é outro problema e não é discutida nesta pesquisa.

O estado mental de um aluno pode ser observado usando suas expressões faciais, pois as características faciais tendem a mudar e fornecem a melhor representação do que o aluno tem em mente [36]. Como o envolvimento de um aluno durante a aprendizagem não supervisionada é fundamental para melhorar o seu potencial de aprendizagem, é pertinente conhecer os problemas enfrentados pelos alunos num ambiente de e-learning.

Finalmente, a maior contribuição desta pesquisa reside nos resultados que mostraram que as expressões faciais extraídas usando redes neurais e a redução do espaço amostral usando o algoritmo Apriori podem ser usadas ativamente para derivar o estado emocional do aluno durante a entrega de conteúdo em um sistema de e-learning. A abordagem integrada proposta mostrou uma alta probabilidade de

taxa de detecção de humor positiva (>70%) para cinco humores. Humor ou estados emocionais felizes, tristes, confusos, perturbados e surpresos

Para trabalhos futuros, os dados resultantes podem ser usados para otimizar a entrega de conteúdo de e-learning para envolver o aluno de forma mais ativa em tempo real quando for detectado um humor que leva à desatenção.

#### REFERÊNCIAS

- [1] G. Eason, B. Noble e IN Sneddon, "Sobre certas integrais do tipo Lipschitz-Hankel envolvendo produtos de funções de Bessel", Phil. Trad. Roy. Soc. Londres, vol. A247, pp. 529-551, abril de 1955. (referências)
- [2] M. Nur-Awaleh e L. Kyei-Blankson, "Avaliando o e-learning e a satisfação dos alunos em um ambiente misto e flexível", Conferência Internacional sobre Sociedade da Informação de 2010, Londres, 2010, pp.
- [3] C. Leghris e R. Mrabet, "Comparação de Custos de Soluções de E-Learning", 2006, 7ª Conferência Internacional sobre Ensino Superior e Treinamento Baseado em Tecnologia da Informação, Sydney, NSW, 2006, pp.
- [4] Fresen, J. (2007). Uma taxonomia de fatores para promover uma aprendizagem de qualidade apoiada pela web. *Jornal Internacional sobre E-Learning*, 6(3), 351-362.
- [5] J. Yu, "An Infrastructure for Real-Time Interactive Distance E-Learning Environment", Primeira Conferência Internacional sobre Ciência e Engenharia da Informação de 2009, Nanjing, 2009, pp.
- [6] Mohamed Sathik M, Sofia G (2011) Identificação da compreensão do aluno usando rugas na testa. 2011, Conferência Internacional sobre Informática, Comunicação e Tecnologia Elétrica (ICCET), pp 66-70.
- [7] N. Fragopanagos e JG Taylor, yEdição especial de 2005: Reconhecimento de emoções na interação humano-computador. *Redes Neurais, Neural*, maio de 2005. *Redes - Edição Especial: Emoção e Cérebro*, vol. 18, pp.
- [8] Rothkrantz, Ambientes de e-learning, *Comunicação e Cognição*, vol. 42, No. 1 e 2, pp 37-52, 2009.
- [9] A. Walia, N. Singhal e AK Sharma, "Uma nova abordagem de e-learning para adicionar mais cognição à Web Semântica", Conferência Internacional IEEE 2015 sobre Inteligência Computacional e Tecnologia de Comunicação, Ghaziabad, 2015, pp. .
- [10] Fabri, M., Moore, DJ, Hobbs, DJ (2004) "Mediando a Expressão de Emoção em Ambientes Virtuais Educativos Colaborativos: Uma Estudo Experimental", no *International Journal of Virtual Reality*, Springer Verlag, Londres
- [11] M. Feidakis, T. Daradoumis, S. Caballé e J. Conesa, "Medindo o Impacto da Consciência Emocional em Situações de e-learning", 2013 Sétima Conferência Internacional sobre Sistemas Complexos, Inteligentes e Intensivos de Software, Taichung, 2013 , pp.
- [12] R. Nkambou, (2006) "Rumo ao Sistema de Tutoria Inteligente Afetiva", Workshop sobre Questões Motivacionais e Afetivas em ITS. 8ª Conferência Internacional sobre ITS 2006, pp 5-12
- [13] Chaffar, S. e Frasson, C. (2005). "As condições emocionais da aprendizagem". *Anais da Conferência FLAIRS 2005*, .pp. 201-206
- [14] Guey-Shya Chen e Min-Feng Lee, "Detecting Emotion Model in e-learning System", Conferência Internacional sobre Aprendizado de Máquina e Cibernética de 2012, Xian, 2012, pp.
- [15] Bailenson J, Beall A, Blascovich J, Raimundo M, Weishbush M (2000) "Agentes inteligentes que usam seu rosto: reações do usuário ao eu virtual" Relatório Técnico, Centro para Ambiente Virtual e Departamento de Comportamento de Psicologia, Universidade da Califórnia, Santa Bárbara
- [16] R. Brunelli e T. Poggio, „Reconhecimento Facial: Recursos versus Modelos", *IEEE Trans. Análise de padrões e inteligência de máquina*, vol. 15, no.10, pp. 1042-1052, outubro de 1993.
- [17] LA. Essa e AP Pentland, "Codificação, análise, interpretação e reconhecimento de expressões faciais", *IEEE Trans. Análise de Padrões e Inteligência de Máquina*, vol. 19, no.7, pp-757-763, julho de 1997
- [18] JWGrzymala-Busse, "Sobre os valores de atributos desconhecidos na aprendizagem com exemplos", em *Proceedings of the ISMIS-91*, 6th International

- Simpósio sobre Metodologias para Sistemas Inteligentes, Notas de Palestra em Inteligência Artificial, Vol.542, Springer-Verlag, Berlin Heidelberg New York, 1991, pp.368-377.
- [19] G. Zhang, "Redes neurais para classificação: uma pesquisa", IEEE Trans. Syst., Man, Cybern., Syst., vol. 30, pp. 1094–6977, novembro de 2000.
- [20] Consortium.ri.cmu.edu, 'Site de download do banco de dados Cohn-Kanade (CK e CK +)', 2015. [On-line]. Disponível: <http://www.consortium.ri.cmu.edu/ckagree/>. [Acessado em: 20 set. 2014]
- [21] Weihua Wang, "Reconhecimento facial baseado em redes neurais de função de base radial", Future Information Technology and Management Engineering, 2008. FITME '08. Seminário Internacional sobre , vol., no., pp.41,44, 20-20 Nov.
- [22] J. Han, M. Kamber, "Mineração de Dados: Conceitos e Técnicas", Editores Morgan Kaufmann, Livro, 2000.
- [23] FH AL-Zawaidah, YH Jbara e AL Marwan, "Um Algoritmo Melhorado para Regras de Associação de Mineração em Grandes Bancos de Dados", Vol. 1, nº 7, 311-316, 2011
- [24] TC Corporation, "Introdução à mineração de dados e conhecimento Discovery", Two Crows Corporation, Livro, 1999
- [25] R. Srikant, "Algoritmos rápidos para regras de associação de mineração e padrões sequenciais", UNIVERSIDADE DE WISCONSIN, 1996.
- [26] S. Rao, R. Gupta, "Implementing Improved Algorithm Over APRIORI Data Mining Association Rule Algorithm", International Journal of Computer Science And Technology, pp.
- [27] Ekman, P. & Oster, H. (1979). Expressões faciais de emoção. Anual Revisão de Psicologia, 30, 527-554.
- [28] Ekman, P., Friesen, WV e Ancoli, S. (1980). Sinais faciais de experiência emocional. *Jornal de Personalidade e Psicologia Social*, 39(6), 1125-1134.
- [29] Ekman, P. (1993). Expressão Facial e Emoção. *Psicólogo Americano*, 48(4), 384-392.
- [30] Ekman, P. & Keltner, D. (1997). Expressões faciais universais de emoção: uma velha controvérsia e novas descobertas. Em Segerstråle, UC & Molnár, P. (Eds.), *Comunicação não-verbal: Onde a natureza encontra a cultura* (pp. 27-46). Mahwah, NJ: Lawrence Erlbaum Associates.
- [31] Aghababayan, Ani. "E3: Emoções, Engajamento e Educação Jogos." In *Educational Data Mining* 2014. 2014.
- [32] Craig, SD, Graesser, A., Sullins, J. e Gholson, B. (2004). Afeto e aprendizagem: um olhar exploratório sobre o papel do afeto na aprendizagem. *Journal of Educational Media (agora: Learning, Media & Technology)*, 29, 241–250.
- [33] D'Mello, SK, Craig, SD, & Graesser, AC (2009). Avaliação multimétodo da experiência e expressão afetiva durante a aprendizagem profunda. *Jornal Internacional de Tecnologia de Aprendizagem*, 4, 165–187.
- [34] TV Pham, M. Worrying e AWM Smeulders. Detecção de rostos por classificadores de redes bayesianas agregadas. *Reconhecimento de padrões. Letra*, 23(4):451–461, 2002
- [35] Li Xia, "Facial Expression Recognition Based on SVM", em *Intelligent Computation Technology and Automation (ICICTA)*, 2014 7ª Conferência Internacional sobre, vol., no., pp.256-259, 25-26 de outubro de 2014
- [36] S. Deshmukh, M. Patwardhan e A. Mahajan, "Pesquisa sobre técnicas de reconhecimento de expressões faciais em tempo real", em *IET Biometrics*, vol. 5, não. 3, pp. 155-163, 9 2016.
- [37] AWP Fok, HS Wong e YS Chen, "Caracterização baseada no modelo oculto de Markov de padrões de acesso a conteúdo em um ambiente de e-Learning", *Conferência Internacional IEEE sobre Multimídia e Expo de 2005, Amsterdã*, 2005, pp.
- [38] W. Gong e W. Wang, "Pesquisa de aplicação de máquina de vetores de suporte em E-Learning para personalidade", *Conferência Internacional IEEE 2011 sobre Computação em Nuvem e Sistemas de Inteligência, Pequim*, 2011, pp.