

## Um novo modelo de aprendizagem profunda para reconhecimento facial e Inscrições em Ensino a Distância

<https://doi.org/10.3991/ijet.v17i12.30377>

Ahmed B Salem Salameh, Halil Ibrahim Akyüz(ÿ)  
Universidade de Kastamonu, Kastamonu, Turquia  
hakyuz@kastamonu.edu.tr

**Resumo**—A demanda por identificação segura, precisa e confiável de indivíduos usando reconhecimento facial tem atraído interesse considerável na educação, segurança e muitos outros setores, não limitado por ser robusto, seguro e autêntico. Recentemente, a demanda por ensino à distância aumentou dramaticamente. Este aumento deve-se a várias barreiras à aprendizagem que surgem de condições impostas, como a reclusão e o distanciamento social. A extração de características faciais na educação a distância é valiosa para apoiar a autenticidade facial, pois evita que a posição dos participantes mude, especialmente durante a fase de exame. No campo do reconhecimento facial, existe um descompasso entre pesquisa e aplicação prática. Neste artigo, apresentamos um modelo de Deep Learning novo, mas altamente eficiente, para melhorar o reconhecimento facial e o registro na educação a distância. A técnica é baseada em uma combinação de bloqueio de identidade sequencial e residual. Isso permite avaliar a eficácia do uso de blocos mais profundos do que outros modelos. O novo modelo provou ser capaz de extrair características de faces de maneira elevada e precisa em comparação com outros métodos de última geração. No processamento de registros, existem vários desafios relacionados com a limitação de dados de formação, reconhecimento facial e verificação. Apresentamos uma nova arquitetura para reconhecimento e registro facial. Experimentos mostraram que nosso modelo de registro é capaz de reconhecer quase todos os rostos e registrar os rótulos correspondentes.

**Palavras-chave** – reconhecimento facial , aprendizagem profunda, identificação facial, ensino à distância, extração de características

### 1 Introdução

O ensino a distância tornou-se uma questão global na cultura da aprendizagem e da informação e torna-se imediatamente importante em 2020 no cenário da pandemia COVID-19[1], que mudou muito a forma como a educação é ministrada em muitos países. tenta[2] [3]. A forma tradicional de oferta educacional evoluiu para uma educação on-line baseada na Internet e orientada por computador[4]. O fator mais importante aqui é o grau de distância social e segurança [5][6]. A educação online é um dos termos utilizados para se referir ao processo de aprendizagem em que professores e alunos não estão fisicamente presentes no mesmo local. Existem muitos termos diferentes que têm o mesmo significado, como ensino on-line e ensino à distância. Em uma aula on-line, o professor e o aluno interagem com

uns aos outros. Eles parecem estar próximos, mas não estão. O processo de ensino e aprendizagem é feito por meio de videochamadas que complementam o curso online. A comunicação entre o professor e o aluno pode ser presencial através de chat de vídeo ou videoconferência, que é a forma ideal de aprendizagem.

Um dos problemas enfrentados pelos docentes online é a autenticidade dos alunos nas diferentes fases do ensino online, tais como ensino e avaliação. A autenticidade dos alunos é garantida por tecnologias de reconhecimento. Em muitos sistemas de educação a distância, é impossível informar se o participante é uma pessoa real que precisa ser instruída ou se o aluno está cursando ativamente o curso[7]. Este artigo enfoca o reconhecimento facial no registro de aulas on-line. Acredita-se que o reconhecimento facial é uma tecnologia biométrica valiosa que pode auxiliar no ensino a distância e apoiar diretamente todo o processo educacional. A contribuição desta parte é um novo modelo de reconhecimento e registro facial. Treinar e testar toda a estrutura do modelo proposto e implementar outras técnicas para controlar o reconhecimento e registro geral do sistema.

### 1.1 Reconhecimento facial

Embora tenham sido feitos grandes progressos no campo do reconhecimento, ainda existem problemas difíceis no reconhecimento facial e nas tarefas de reconhecimento. As limitações estão na pose da cabeça, dimensionamento, variações de iluminação, segmentação do ambiente e oclusão. O reconhecimento facial é uma das técnicas de verificação de identidade usadas em muitas aplicações de visão computacional[8]. O reconhecimento é feito usando diferentes métodos de extração de características após o processo de detecção e alinhamento de faces. A técnica mais popular é a técnica tradicional e de aprendizagem profunda. Os métodos tradicionais são conhecidos por extrair recursos artesanais, como modelo Multi Descriptor [9], Padrão Binário Local [10] [11], His-tograma de Gradientes Orientados [12], filtro Gabor [13] e Scale Invariant Feature Trans. -formulário [14] que é usado para extrair características distintivas. Essas técnicas eram robustas e eficientes para reconhecimento facial. Além disso, essas técnicas foram modificadas e desenvolvidas diversas vezes[15], por exemplo, o LBP foi modificado para ser mais eficiente no reconhecimento facial[16].

As redes neurais de convolução (CNN) estão entre as técnicas comuns para resolver problemas de processamento de imagens e visão computacional ao longo da última década [17]. Em muitos níveis de abstração, a força de um trabalho Neural de Convolução (CNN) reside na obtenção de um conjunto de mapas de características distintivas. As redes neurais convolucionais influenciaram positivamente o topo da maioria das outras implementações [18]. Em geral, existem muitas arquiteturas CNN, modelos profundos como GoogLeNet[19], ResNet[20] e[21]. Além disso, um grupo de geometria visual da Universidade de Oxford propôs uma arquitetura de rede neural convolucional chamada Deep Face Recognition [22]. Detecção facial, extração de recursos e identificação são os 3 componentes principais do reconhecimento facial. A detecção de rosto extrai rostos únicos ou múltiplos de imagens usando técnicas comuns, como detector de rosto Viola Jones [23] e CNN em cascata multitarefa [24]. A fase mais importante é a extração de características, que determina as características do rosto, enquanto a identificação é realizada para determinar a quem pertence aquela pessoa. Primeiro, detecção de rosto: o objetivo desta fase é selecionar um rosto específico na imagem. Dois conhecidos

algoritmos são usados no reconhecimento facial: detector facial viola-jones e CNN multitarefa em cascata. Nossa pesquisa mostrou que o detector facial Viola-Jones funciona bem em ambientes restritos com diferentes poses, iluminações e oclusões, mas que problemas são encontrados em situações irrestritas com diferentes poses, iluminações e oclusões. Multitarefa Cascade CNN usa uma estrutura em cascata de três estágios de redes de convolução profunda especialmente projetadas para detectar a face e a região de referência de maneira grosseira a fina. A CNN multitarefa em cascata foi usada neste artigo porque pode resolver o problema da baixa taxa de detecção. Em segundo lugar, extração de recursos: a extração de recursos é o objetivo principal de qualquer algoritmo de reconhecimento de padrões. Para reconhecimento facial, uma rede neural de convolução de aprendizado profundo é usada para extração de recursos. Esta é uma estratégia simples que não requer um método complicado de extração de características.

Terceiro, identificação: identificação é o reconhecimento da imagem facial de uma pessoa para atribuí-la a uma classe específica. Após a extração de recursos, a técnica compara um rosto em uma foto ou imagem de vídeo com um conjunto de dados de rosto existente. Quarto, a contribuição softmax é composta pela saída da camada totalmente vinculada que estava à sua frente e pelos recursos extraídos da rede neural real. Este resultado representa a função de probabilidade para todos os rótulos de classe.

## 2 Modelo proposto de aprendizagem profunda para reconhecimento facial

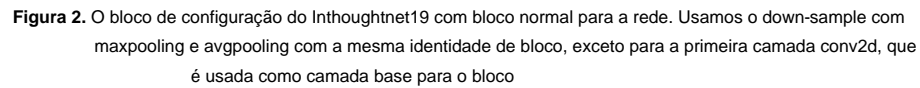
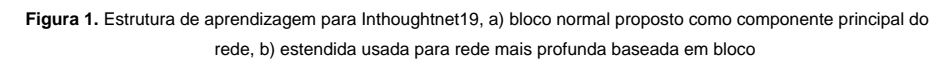
As arquiteturas propostas possuem a imagem de entrada com tamanho de 224X224x3 pixels e a primeira camada com tamanho de filtro de 7X7. A Tabela 1 e a Figura 2 mostram que a arquitetura  $\gamma$ profundnet19 com passo 2 permite que a CNN aprenda recursos mais relevantes com um total de 64 filtros. A camada seguinte possui uma dimensionalidade de dados de 112 e um tamanho de filtro de 5X5 com 64 filtros. O bloco normal proposto, como principal componente da rede, possui uma arquitetura de aprendizagem com o pooling médio da camada inicial para complementar a saída final do bloco, conforme mostrado na Figura 1.a.

$$y = \max (F(x, \{W_i\})) + \max (x) \quad (1)$$

$$y = \max(F(x, \{W_i\})) + \text{média}(x) \quad (2)$$

A rede principal possui uma arquitetura de aprendizagem onde o agrupamento médio precede a camada inicial para completar a saída final do bloco, com agrupamento médio e máximo para o bloco estendido, conforme mostrado nas equações (1) e (2). Finalmente, cada camada convolucional para todos os modelos é seguida por normalização em lote e unidade linear retificadora (ReLU) para acelerar o processamento e estabilidade [25][26] do modelo.

Finalmente, foram adicionados pooling médio global, uma camada totalmente conectada e uma camada softmax. Para treinar o modelo, a função de perda de entropia cruzada é aplicada. Para atualizações de peso e otimização da função Perda, é aplicado Stochastic Gradient Descent with Momentum.



Camada	Número de Convolução	Tamanho do núcleo	Canais	Passo	Tamanho de entrada
Imagem de entrada					224x224
Conv1	1	7x7	64	2	224x224
Conv1_1	1	5x5	64	1	112x112
Bloco 1	2	3x3	64	1	112x112
Bloco 2	3	3x3	128	1	55x55
Bloco 3	3	3x3	256	1	27x27
Bloco 4	3	3x3	512	1	13x13
Bloco 5	3	3x3	1024	1	6x6
Bloco 6	3	3x3	2048	1	6x6

### 3 conjuntos de dados de reconhecimento facial

Por aplicarmos o modelo proposto para reconhecimento e registro facial na educação a distância, a seleção do conjunto de dados é crucial para o nosso estudo. O conjunto de dados coletado na aula foi selecionado para validação do modelo. A Universidade de Essex, Projetos de Pesquisa em Ciência da Visão Computacional, introduziu quatro pastas de dados (Faces94, Faces95, Faces96, Grimace) [27]. O banco de dados total de rostos contém 395 rostos, compostos por homens e mulheres para cada sujeito, e inclui 20 imagens. Contém fotos de pessoas de diferentes origens étnicas, principalmente estudantes universitários do primeiro ano. A maioria dos sujeitos tem entre 18 e 20 anos, havendo também alguns sujeitos mais velhos.

Alguns outros indivíduos usam óculos e barbas. Face94 contém 152 pessoas, incluindo 20 mulheres, 113 homens e 20 homens, para um total de 3.060 pessoas. A resolução das imagens é de 180 x 200 pixels. A variação de um indivíduo é apresentada para resumir algumas características. O banco de dados Face95 contém 72 sujeitos do sexo masculino e feminino, e para cada sujeito há 20 exemplos com um total de 1.440 indivíduos. Os recursos incluem rotação da cabeça e algumas variações de expressão. Face96 incluiu 151 indivíduos com 20.3013 amostras coletadas para cada indivíduo. A resolução das imagens é de 196 x 196 pixels. As características deste banco de dados são consideradas de grande escala e algumas expressões e outras estão incluídas na Tabela 4, que contém algumas características das imagens faciais. O banco de dados de caretas contém sujeitos do sexo masculino e feminino com 18 sujeitos e 20 sujeitos com resolução de imagem de 180 x 200 pixels. O banco de dados contém as principais variações de expressão. A Tabela 2 mostra as características gerais dos quatro conjuntos de dados utilizados neste artigo. O experimento foi avaliado por meio de validação cruzada de 5 vezes.

Aumentamos os quatro conjuntos de dados com base em pequenas rotações para a esquerda e para a direita, sem processamento adicional.

**Tabela 2.** Resumo dos conjuntos de dados de reconhecimento facial

Conjunto de dados	Número de assunto	Número da imagem	Fundo	Escala de cabeça	virada de cabeça	Posição de rosto	variações de expressão	variação de iluminação
Rostos94	152	3060	verde claro	variação muito pequena	nenhum	pequenas alterações	considere mudanças de expressão	nenhum
Rostos95	72	1440	cortina vermelha	pequena variação	cabeça grande variação de escala	alguns tradução	alguns ex- variação de pressão	mudanças significativas de iluminação
Rostos96	72	Complexo	3013	pequena variação	cabeça grande variação de escala	alguns tradução	alguns ex- variação de pressão	mudanças significativas de iluminação
Careta	18	360	simples	variação considerável	pequena variação de escala de cabeça	alguns tradução	expressão principal variação	muito pouco

### 4 Avaliação e comparação de desempenho

Para avaliar e comparar o desempenho da CNN proposta, utilizamos os seguintes índices: o número de detecções positivas e negativas (P, N) e o número

de detecções corretas e falsas (T, F), acurácia total na equação (3) e acurácia média na equação (4).

1. Precisão (Acc):

$$\text{Conta} = \frac{(+)}{(+ + +)} \quad (3)$$

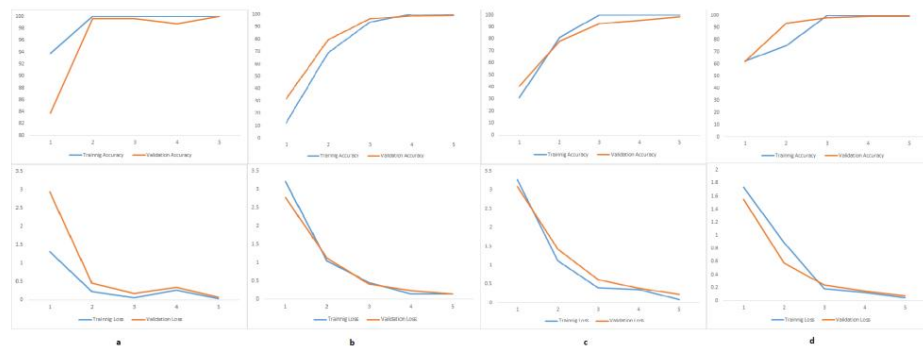
2. A precisão média  $\bar{y}$  é dada por:

$$\mu = \frac{\bar{y}^5}{5} \quad (4)$$

Onde denota a proporção de classificação válida.

## 5 Resultados e discussão

O conjunto de dados público foi escolhido porque facilita a comparação com outras abordagens e está relacionado a problemas de reconhecimento facial e registro em sala de aula. Também é comumente usado por outros pesquisadores. Os resultados foram avaliados com validação cruzada de 5 vezes. O diagnóstico dos modelos propostos é uma etapa crucial para o reconhecimento facial. A Figura 3 mostra a precisão do treinamento, precisão da validação, perda de treinamento e perda de validação para os conjuntos de dados. A partir da análise das curvas, pode-se observar que todos os conjuntos de dados apresentam um bom ajuste. A taxa de reconhecimento facial desta técnica foi comparada com outros modelos de aprendizagem profunda de última geração. A Figura 4 mostra que nosso modelo supera os outros métodos com uma precisão de 100% para os conjuntos de dados Face94 e Grimace e atinge 99,86% para Face95. No caso do Face96, o modelo atinge uma boa precisão de 99,54 em comparação com o resnet50 e o Densenet201.



**Figura 3.** Mostra a precisão do treinamento e validação, perda de treinamento e curvas de perda de validação para  $\bar{y}$ npfundnet19, (a) Faces94, (b) Faces95, (c) Faces96, (d) Careta

Artigo — Um novo modelo de aprendizagem profunda para reconhecimento e registro facial no ensino à distância



**Figura 4.** Comparação de desempenho do Inthoughtnet19

Para compreensão dos resultados, foram criados quatro conjuntos de dados com desafios diferentes, conforme mostrado na Tabela 2. Para os desafios relacionados aos conjuntos de dados, faces94 e caretas com menor escala de cabeça, posição facial, giro de cabeça e grandes diferenças de expressão, a proposta modelo obteve resultados significativos. Para face95 com alterações significativas de iluminação e grandes diferenças na escala da cabeça, o modelo apresenta desempenho perfeito em comparação com outros métodos. O conjunto de dados face96 possui um fundo complexo diferente com grandes diferenças de escala principal, o que afeta ligeiramente o desempenho do modelo proposto e de outros modelos. Para fazer melhor uso do Inthoughtnet19, consideramos que os desafios Face94, Grim-mace e Face95 apresentam um bom desempenho. Para o Facenet, a precisão no conjunto de dados faces96 não é ideal, o que provavelmente ocorre porque existem vários rótulos de rosto neste conjunto de dados que contêm faces diferentes. No entanto, a precisão dos resultados do FaceNet de [26] foi de apenas 77,67%. Isso parece bastante viável, uma vez que cada rótulo facial tem múltiplas diferenças e a técnica de treinamento FaceNet usa perda tripla.

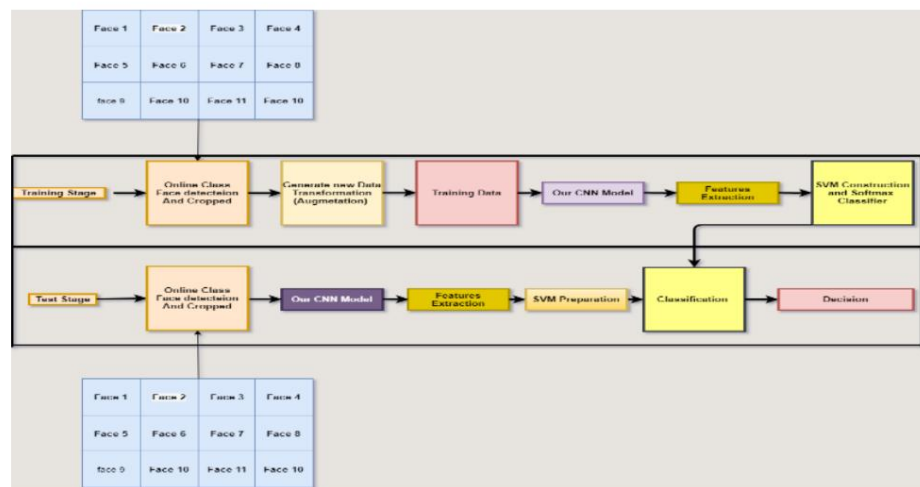
Todos os métodos de última geração alcançaram desempenho significativo. Os resultados médios indicam que o Inthoughtnet19 provou ser o método mais eficaz e superou os outros métodos do estado da arte, tornando-o mais interessante para os desafios relacionados aos quatro conjuntos de dados.

## 6 Ensino a distância e matrícula

### 6.1 Conjuntos de dados de ensino à distância

Todos os rostos são adquiridos por detecção ao vivo. Cada imagem facial na sala de aula online foi cortada automaticamente usando o método de detecção de rosto, consulte a seção II. A detecção e

recortado foi baseado em uma única imagem para cada rosto. As imagens foram preparadas usando transformação e aumento de dados. Esta técnica foi utilizada para desenvolver os conjuntos de dados em reconhecimento facial online. Além disso, foram introduzidas etapas sobre como treinar o classificador passo a passo, conforme aparece na Figura 5. Além disso, a principal preocupação da transformação de dados neste artigo é processar as classes que possuem algumas imagens faciais, bem como o aulas que têm mais do que uma imagem facial. O processo de treinamento é valioso e uma etapa desafiadora de todos os sistemas. Este método foi aplicado usando CNN proposta e máquina de vetores de suporte para extração de características faciais. Além disso, o classificador com a máquina de vetores de suporte foi mantido. Esta etapa valiosa e crucial revelou que o SVM que usa o melhor hiperplano que separa as classes tende a ter menos erros do que a função de probabilidade softmax para identificar as classes. A etapa de teste foi baseada no reconhecimento facial ao vivo nos rostos que apareciam na tela.



**Figura 5.** Mostrar arquitetura proposta de treinamento e teste de aulas on-line CNN e SVM

## 6.2 Aumento de dados

O aumento de dados é útil e fornece um excelente método para aumentar a precisão do reconhecimento facial, implementando modificações de dados no brilho, contraste e saturação [28]. Contraste, diferentes condições de fotografia levam a contrastes fotográficos inesperados que podem dificultar o reconhecimento. Tais variações podem ser representadas alterando digitalmente as informações de contraste usando a transformada HSV. Isto mostra que é necessário gerar novas informações de contraste aumentando e diminuindo o contraste em 20%, preservando as informações originais da imagem facial. As variações de brilho e iluminação ainda são um claro desafio em uma operação em tempo real. Transformações que alteram o brilho da imagem foram implementadas basicamente para detectar tal ação. Os atuais pesquisadores aumentaram e diminuíram o brilho em 20%, desenvolvendo uma nova imagem com uma condição diferente, mantendo a imagem original do rosto como parte do trabalho em todas as operações. Saturação, más condições de iluminação e eficiência,



## 7 Modelo de reconhecimento e registro facial online

$$= (8 \ddot{y} \ddot{y} \ddot{y} + (\ddot{y} \ddot{y} \ddot{y})) \stackrel{=0}{=7} \stackrel{(+1)}{\ddot{y} \ddot{y} \ddot{y}} \quad 2,55 \quad (5)$$

$$F(x) = \ddot{y} = 0 \quad \ddot{y} = 0, \quad (6)$$

$$F(x) = \ddot{y} - 0 \quad \ddot{y} = 0, \quad (7)$$

$$\text{similaridade (M, N)} = \frac{\sum_{i=1}^n \sum_{j=1}^n \min(|M_i - N_j|, 1)}{n^2} \quad (8)$$

$$\text{similaridade (M, N)} = \frac{\frac{\ddot{Y} = 1}{\ddot{Y} \ddot{Y} = 1}}{2} \frac{\ddot{Y}}{= 1} \frac{\ddot{Y}}{2} \quad (9)$$

$$s_1 = \text{semelhan\c{c}a} (x_1, N_1) \quad (10)$$

$$s_1 = \text{semelhan\c{c}a} (x_1, N_2) \quad (11)$$

$$(\cdot) = \max(1, 2) \quad (12)$$

Este modelo foi desenvolvido para medir o desempenho do CNN Softmax e SVM na aplicação do mundo real e para esclarecer como ele pode ser utilizado na educação a distância conforme visto na Figura 6. A turma com melhor similaridade deve ser considerada como a turma verdadeira.

como mostra a Equação 10. Baseado no reconhecimento e recorte de faces considerando o número de faces como referência, o sistema passa. O próprio sistema altera o número de referência caso ocorra algum erro durante o processo de registro.

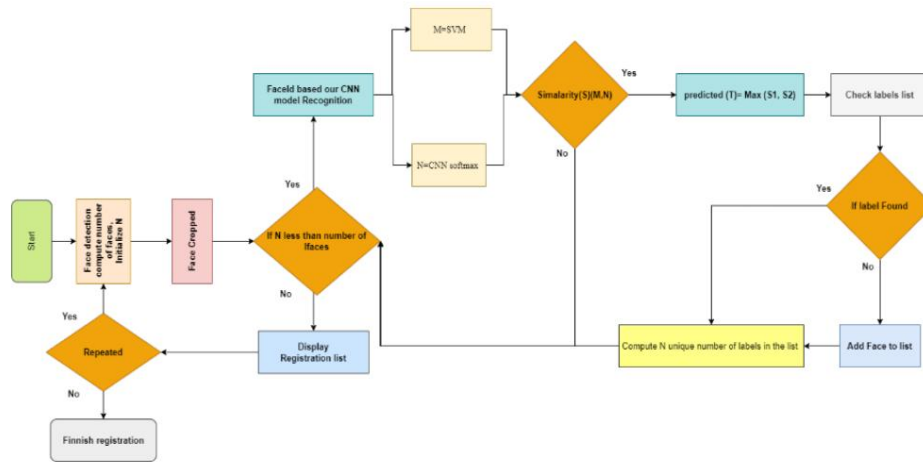


Figura 6. Mostra a arquitetura completa do sistema de reconhecimento facial de aulas online

## 7.1 Resultados e discussão

As comparações de desempenho foram feitas com base em dois testes. O primeiro teste foi relacionado ao reconhecimento de rostos de todas as turmas. A Figura 7 mostra o resultado do CNN Softmax proposto com apoio do SVM que apresentou resultados significativos no teste 1, face frontal com expressão facial diferente e leve rotação para direita e esquerda com 100% de precisão. Isso se deve à função de similaridade de cosseno que utilizamos para destacar o processo de identificação. Figura 7, no teste 2, face frontal com grande expressão facial e grande rotação para direita e esquerda, além de fundo diferente e grande escala de cabeça. O resultado para este caso mostra 88,88% de precisão.

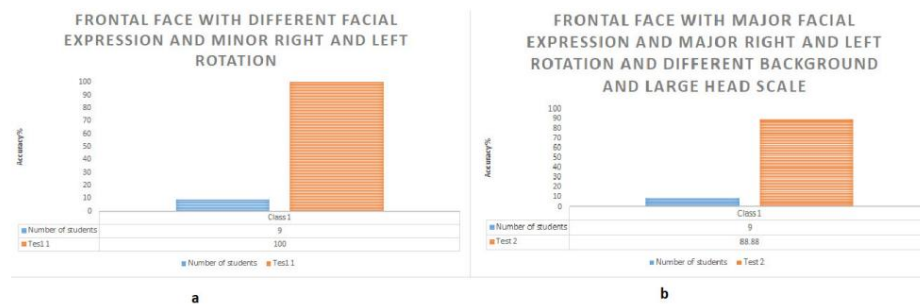


Figura 7. Mostra os resultados completos do reconhecimento facial online, a) teste 1, pequenas variações, b) teste 2, grandes variações

No Experimento 1, as tarefas de face frontal com diferentes expressões faciais e baixa rotação direita e esquerda foram mais seguras, precisas e confiáveis do que no Experimento 2.

Porém, o Experimento 2, teste 2 com 88,88% de precisão significa que o modelo foi capaz de reconhecer 8 de 9 faces nesta situação, devido às mudanças extremas na posição da face, escala, resolução e baixa variação dos dados de treinamento.

O modelo proposto não precisa de um grande conjunto de dados para aprender e isso é considerado mais eficaz, uma vez que o processamento do conjunto de dados com base em menos imagens faciais para treinamento da CNN é melhor do que um grande conjunto de dados e transferência de aprendizagem, bem como mais eficaz na verificação facial usando multi descritor para extração de recursos.

Os resultados esclarecem os desafios correspondentes que devem ser considerados no desenvolvimento da aplicação do reconhecimento e registro facial no ensino à distância e outras tarefas. Como desenvolvemos o modelo com base na similaridade entre a finalidade dos conjuntos de dados, nossa metodologia deve considerar evitar a lacuna entre os modelos de reconhecimento facial e a aplicação no mundo real no caso de ensino à distância.

## 8 Conclusão

Neste artigo, apresentamos uma rede neural profunda exclusiva com um modelo de alto desempenho para reconhecimento facial chamado *ynprofundnet19*, motivado por várias técnicas de design de rede. Os conjuntos de dados que selecionamos para validação do modelo são adequados para requisitos de reconhecimento facial e ensino à distância. Os testes nos quatro conjuntos de dados com diferentes desafios de reconhecimento facial mostraram que a nossa *ynprofundnet19* é eficiente em termos de precisão e a eficácia do modelo é comparável à da maioria das outras redes de reconhecimento facial profundo. Também apresentamos um novo modelo e técnica da CNN para reconhecimento e registro facial. A aplicação do reconhecimento facial no ensino a distância é um problema que surge da dificuldade de obtenção de dados de treinamento que estão disponíveis online. Nós

mostre como enfrentar e resolver esse problema usando transformação e aumento de dados.

O recurso facial foi extraído da CNN proposta e treinado usando Softmax e Support Vector Machine, que é adequado para conjuntos de dados limitados e menores erros de reconhecimento facial. Para todos os conjuntos de dados, enfatizamos a vantagem de usar Support Vector Machine para melhorar o reconhecimento facial em sistemas em tempo real, o que suporta a fase de verificação. Em nosso trabalho, apresentamos um modelo de reconhecimento facial que pode ser utilizado com sucesso no registro em ensino a distância e é adequado para superar os desafios de reconhecimento e registro facial.

Finalmente, nosso modelo também poderia contribuir para outras tarefas de classificação. A arquitetura de reconhecimento e registro facial é adequada para qualquer trabalho que necessite ser realizado remotamente, ou pode ser utilizada em algumas instituições, especialmente nas fases atual e futura devido aos constrangimentos impostos às reuniões e ao trabalho em local fechado.

A utilização do nosso modelo de reconhecimento de emoções no ensino à distância pode ser benéfica no futuro e ter um bom impacto nos processos de aprendizagem.

### Conflitos de interesse

Os autores declaram não haver conflitos de interesse.

## 9 Referências

- [1] AB Salem Salamh, AA Salamah e HI Akyüz, "Um estudo de uma nova técnica de visualização de tomografia computadorizada e protocolo de classificação de doenças com base em desafios de nível em casos de doença por coronavírus", *Radiol. Res. Prática*, vol. 2021, pp. 1–9, março de 2021. <https://doi.org/10.1155/2021/5554408>
- [2] NFRSK Nazarova, GAJalilova, NSMukhamedova, "Características do Ensino à Distância Organização", *Ann. RSCB*, não. 339–347, 2021.
- [3] D. Li, "Tecnologia de aprendizagem profunda baseada no ensino inteligente em cursos de psicologia social", *Int. J. Emerg. Tecnologia. Aprenda.*, vol. 16, não. 24, pp. 40–56, 2021. <https://doi.org/10.3991/ijet.v16i24.27255>
- [4] D. Mu e W. Guo, "Impacto do esgotamento da aprendizagem on-line dos alunos no desempenho da aprendizagem – o papel intermediário da avaliação de jogos", *Int. J. Emerg. Tecnologia. Aprenda.*, vol. 17, não. 02, pp. 239–253, janeiro de 2022. <https://doi.org/10.3991/ijet.v17i02.28555>
- [5] MH Akmal Abdullaev, "TECNOLOGIAS INOVADORAS DE APRENDIZAGEM À DISTÂNCIA," *J. Crit. Rev.*, vol. 7, não. 11, 2020. <https://doi.org/10.5958/2249-7137.2021.00198.1>
- [6] KK Abduraximovich, "Ensino baseado em tecnologia de educação a distância como um problema pedagógico completo", *Acad. UM Int. Multidisciplinar. Res. J.*, vol. 11, não. 1, pp. 1, pp.
- [7] D. Ozdemir e ME Ugur, "Uma proposta modelo sobre a determinação da frequência dos alunos na educação a distância com tecnologia de reconhecimento facial", *Turkish Online J. Dis-tance Educ.*, vol. 22, não. 1, pp. 19–32, 2021. <https://doi.org/10.17718/tojde.849872>
- [8] Z. Pei, H. Xu, Y. Zhang, M. Guo e Y.-H. Yang, "Reconhecimento facial via aprendizagem profunda usando aumento de dados baseado em experimentos ortogonais", *Electronics*, vol. 8, não. 10, pág. 1088, setembro de 2019. <https://doi.org/10.3390/electronics8101088>
- [9] ABS Salamh e HI Akyüz, "Um novo descritor de extração de recursos para reconhecimento facial", *Eng. Tecnologia. Apl. Ciência. Res.*, vol. 12, não. 8033–8038, fevereiro de 2022. <https://doi.org/10.48084/etasr.4624>
- [10] L. Zhou, H. Wang, S. Lin, S. Hao e Z.-M. Lu, "Reconhecimento facial baseado em padrão binário local e aprendizagem de métricas múltiplas restrita por pares aprimorada", *Multimed. Ferramentas Appl.*, vol. 79, não. 675–691, janeiro de 2020. <https://doi.org/10.1007/s11042-019-08157-0>
- [11] T. Lindahl, "Estudo de Padrões Binários Locais", *Ciência e Tecnologia*. pág. 3, 2007, [On-line]. Disponível: <http://www.ep.liu.se/>
- [12] CH Hima Bindu e K. Manjunatha Chari, "Reconhecimento facial usando recursos Co-HOG aprimorados", 2020, pp. [https://doi.org/10.1007/978-981-15-3992-3\\_55](https://doi.org/10.1007/978-981-15-3992-3_55)
- [13] TM Abhishree, J. Latha, K. Manikantan e S. Ramachandran, "Reconhecimento facial usando extração de recursos baseada em filtro Gabor com difusão anisotrópica como técnica de pré-processamento", *Procedia Comput. Ciência*, vol. 312–321, 2015. <https://doi.org/10.1016/j.procs.2015.03.149>
- [14] T. Lindeberg, "Transformação de recurso invariante de escala", *Scholarpedia*, vol. 7, não. 5, pág. 10491, 2012. <https://doi.org/10.4249/scholarpedia.10491>
- [15] M. Ghorbani, AT Targhi e MM Dehshibi, "HOG e LBP: Rumo a um sistema robusto de reconhecimento facial", em *2015 Décima Conferência Internacional sobre Gerenciamento de Informações Digitais (ICDIM)*, outubro de 2015, pp. 141. <https://doi.org/10.1109/ICDIM.2015.7381860>
- [16] B. Ahuja e VP Vishwakarma, "Local Binary Pattern Based Feature Extraction with KELM for Face Identification", em *2020, 6ª Conferência Internacional sobre Processamento e Comunicação de Sinais (ICSC)*, março de 2020, pp. <https://doi.org/10.1109/ICSC48311.2020.9182760>

- [17] X. Wu, R. He, Z. Sun e T. Tan, "Uma CNN leve para representação de rosto profundo com rótulos barulhentos", *IEEE Trans. Inf. Segurança Forense*, vol. 13, não. 2884–2896, novembro de 2018. <https://doi.org/10.1109/TIFS.2018.2833032>
- [18] K. Mrhar, L. Benhiba, S. Bouekkache e M. Abik, "Um modelo bayesiano CNN-LSTM para análise de sentimentos em MOOCs de cursos on-line abertos massivos", *Int. J. Emerg. Tecnologia. Aprenda.*, vol. 16, não. 23, pp. .
- [19] G. Zeng, Y. He, Z. Yu, X. Yang, R. Yang e L. Zhang, "Preparação de novas membranas de remoção de íons de cobre por incorporação de nanotubos de carbono de paredes múltiplas funcionalizados com organossilano", *J. Química. Tecnologia. Biotecnologia*, vol. 91, não. 8, pp. 2322–2330, agosto de 2016. <https://doi.org/10.1002/jctb.4820>
- [20] V. Sangeetha e KJR Prasad, "Sínteses de novos derivados de 2-acetilfuro[2,3-a] carbazóis, Benzo[1,2-b]-1,4-tiazepino[2,3-a]carbazolas e 1-Acetiloxicarbazol-2-carbaldeídos." *ChemInform*, vol. 37, não. 50, dezembro de 2006. <https://doi.org/10.1002/chin.200650130>
- [21] FN Iandola, S. Han, MW Moskewicz, K. Ashraf, WJ Dally e K. Keutzer, "SqueezeNet: precisão de nível AlexNet com 50x menos parâmetros e tamanho de modelo <0,5 MB," Fevereiro de 2016, [On-line]. Disponível: <http://arxiv.org/abs/1602.07360>
- [22] OM Parkhi, A. Vedaldi e A. Zisserman, "Deep Face Recognition", em *Procedings of the British Machine Vision Conference 2015*, 2015, pp. <https://doi.org/10.5244/C.29.41>
- [23] P. Viola e MJ Jones, "Robust Real-Time Face Detection", *Int. J. Computação. Vis.*, vol. 57, não. 2, pp. 137–154, maio de 2004. <https://doi.org/10.1023/B:VISI.0000013087.49260.fb>
- [24] K. Zhang, Z. Zhang, Z. Li e Y. Qiao, "Detecção e alinhamento de faces conjuntas usando redes convolucionais em cascata multitarefa", *Processo de sinal IEEE. Lett.*, vol. 23, não. 10, pp. 1499–1503, outubro de 2016. <https://doi.org/10.1109/LSP.2016.2603342>
- [25] Sergey Ioffe; Christian Szegedy, "Normalização em lote: acelerando o treinamento profundo da rede reduzindo a mudança interna de covariáveis", *Proc. 32ª Int. Conf. Mach. Aprenda.*, vol. 37, pp. 448–456, 2015.
- [26] S. Santurkar, D. Tsipras, A. Ilyas e AM Yadry, "Como a normalização em lote ajuda Otimização", 2018.
- [27] L. Spacek, "Bancos de dados de imagens faciais de Libor Spacek", *Projetos de pesquisa em ciência da visão computacional*, 2009. <https://cmp.felk.cvut.cz/~spacek/faces/>
- [28] V. Uchoa, K. Aires, R. Veras, A. Paiva e L. Britto, "Data Augmentation for Face Recognition with CNN Transfer Learning", na *Conferência Internacional de 2020 sobre Sistemas, Sinais e Processamento de Imagens (IWSSIP)*, julho de 2020, pp. <https://doi.org/10.1109/IWSSIP.48289.2020.9145453>

## 10 Autores

**Ahmed B Salem Salamh**, estudante de doutorado, Instituto de Ciência, Ciência e Engenharia de Materiais, Universidade de Kastamonu, Kuzey Kent /PO Box, Kastamonu / estado/Turquia, código postal 37150, Turquia.

**Halil Ibrahim Akyüz**, PHD, professor associado, Faculdade de Educação, Educação em Tecnologias de Computação e Ensino, Universidade de Kastamonu, endereço Kuzey Kent /PO Box, Kastamonu /estado/Turquia, código postal 37150, Turquia.

Artigo submetido em 23/02/2022. Reenviado em 28/03/2022. Aceitação final 28/03/2022. Publicação da versão final conforme apresentado pelos autores.