

Previsão de envolvimento do aluno em um Plataforma de e-learning

Dr. , Harshitha.L2, Harshitha.N3, Brinda4

1Professor Associado, Departamento de ISE, CMR Institute of Technology, Bengaluru

2,3,4Estudante de Graduação, Departamento de. ISE, Instituto de Tecnologia CMR, Bengaluru

Resumo— COVID-19 é uma doença infecciosa causada pelo recém-descoberto coronavírus que se originou em Wuhan. Esta doença contagiosa se espalhou rapidamente, devido ao fechamento de grandes locais de reunião, incluindo escolas e faculdades. Isso levou ao conceito de sistema de educação online. Nesse sistema, os professores poderiam dar aulas aos alunos que estão em casa por meio de diversas plataformas online. Este projeto discute os avanços tecnológicos que podem ser feitos para prever o envolvimento dos alunos em uma plataforma de e-learning. Foi implementado um sistema automático de registro de presença por reconhecimento facial, onde o tempo de login do aluno é registrado em uma planilha Excel. Através do olhar do aluno, pode-se estimar se o aluno está atento, distraído, sonolento, etc. Além disso, a participação do aluno em fóruns de discussão, o número de vezes que a mão foi levantada, os recursos visitados e as visualizações dos anúncios para determinar o nível de envolvimento podem ser analisado. **Palavras-chave**—Reconhecimento facial, envolvimento dos alunos, olhares, educação online.

I. INTRODUÇÃO

Com o surgimento da Pandemia de Covid-19, o ensino à distância entrou em ação à medida que as instituições de ensino foram fechadas, mas o aprendizado teve que continuar. O E-learning foi um caos durante os primeiros meses, pois alunos e professores tiveram que se adaptar a este novo modo de aprender e ensinar, respectivamente.

O problema era que a interação entre alunos e professores diminuía porque não havia conexão física. Na maioria dos casos, os alunos entraram nas aulas, mas prestaram pouca atenção. Tornou-se um desafio para os professores monitorar o nível de envolvimento de cada aluno [1]. Webcam e fórum de bate-papo tornaram-se o único meio de interação em uma sala de aula on-line [2].

No nosso artigo, abordamos o desafio discutindo as várias estratégias implementadas para extrair insights sobre o comportamento dos alunos no E-learning. Para isso, utilizamos reconhecimento facial com sistema de atendimento aliado a detector de distração. **Aqui, o horário de login é registrado automaticamente quando o rosto é detectado; mas determinar apenas o horário de login não pode levar a uma conclusão sobre o nível de envolvimento do aluno;** portanto, incluímos também a extração de características faciais. Nós temos

focado na detecção do olhar para prever o nível de envolvimento e desligamento, juntamente com a participação do aluno em outras atividades, como mão levantada, discussão, recursos visitados e anúncios lidos. Esses fatores ajudam os professores a acompanhar o envolvimento dos alunos de forma eficaz.

O restante deste trabalho está organizado da seguinte forma. A seção 2 apresenta uma pesquisa bibliográfica de vários trabalhos relacionados. A seção 3 descreve brevemente a metodologia proposta juntamente com fluxogramas. A seção 4 inclui os resultados e a discussão do nosso trabalho; Por fim, a Seção 5 apresenta a conclusão.

II. PESQUISA DE LITERATURA

A. Medindo o nível de envolvimento do aluno usando a expressão facial

A estrutura sugerida grava o vídeo do usuário e segue seus rostos conforme eles se movem pelos frames do vídeo. Pontos de referência do rosto, atitude da cabeça, olhar, recursos de aprendizagem e outros recursos são extraídos do rosto do usuário [3]. Essas características são então usadas para detectar o Sistema de Codificação de Ação Facial (FACS), que divide as expressões faciais nas ações fundamentais de músculos individuais ou grupos de músculos [4] [5]. As unidades de ação decodificadas (AUs) são então usadas para avaliar a disposição do aluno em participar do processo de aprendizagem. O professor será capaz de receber informações em tempo real sobre características faciais, olhar e outras cinéticas corporais usando esta estrutura [6].

B. Previsão de desempenho dos alunos online

Cursos usando algoritmos de aprendizado de máquina

As notas de avaliação dos alunos e o desempenho final dos alunos foram usados para criar dois modelos preditivos [7]. Os modelos podem ser usados para identificar os elementos que influenciam os resultados de aprendizagem dos alunos MOOC. Como resultado, ambos os modelos produzem resultados práticos e precisos [8][9]. O menor ganho do RSME foi produzido pelo RF, com valor médio de 8,131 para o modelo de notas de avaliação dos alunos, enquanto o GBM proporcionou a melhor acurácia no desempenho final dos alunos, com valor médio de 0,086 [10].

C. Previsão de alunos em risco em diferentes porcentagens de duração do curso para intervenção precoce usando modelos de aprendizado de máquina

Eles criaram um modelo que fornece os melhores resultados de exatidão, precisão, recall, suporte e métricas de pontuação f [11]. O modelo preditivo pode ajudar os instrutores a identificar alunos em risco no início do curso, para que possam receber a intervenção adequada e evitar o abandono. As pontuações da avaliação dos alunos, a intensidade do envolvimento (dados de fluxo de cliques) e as variáveis dependentes do tempo são aspectos-chave na aprendizagem on-line, de acordo com os resultados [12][13].

D. Previsão do desempenho dos alunos usando regressão linear

Eles usaram um modelo de regressão linear para prever o desempenho acadêmico dos alunos [14]. Eles também implementaram novos aplicativos de aprendizado de máquina no ensino e na aprendizagem, levando em consideração a formação dos alunos, pontuações acadêmicas anteriores e outros fatores [15] [16].

III. METODOLOGIA PROPOSTA

Etapas envolvidas no sistema de atendimento

- 1) **Codifique** a imagem utilizando o algoritmo HOG, que simplifica a imagem e esta imagem simplificada ajudará na geração do HOG para determinada parte da imagem.
- 2) **Encontre** os pontos de referência da imagem posada, envolvendo esta imagem de forma que os olhos e a boca fiquem centralizados.
- 3) **Passa** esse ponto de referência para a rede neural que faz as 128 medições das características do rosto.
- 4) **Por fim**, observe as medidas e compare-as com as do passado e encontre a correspondência de fechamento fornecendo o nome como resultado final.
- 5) O nome e o horário de chegada do aluno serão então registrados na planilha Excel automaticamente.

a) Visão Geral da Subseção

Para detectar o rosto, utilizamos o algoritmo de reconhecimento facial que auxilia na detecção dos rostos quando a web cam está ligada. Isso serve como base para o nosso projeto, pois o modelo é treinado com diversas imagens e reconhece automaticamente uma pessoa com boa precisão.

Primeiro importamos os pacotes necessários como numpy, cv2, dlib e carregamos o quadro. Usamos opencv para

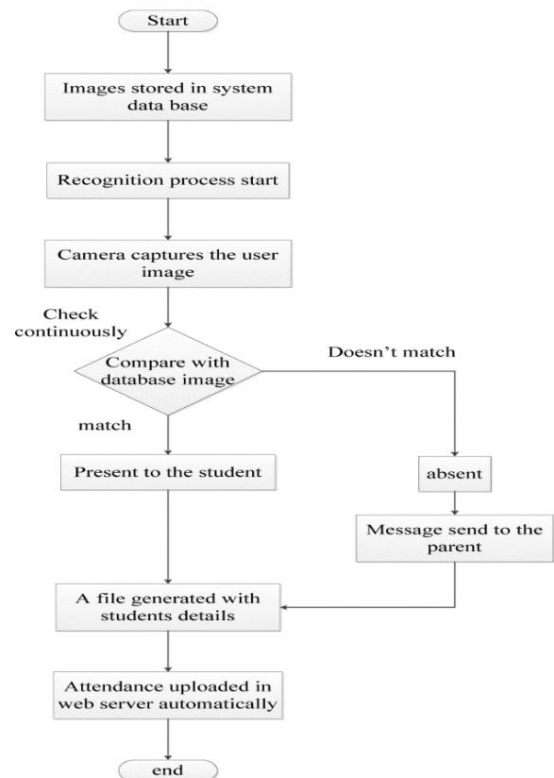


Fig. 1: Reconhecimento facial com sistema de atendimento

reunindo todas as imagens da webcam e então inicia-se o processo de reconhecimento. A câmera passa a capturar a imagem do usuário e a compara com todas as imagens presentes no banco de dados. Para a classificação das imagens, utilizamos o classificador SVM. Se for encontrada alguma correspondência, o nome da pessoa é reconhecido e marcado como presente; finalmente, essas informações são armazenadas em um documento.

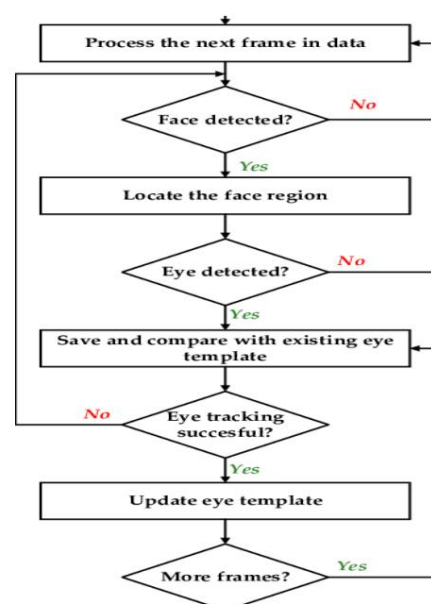


Fig. 2: Sistema de rastreamento do olhar

Uma vez que o rosto é detectado, o próximo passo é a detecção dos olhos do rosto. Para localizar os olhos como

mostrado na fig. 2; nos referimos aos 66 pontos de referência. De onde são extraídos os pontos 37-48. O foco aqui está na visibilidade da esclera do olho. Se a esclera estiver mais visível na parte direita, o olho está voltado para a esquerda. Para detectar a esclera convertemos o olho em escala de cinza, encontramos um limiar e contamos os pixels brancos.

Para ser mais preciso, encontramos a proporção do olhar para prever para onde o olho está olhando. Nós pegamos o olhar

$$\text{Gaze_ratio} = \frac{\text{left_eye_white_pixels}}{\text{right_eye_white_pixels}}$$

Com uma análise adequada, descobrimos que se $\text{gaze_ratio} \leq 0,8$ ou $\text{gaze_ratio} \geq 3$ então prevemos que o aluno está distraído enquanto olha na região da tela, caso contrário, se $0,8 < \text{gaze_ratio} < 3$ então o aluno está focado.

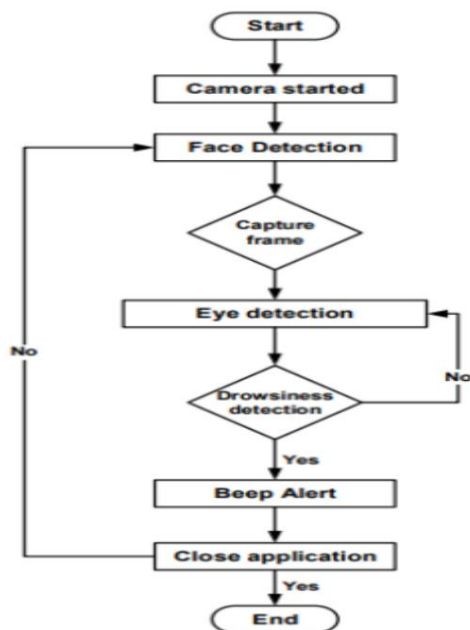


Fig.3 Detecção de sonolência

A webcam detecta os olhos como a região de interesse (ROI). Isso é inserido em um classificador que classifica se o olho da pessoa está aberto ou fechado. Se os olhos da pessoa ficarem fechados por mais de 5 segundos, detecta que a pessoa está com sono.

b) Análise do Comportamento

A segunda parte do nosso trabalho é a análise comportamental, para isso levamos em conta o envolvimento do aluno em diversas atividades como a sua participação em discussões, mãos levantadas, recursos visitados e anúncios visualizados.

Realizamos regressão linear múltipla em dados, pois funciona bem para dados linearmente não separáveis, mais fácil

para implementar e eficiente para treinar junto com menor complexidade de tempo.

Podemos representar a regressão linear múltipla como

$$Y = m_1 \cdot X_1 + m_2 \cdot X_2 + m_3 \cdot X_3 + \dots + m_n \cdot X_n + C$$

Variável dependente de Y

Coefficiente C

$X_1, X_2, X_3, \dots, X_n$ – variáveis independentes

$m_1, m_2, m_3, \dots, m_n$ – declives.

Aqui a variável dependente é % de engajamento

E as variáveis independentes são Discussão, mãos levantadas, recursos visitados e visualizações de anúncios. 20% são dados de validação e 80% são dados de treinamento.

4. RESULTADOS E DISCUSSÕES

Para fornecer atualizações em tempo real ao professor sobre o envolvimento do aluno em uma plataforma de E-Learning, incluímos um recurso em que, se o aluno estiver olhando para a tela, ele exibirá 'focado' ou se estiver olhando para outro lugar, exibirá 'distraído' como mostrado na fig.2 e fig. 3.

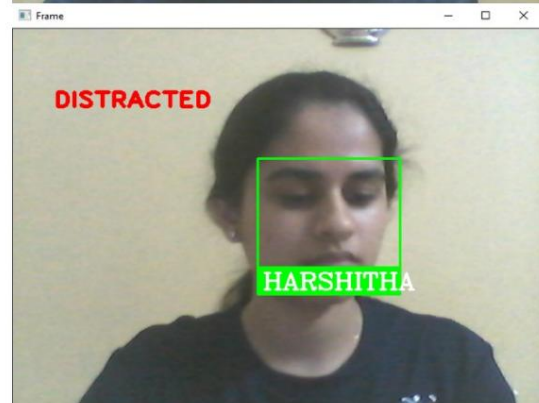


Fig. 4 Captura de evento distraído



Fig. 5 Captura de evento de sono

A detecção de sonolência é um recurso adicional que permite ao professor entender se um aluno está se sentindo sonolento durante a aula. Portanto, se o aluno fechar os olhos por mais de 5 segundos, ele exibirá 'Dormindo', conforme mostrado na Fig.5.

Assim que o rosto for detectado, a presença desse aluno será automaticamente registrada no arquivo. Este arquivo contém o nome do aluno e o horário em que ele foi detectado conforme mostrado na Fig.



Fig. 6 Sistema de registro de presença

A Figura 7 representa uma GUI criada pelo tkinter com quatro rótulos, ou seja, Discussão, Mão levantada, Recursos visitados e Anúncios visualizados. A barra deslizante tem valor que varia de 0 a 100, com base na média de quatro fatores, treinamos o modelo para prever o percentual de Engajamento.

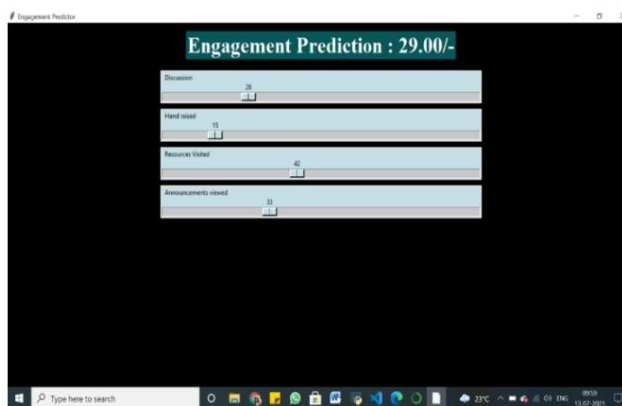


Fig. 7 Relatório de previsão de engajamento

V CONCLUSÃO E ESCOPO FUTURO

A previsão do envolvimento dos alunos é uma grande preocupação para melhorar a qualidade da educação e diminuir o abandono escolar. Em nosso estudo analisamos o comportamento do aluno considerando vários aspectos como Sistema de Presença, detecção de distração, detecção de sonolência e outras atividades online como mão levantada, visualizações de anúncios, participação em discussões.

Isto inclui uma perspectiva mais ampla e também ajudou a aumentar a eficiência da previsão. Nosso modelo pode ajudar a reduzir a carga imposta aos professores para monitorar os alunos.

Abordamos a previsão não só do nível de envolvimento, mas também do desligamento. Isto serviria de modelo em condições críticas como a Covid-19 para promover o sistema educativo. O escopo futuro do nosso projeto seria sugerir técnicas e formas de aumentar o envolvimento do aluno em uma aula online, como questionários, gamificação, além de prever o estado emocional do aluno durante a participação nas aulas virtuais.

Referências [1].

Domina, Thurston & Renzulli, Linda & Murray, Brittany & Garza, Alma & Perez, Lysandra. (2021). Remoto ou remoto: prevendo o envolvimento bem-sucedido com a aprendizagem on-line durante o COVID-19. Socius: Pesquisa Sociológica para um Mundo Dinâmico.

[2]. KC Manwaring, R. Larsen, CR Graham, CR Henrie e LR Halverson, "Investigando o envolvimento dos alunos em ambientes de aprendizagem combinada usando amostragem de experiência e modelagem de equações estruturais", Internet e Ensino Superior, vol. 35, pp. 21–33, 2017.

[3]. Hussain, Mushtaq e Zhu, Wenhao e Zhang, Wu e Abidi, Raza. (2018). Previsões de envolvimento dos alunos em um sistema de e-Learning e seu impacto nas pontuações da avaliação dos cursos dos alunos. Inteligência Computacional e Neurociência. 2018. 1-21.

[4] E. Aguiar, GA Ambrose, NV Chawla, V. Goodrich e J. Brockman, "Engajamento vs desempenho: usando portfólios eletrônicos para prever a persistência dos alunos de engenharia no primeiro semestre", Journal of Learning Analytics, vol.1, no. 3, pp. 7–33, 2014.

[5] C. ,omas e DB Jayagopi, "Predicting Student Engagement in Classrooms Using Facial Behavior Cues", em Proceedings of 1st ACM SIGCHI International Workshop on Multimodal Interaction for Education, pp.

[6] ML Bote-Lorenzo e E. Gomez-Sanchez, "Prevendo a diminuição dos indicadores de engajamento em um MOOC", em Proceedings of Seventh International Conference on Learning Analytics and Knowledge, pp. , março de 2017.

[7] M. Atherton, M. Shah, J. Vazquez, Z. Griffiths, B. Jackson e C. Burgess, "Usando análise de aprendizagem para avaliar o envolvimento dos alunos e os resultados acadêmicos em acesso aberto, permitindo

programas", Journal of Open, Distance and e-Learning, vol. 32, não. 2, pp. 119–136, 2017.

[8] RF Kizilcec, C. Piech e E. Schneider, "Desconstruindo o desengajamento: analisando subpopulações de alunos em cursos online abertos massivos", em Proceedings of 3rd International Conference on Learning Analytics and Knowledge, pp. , Abril de 2013.

[9] M. Wells, A. Wollenschlaeger, D. Lefevre, GD Magoulas e A. Poulouvassilis, "Analisando o envolvimento em um programa de gerenciamento online e implicações para o design do curso", em Proceedings of Sixth International Conference on Learning Analytics & Knowledge, pp. 236–240, Edimburgo, Reino Unido, abril de 2016.

[10] A. Pardo, F. Han e RA Ellis, "Explorando a relação entre autorregulação, atividades online e desempenho acadêmico: um estudo de caso", em Proceedings of Sixth International Conference on Learning Analytics & Knowledge, pp. 422–429, Edimburgo, Reino Unido, abril de 2016.

[11] SSA Hamid, N. Admodisastro, N. Manshor, A. Kamaruddin e AAA Ghani, "Modelo de aprendizagem adaptativa para dislexia: previsão do envolvimento do aluno usando abordagem de aprendizado de máquina", em Advances in Intelligent Systems and Computing, R. Ghazali, M. Deris, N. Nawi e J. Abawajy, Eds., pp. 372–384, Springer, Berlim, Alemanha, 2018.

[12] Raj, R. Joshua Samuel, et al. "Classificação ideal de imagens médicas baseada na seleção de recursos usando modelo de aprendizado profundo na Internet das coisas médicas." *Acesso IEEE* 8 (2020): 58006-58017.

[13] N. Bosch, "Detecting student engagement: human versus machine", em Proceedings of 24th International Conference on User Modelling, Adaptation and Personalization, pp. 317–320, Halifax, Nova Scotia, Canadá, julho de 2016.

[14] C. Milligan, A. Littlejohn e A. Margaryan, "Padrões de envolvimento em MOOCs conectivistas", Journal of Online Learning and Teaching, vol. 9, não. 2, pp.

[15] L. Ding, E. Er e M. Orey, "Um estudo exploratório do envolvimento dos alunos em discussões online gamificadas", Computers & Education, vol. 120, pp. 213–226, 2018.

[16] B. Bahati, F. Uno e M. Tedre, "O envolvimento dos alunos em cursos on-line prevêem desempenho em pesquisas de conhecimento on-line?," International Journal of Learning, Teaching and Educational Research, vol. 16, não. 3, pp. 73–87, 2017.