

Emoção e envolvimento dos alunos na aula

Sistema de detecção (iSEEDS): um sistema baseado em IA

Abordagem para ensino responsivo

Sai Krishna Vishnumolakala Departamento da

CSE SRM University

AP Andhra Pradesh, Índia

saikrishna.v1970@gmail.com

VSNV Sadwika Vallamkonda Departamento da

CSE SRM University

AP Andhra Pradesh, Índia

sadwika.vallamkonda@gmail.com

Departamento

Sobin CC da CSE

SRM University AP Andhra

Pradesh, Índia sobincc@gmail.com

Departamento NP

Subheesh de HSS

IIT Madras Chennai

Tamilnadu, Índia

npsubheesh@gmail.com

Jahfar Ali LTRC

IIIT

Hyderabad Telangana,

Índia jahfar2004@gmail.com

Resumo—A capacidade inata de reconhecer expressões faciais e emoções associadas é fundamental para a comunicação humana. Os avanços tecnológicos permitiram que os computadores executassem tarefas semelhantes em grande medida, abrindo aplicações versáteis em diversos domínios. Em particular, a tecnologia de reconhecimento de emoções faciais (FER) foi recentemente amplamente explorada para investigar o envolvimento dos alunos em ambientes de sala de aula. Embora pesquisas anteriores tenham cativado principalmente a prática do FER na detecção de engajamento, muito pouca atenção tem sido dada aos estados emocionais dos alunos em tempo real durante as interações em sala de aula. Nesse sentido, este artigo apresenta o Sistema de detecção de emoções e envolvimento dos alunos em sala de aula (iSEEDS), uma nova abordagem baseada em IA para identificar os estados emocionais dos alunos durante as aulas em sala de aula. O iSEEDS emprega modelos de Rede Neural Convolutiva (CNN) para detecção de emoções e análise correspondente do movimento ocular. O sistema pode ajudar os educadores a responder em tempo real aos estados emocionais e aos níveis de envolvimento dos alunos. Pode apoiar um ensino responsivo, iniciando feedback corretivo de acordo com as emoções e o envolvimento atuais dos alunos. Uma revisão detalhada da literatura dos modelos de reconhecimento de emoções existentes é apresentada como pano de fundo para o desenvolvimento do iSEEDS. Em seguida, são discutidos o design do modelo de protótipo inicial e os resultados ilustrativos dos testes. Também são elaboradas aplicações potenciais do iSEEDS e direções de pesquisas futuras.

Termos de indexação – análise de concentração, detecção de emoções, envolvimento, rastreamento ocular, iSEEDS, ensino responsivo, emoções dos alunos

I. INTRODUÇÃO

Encontrar maneiras de aumentar o envolvimento dos alunos é crucial para melhorar o processo de aprendizagem. De acordo com D'Errico, et. al [1], o engajamento é uma das medidas qualitativas do processo de aprendizagem. Ao aprender, possui uma estrutura tridimensional [2]. Existem três tipos de engajamento: engajamento comportamental, engajamento emocional (tédio) e engajamento cognitivo (atenção concentrada) [3]. A aprendizagem dos alunos, o envolvimento na sala de aula e as realizações são significativamente

influenciados por suas emoções. As emoções afetam a motivação dos alunos para estudar, gerenciam seu foco e afetam como eles regulam sua aprendizagem [4]. Uma das arquiteturas de aprendizagem profunda frequentemente usada para aplicações de reconhecimento e classificação de imagens é a CNN, que fez avanços significativos no campo da visão computacional. Nos últimos dez anos, os algoritmos de aprendizagem profunda dominaram o campo da inteligência artificial (IA).

Apesar de algumas pesquisas sobre detecção de expressões faciais, tem havido poucas investigações sobre como tal tecnologia poderia ser aplicada a sistemas de e-learning. Ainda é necessário haver abordagens adequadas para lidar com as emoções na aprendizagem. Como resultado, o objetivo principal deste trabalho é sugerir um novo método para analisar emoções com base em expressões faciais e rastreamento ocular usando CNN para o sistema de detecção de emoções e envolvimento dos alunos em sala de aula (iSEEDS). O método pode ser usado para melhorar a experiência de aprendizagem, e os materiais de aprendizagem podem ser atualizados avaliando as emoções do aluno usando o iSEEDS. Além disso, nesta pesquisa, fornecemos um sistema que pode reconhecer e rastrear as emoções e os níveis de concentração de um aluno enquanto ele aprende online ou em uma sala de aula que está sendo gravada. Além disso, o sistema iSEED fornece feedback em tempo real, que pode ser usado para aprimorar os recursos de ensino para melhorar a entrega de conteúdo.

Além disso, o sistema auxilia na compreensão das necessidades e do nível atual de compreensão dos alunos e, assim, promove um ensino responsivo.

II. ANTECEDENTES E TRABALHOS RELACIONADOS

As táticas e a tecnologia empregadas em diversas situações e circunstâncias para a aprendizagem em sala de aula são examinadas criticamente nesta seção. No entanto, há um trabalho limitado sobre a integração do reconhecimento facial e do rastreamento ocular. Tentamos fornecer uma visão precisa sobre essas abordagens.

A. Classificador para jogo de teste aritmético baseado em robô

Jang, M, et. al [5] conduziu um estudo sobre o desenvolvimento de um classificador usando dados para identificar a participação de crianças em um jogo de perguntas e respostas aritméticas baseado em robô. Gravações de vídeo de testes de HRI foram coletadas e a análise de vídeo foi usada para anotar sinais sociais e níveis de engajamento. Vetores de recursos foram então extraídos das anotações e classificadores foram desenvolvidos. Um robô andróide chamado EveR-4 foi usado em um experimento com sete participantes com idades entre 10 e 11 anos. O estudo alcançou 84,83% de desempenho de recordação ao ter três codificadores anotando as gravações de vídeo e extraindo recursos usando um paradigma de instantâneo com 1 segundo. prazo. O estudo apresentou um procedimento para desenvolver um reconhecedor de interação autônomo baseado em análise de vídeo em linha com a estratégia declarada no artigo. O impacto das ações sociais de um robô no envolvimento do usuário tem recebido muitos estudos, mas a detecção do envolvimento do usuário é rara. O procedimento estudado por Jang, M, et. al [5] poderia ser usado para desenvolver um reconhecedor de interação autônomo para robôs.

B. Métodos de visão computacional para medir o envolvimento dos alunos mento

O uso de métodos de visão computacional para medir o envolvimento do aluno em uma tarefa estruturada de escrita foi investigado no artigo de Monkaresi, et. al [6]. Para detectar níveis de participação durante e depois da tarefa, os alunos forneceram anotações. Para detectar esses níveis de engajamento auto-relatados, foram usados três conjuntos de recursos baseados em vídeo – frequência cardíaca, unidades de animação (do Microsoft Kinect Face Tracker) e padrões binários locais em três planos ortogonais (LBP-TOP). A aprendizagem supervisionada foi então aplicada a esses recursos, que alcançou AUCs de 0,758 para anotações coexistentes e 0,733 para anotações remanescentes.

C. Modelo de Rede Neural Convolutiva para Reconhecimento de Expressão Facial Os autores de

[7] projetaram um modelo de Rede Neural Convolutiva para identificar expressões faciais em estudantes usando cite cnn arch. Além disso, o modelo proposto consiste em quatro camadas convolucionais, quatro camadas de pooling máximo e duas camadas totalmente conectadas. O sistema reconhece rostos nas fotos dos alunos e os classifica em uma das sete expressões faciais: espanto, ansiedade, nojo, melancolia, satisfação, indignação ou equilíbrio. Isso é feito usando um detector do tipo Haar. Na base de dados FER 2013, o modelo sugerido teve uma taxa precisa de 70%. O professor pode determinar se os alunos estão entendendo ou não sua apresentação com o auxílio da tecnologia de reconhecimento de expressões faciais.

D. Rastreamento ocular emocional em um contexto de sala de aula

Este estudo em [8] explora o rastreamento ocular emocional na sala de aula, com foco no desenvolvimento de uma plataforma de aprendizagem online que utiliza dados oculares para rastrear o estado emocional de um aluno. Embora algumas plataformas de e-learning tenham usado informações do olhar para melhorar a aprendizagem, poucas extraíram informações emocionais de dados de rastreamento ocular de uma forma que pudesse refletir com precisão line. O experimental

processos cognitivos de um aluno. Esta pesquisa visa criar um ambiente de e-learning confiável onde os movimentos oculares possam ser interpretados com precisão como sinais de estresse, fadiga ou falta de compreensão. Foram realizados exames preliminares nos quais os alunos completavam problemas de matemática enquanto seus dados oculares eram capturados continuamente, permitindo a obtenção de medidas indiretas de velocidade e frequência de piscar.

E. Reconhecimento de envolvimento automatizado em tempo real de expressões faciais

Uma investigação das emoções dos alunos foi feita em uma animada sala de aula presencial no jornal [9]. Foi criada uma ferramenta online que permite aos professores ver os sentimentos dos alunos. O resultado, que é uma linha do tempo dos sentimentos dos alunos monitorados ao longo e concomitantemente com a palestra, ajuda o palestrante e outras partes interessadas a melhorar a forma como a educação é ministrada. Embora o sistema esteja funcionando corretamente, depende do envolvimento humano para que pontos importantes da aula, como aqueles que confundiram os alunos, sejam escolhidos pelo usuário. Tornar o projeto mais inteligente seria uma boa melhoria futura. O sistema analisaria os dados por conta própria, identificando efetivamente pontos de interesse ao longo da gravação, para que o usuário não precisasse depender apenas da visualização dos resultados da gravação. Esses pontos seriam então anotados pelo sistema ou receberiam notificações para o usuário revisar mais detalhadamente. Com a infraestrutura do sistema já instalada e o foco em código limpo e bem documentado, expandir o sistema para atender às necessidades futuras é uma tarefa simples.

F. Ferramenta para monitorar os sentimentos dos alunos em uma sala de aula presencial

Em [3], os pesquisadores exploraram o desenvolvimento de reconhecimento automatizado em tempo real do envolvimento dos alunos com base em expressões faciais. O estudo teve como objetivo automatizar a forma como os professores avaliam a participação dos alunos por meio de expressões faciais. A pesquisa foi baseada em pesquisas anteriores de reconhecimento de engajamento baseadas em visão computacional, que incluíam o maior conjunto de dados até o momento. Durante um exercício de treinamento cognitivo, as expressões faciais dos alunos foram registradas e vários métodos para medir o interesse dos alunos foram testados. O estudo descobriu que a confiabilidade interobservador era mais forte para cliques com cerca de 10 segundos de duração. Os observadores basearam suas conclusões na postura da cabeça e em expressões faciais simples, como sobrancelhas levantadas, olhos fechados e lábios superiores levantados. O estudo descobriu que técnicas de aprendizado de máquina poderiam ser usadas para criar detectores de engajamento automático em tempo real que sejam tão precisos quanto os observadores humanos. Finalmente, o estudo descobriu uma correlação entre o desempenho das tarefas e a avaliação automática do envolvimento nas tarefas.

G. RIAMS: uma solução criativa para gerenciamento de atendimento on-line

Um sistema criativo de gerenciamento de frequência de intervalo aleatório (RIAMS) dos autores de [10], que aborda a questão da necessidade de haver um sistema de gerenciamento de frequência adequado para escolaridade on-

as descobertas demonstram quão eficaz e escalável é o modelo de dispositivo RIAMS. Seu design simples permite que os professores regulem adequadamente a frequência dos alunos e produzam relatórios que atendam às necessidades administrativas. A abordagem automatizada diminui a quantidade de tempo e trabalho que deve ser despendido manualmente para rastrear e gerenciar a frequência nas aulas online. O RIAMS é incrivelmente robusto e fácil de usar e pode ser rapidamente conectado a qualquer plataforma de reunião virtual já existente. Ele oferece as seguintes funções de ponta usando reconhecimento facial AI-DL e modalidades auxiliares como CAPTCHA e UIN. Essas funcionalidades ajudarão a limitar qualquer tipo de má prática.

III. METODOLOGIA

No presente estudo para o desenvolvimento do Sistema iSEED para promover o ensino responsivo, criamos um sistema de detecção de expressões faciais e rastreamento ocular baseado em CNN, pretendendo incorporá-lo a um sistema de e-learning. Conduzimos os estudos usando dois conjuntos de dados de acesso gratuito, Fer 2013 para detecção de emoções do iSEEDS [11] e Eye Gaze [12] para rastreamento ocular do iSEEDS. Os dois conjuntos de dados diferentes são treinados para reconhecer emoções e posicionamento dos olhos. Os conjuntos de dados são pré-processados e treinados para os respectivos modelos, conforme descrito na figura 1.

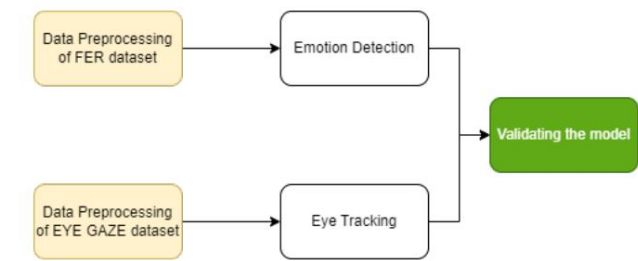


Figura 1: Construindo o Modelo CNN

O modelo de detecção de emoção e de detecção do olhar ocular usa a arquitetura CNN de [7] e a arquitetura resnet50, respectivamente, para prever a emoção e a localização do ponteiro do olho. Inicialmente, a imagem de entrada é pré-processada para extrair a face. A imagem pré-processada é passada pelo modelo. A arquitetura do modelo para detecção de emoções e rastreamento ocular é descrita nas figuras 2 e 3.

Esses modelos são passados com a mesma entrada. No entanto, para o modelo de rastreamento ocular, a imagem precisa ser preparada para cortar os olhos e passar como entrada. A saída do modelo de detecção de emoção são as probabilidades de uma emoção. A saída do segundo modelo é a probabilidade da posição dos olhos. As três principais emoções prováveis são avaliadas juntamente com a posição dos olhos. A média das três principais emoções e a posição dominante do olho são consideradas e validadas sobre a entrada personalizada, conforme descrito na figura 4. Para aumentar a escala, o processo é aplicado ao número n de alunos da turma.

Com base nessas duas métricas, o aluno é classificado em três clusters: altamente concentrado, neutro e baixa concentração.

Layer type	Size	Stride
Data	48x48	-
Convolution 1	3x3	2
Max Pooling 1	2x2	2
Convolution 2	3x3	2
Max Pooling 2	2x2	2
Convolution 3	3x3	2
Max Pooling 3	2x2	2
Convolution 4	3x3	2
Max Pooling 4	2x2	2
Fully Connected	-	-
Fully Connected	-	-

Fig. 2: Arquitetura do modelo de detecção de emoções iSEEDS

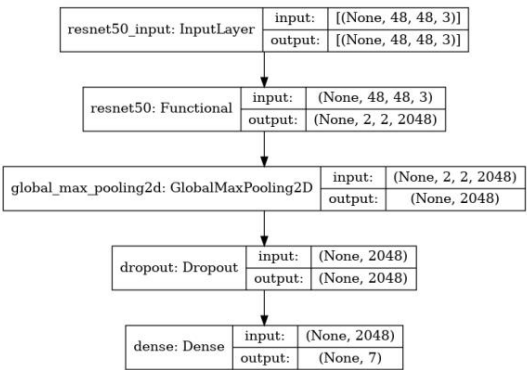


Figura 3: Arquitetura do modelo de rastreamento ocular iSEEDS

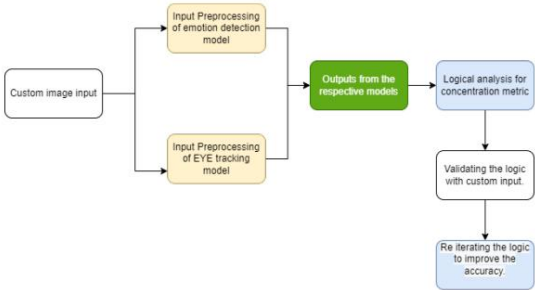


Fig. 4: Validando o modelo com entrada personalizada.

Após várias iterações dos modelos a seguir, essas métricas se assemelham ao nível de envolvimento dos usuários com razoável precisão.

- Alta Concentração: Se as emoções predominantes forem positivas e a posição dos olhos estiver alinhada ao centro, então a métrica de engajamento global é classificada como altamente concentrada. Emoções como felicidade e surpresa são categorizadas em um alto nível de concentração.
- Concentração Média: Se a emoção predominante for neutra e a posição dos olhos estiver alinhada ao centro, então a métrica de engajamento global é classificada como concentração Média. Emoções como neutras e felizes são categorizadas em um nível de concentração médio.

- **Baixa concentração:** Se as emoções predominantes forem negativas e confusas e a posição dos olhos não estiver alinhada ao centro, então a métrica de envolvimento global é classificada como baixa concentração. Emoções como medo, tristeza e nojo são categorizadas em baixo nível de concentração.

1) Métricas de concentração.

- a) Concentração Alta = 3 b)
- Concentração Média = 2 c)
- Concentração Baixa = 1 Os

valores descritos acima são atribuídos a cada métrica de concentração e os valores subsequentes da mesma faixa serão atribuídos às saídas dos modelos iSEEDS individuais. É evidente que o Sistema iSEEDS emprega dois modelos de classificação diferentes. Além disso, os seguintes valores são atribuídos às saídas dos dois modelos de classificação.

1) Resultados do sistema de rastreamento ocular.

- a) Centro = 3 b)
- Não Centro ou UP = 2 c) Não
- Centro ou LOW = 1 2) Saídas do

Sistema de Detecção de Emoções. a) Feliz ou Surpresa =

- 3 b) Neutro = 2 c) Raiva,
- Tristeza, Medo,
- Nojo = 1

A seguinte abordagem foi utilizada para extrair a análise de os modelos acima descritos.

Algoritmo 1 Análise Métrica de Concentração para

cada 10 quadros no tempo t^*10 , . . . **fazer**

para o quadro N, . . . **fazer**

Extraia probabilidades de emoção

emoção \hat{y} ($P(i)[\text{emoções positivas}] +$

$P(i)[\text{emoções neutras}] + P(i)[\text{emoções negativas}]/3$

Extraia o **final da posição**

dos

olhos para emoção \hat{y} emoção/

N eyepointer \hat{y} eyepointer/N **end para**

Métrica de concentração \hat{y} rodada $((\text{emoção} + \text{ponteiro ocular})/2)$

4. CONCLUSÕES E DISCUSSÕES

Com base nos experimentos realizados, vários resultados foram observados. Os modelos de detecção de emoções e rastreamento ocular baseados na CNN alcançaram precisões decentes. O modelo de detecção de emoções possui sete emoções para classificar. Ou seja, feliz, enojado, triste, neutro, irritado, medroso e surpreso. O agrupamento de emoções auxilia na segmentação do nível de concentração do usuário com base nas emoções extremas positivas e negativas. A Figura 5 mostra o resultado do modelo de detecção de emoções. O modelo de detecção de emoções iSEEDS fornece a emoção mais provável da pessoa em uma determinada entrada. A saída é posteriormente repassada ao pipeline iSEEDS para analisar a métrica de concentração juntamente com a saída do modelo de rastreamento ocular.




Fig. 5: Resultado do modelo de detecção de emoções iSEEDS

O modelo de rastreamento ocular iSEEDS foi treinado nas coordenadas para as quais os olhos estariam apontando. No entanto, os resultados dos modelos foram redefinidos para se adequarem aos resultados da investigação. Dois parâmetros de segmentação vertical e horizontal foram introduzidos para segmentar o posicionamento do olho em CIMA, BAIXO, DIREITA, ESQUERDA e CENTRO. Esses parâmetros auxiliam na avaliação detalhada do nível de concentração do usuário. A Figura 6 exhibe o modelo de rastreamento fora do olho.



Fig. 6: Resultado do modelo de rastreamento ocular iSEEDS

Utilizando as previsões do modelo, o pipeline foi empregado para testar duas palestras diferentes no mesmo usuário. A primeira palestra foi baseada no domínio de expertise do usuário, enquanto a outra palestra estava fora da expertise do usuário. As palestras tiveram duração de 80 minutos, e o agregado dos valores emocionais e valores posicionais dos olhos foi realizado a cada 10 minutos. Os valores 2, 1 e 0 são fornecidos para concentrações altas, médias e baixas, respectivamente. A Figura 7 representa os resultados dos experimentos.

Os níveis de concentração foram testados durante a palestra e variaram entre alto, médio e baixo. Baixa concentração foi observada quando o conteúdo estava fora do domínio de conhecimento do usuário, enquanto alta concentração foi encontrada quando o conteúdo era do domínio do usuário. Uma mistura de conteúdos resultou em concentração neutra. O modelo, utilizando a biblioteca de detecção de rosto dlib, pode identificar vários rostos em um quadro. Após resultados precisos de um pequeno grupo, o modelo será ampliado para detectar métricas de engajamento de grupos maiores.

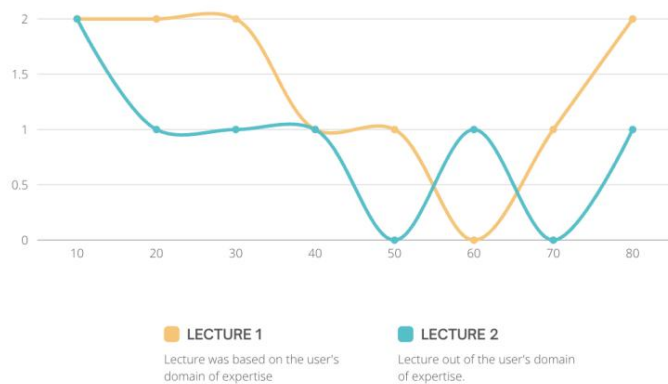


Fig. 7: Análise do pipeline iSEEDS

V. LIMITAÇÕES DO ESTUDO

O atual processo de implementação está limitado à análise pós-aula. O usuário só poderá obter a análise de sua palestra após finalizar toda a palestra. Uma análise ao vivo não é possível. A análise existente leva em conta apenas a emoção e o rastreamento ocular, mas não a estimativa da pose da cabeça. No entanto, a estimativa da pose da cabeça também é um aspecto crucial da análise de concentração.

VI. TRABALHO FUTURO

A precisão dos modelos de detecção de emoções e de detecção do olhar pode ser melhorada para melhor atender ao propósito. A estimativa da pose da cabeça pode ser incluída posteriormente na análise para ter uma métrica de concentração precisa. Atualmente, o modelo de olhar fixo segmenta apenas cinco posições dos olhos. No entanto, eles podem ser segmentados em nove posições. As posições adicionadas podem ser UP-RIGHT, UP-LEFT, DOWN-RIGHT e DOWN-LEFT. Assim, com base na experiência do domínio da psicologia educacional, a posição dos olhos e as emoções podem ser segmentadas com precisão para obter melhores resultados.

VII. CONCLUSÕES

Nesta pesquisa, apresentamos uma forma progressiva de manter e redesenhar o auxílio à aprendizagem, fornecendo ao palestrante informações relevantes sobre seu público para projetar uma palestra imersiva e promover um ensino responsivo. A qualidade da palestra poderia ser melhorada com o Sistema iSEED e tornada mais envolvente com base no nível de foco determinado pelos movimentos da cabeça e dos olhos. A análise dos níveis de concentração dos alunos do iSEEDS pode ser mapeada com os diferentes temas ministrados durante a aula, permitindo ao palestrante examinar os temas complexos para os alunos e atualizar a forma de ministração desses temas. Como as métricas são baseadas no movimento dos olhos e nas emoções, não precisamos utilizar dispositivos que necessitem de contato físico direto com o sujeito estudado. A técnica sugerida é eficaz o suficiente para identificar sentimentos desfavoráveis no aluno, como tédio ou falta de interesse pela sala de aula.

REFERÊNCIAS

- [1] D'Errico, Francesca & Paciello, Marinella & Cerniglia, Luca. (2016). Quando as emoções aumentam o envolvimento dos alunos nos processos de e-learning. *Jornal de E-Learning e Sociedade do Conhecimento*. 12. 9-23. 10.20368/1971- 8829/1144.
- [2] Fredricks, JA, Blumenfeld, PC e Paris, AH (2004). Engajamento Escolar: Potencial do Conceito, Estado da Evidência. *Revisão de Pesquisa Educacional*, 74(1), 59–109. <https://doi.org/10.3102/00346543074001059> [3] Whitehill, J. et. al. (2014) "As faces do envolvimento: Reconhecimento automático do envolvimento do aluno a partir de expressões faciais", *IEEE Transactions on Affective Computing*, 5(1), pp. Disponível em: <https://doi.org/10.1109/taffc.2014.2316163>.
- [4] MH Immordino-Yang e A. Damasio, "Sentimos, portanto aprendemos: a relevância da neurociência afetiva e social para a educação", *Mente, Cérebro e Educação*, vol. 1, não. 1. Wiley, pp. 3–10, março de 2007. doi: 10.1111/j.1751-228x.2007.00004.x.
- [5] Jang, M., Park, C., Yang, HS, Kim, JH, Cho, YJ, Lee, DW, ... e Ahn, BK (março de 2014). Construindo um reconhecedor de engajamento automatizado com base na análise de vídeo. Em *Anais da conferência internacional ACM/IEEE de 2014 sobre interação humano-robô* (pp. 182-183).
- [6] Monkaresi, H., Bosch, N., Calvo, RA, & D'Mello, SK (2016). Detecção automatizada de envolvimento usando estimativa baseada em vídeo de expressões faciais e frequência cardíaca. *Transações IEEE em Computação Afetiva*, 8(1), 15-28.
- [7] I. Lasri, AR Solh e ME Belkacemi, "Reconhecimento de emoções faciais de estudantes usando rede neural convolucional", 2019 Terceira Conferência Internacional sobre Computação Inteligente em Ciências de Dados (ICDS), 2019, pp. : 10.1109/ICDS47004.2019.8942386.
- [8] M. Porta, S. Ricotti e CJ Perez, "Emotional e-learning through eye tracking," *Proceedings of the 2012 IEEE Global Engineering Education Conference (EDUCON)*, 2012, pp. / EDUCON.2012.6201145.
- [9] A. Savva, V. Stylianou, K. Kyriacou e F. Domenach, "Reconhecendo expressões faciais de alunos: uma aplicação web", 2018 IEEE Global Engineering Education Conference (EDUCON), 2018, pp. 10.1109/EDUCON.2018.8363404.
- [10] SM Anzar, NP Subheesh, A. Panthakkan, S. Malayil e HA Ahmad, "Sistema de gerenciamento de frequência de intervalo aleatório (RIAMS): uma nova abordagem multimodal para aprendizagem virtual pós-COVID", em *IEEE Access*, vol. 9, pp.
- [11] IJ Goodfellow e outros. al., "Desafios na aprendizagem de representação: um relatório sobre três concursos de aprendizado de máquina". *arXiv*, 2013. doi: 10.48550/ARXIV.1307.0414.
- [12] S. Asteriadis, D. Soufleros, K. Karpouzis e S. Kollias, "Uma pose natural de cabeça e conjunto de dados de olhar ocular", *Anais do Workshop Internacional sobre Agentes Virtuais Conscientes Afetivos e Robôs Sociais - AFFINE '09*. ACM Press, 2009. doi: 10.1145/1655260.1655261.